

IP 파운데이션 월드모델 연구 노트 293

만나는 것은 같은 작품이다

별칭 사전이 만화↔웹툰을 1건에서 175건으로 열었다 --- 그런데 152건이 같은 작품이고 lab 은 이미 그걸 걸러 놓았다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 291이 “도메인끼리 이름으로 안 만난다”로 끝나면서 별칭 사전을 남은 것으로 적었다. 조사했다(병렬 에이전트). 웹툰↔애니에서는 별칭이 소용없다 — 둘 다 이미 한국어라 표기 문제가 아니고, 병목은 모집단이다 (웹툰 2,817편 중 라프텔에 애니가 있는 게 원래 십수 편). 천장이 14~20건 이고 그 증가분도 별칭이 아니라 시즌 접미사 정리에서 나온다. 그런데 만화↔웹툰은 다르다 — cache_manga_kr 에 한글 원제가 있어 1건 → 175건이 된다. 여기서 멈추지 않고 그 175건이 무엇인지 봤다. 만화가 웹툰보다 먼저 시작한 것은 23건(0.8%) 이고 나머지 152건은 같은 작품이 두 곳에 있는 것이다 — AniList 의 MANGA 포맷이 한국 웹툰을 포함하기 때문이다. 그리고 lab 의 만화 도메인은 그 전부를 이미 제외하고 있다: 만화 레코드는 JP 1,789 · KR 556 · CN 55 인데 lab 도메인은 JP 1,789 뿐이다. 웹툰과 붙는 것은 전부 KR 556 안에 있다. 그래서 웹툰 유보 × 만화 학습 중복 쌍이 0개다 — 중복 누출이 없다. 도메인이 만나는 자리는 대개 전이가 아니라 중복이고, 이 실험실은 그걸 이미 걸러 놓았다. 진짜 크로스 IP 23건은 웹툰의 0.8% 라 검출 문턱 0.046 근처도 못 간다.

1. 별칭 사전을 실제로 세어 봤다

노트 291이 열한 도메인이 이름으로 안 만난다는 것을 채고(웹툰↔애니 10건 · 만화↔게임 1건), 원인을 “표기가 다르다”로 적었다. 별칭 사전이 그걸 고칠 수 있는지 재료를 세었다.

재료	
세계애니 synonyms 중 한글 포함	85 / 7,169 (1.2%)
anime_match.json 다리	87건 (그중 51 해소)
cache_manga_kr 한글 원제	1,250 (만화 556건 덮음)
모바일 bundleId IP 토큰 수율	0.3%

웹툰↔애니에서는 별칭이 소용없다. 누적 실험 결과 9 → 14 → 15건인데, 증가분의 대부분(9→14)이 별칭이 아니라 시즌 · 괄호 접미사 정리에서 나온다. anime_match(87건)와 세계애니 한글 별칭(85개)을 통째로 넣어도 증가 0건이다. 이유는 명확하다 — 웹툰과 라프텔은 이미 둘 다 한국어다. 표기가 문제가 아니라 모집단이 안 겹친다(웹툰 2,817편 중 라프텔에 애니가 있는 작품이 원래 십수 편). 노트 291의 진단이 이 쌍에서는 틀렸다.

2. 만화↔웹툰은 1건에서 175건

만화는 다르다. manga_records 의 title 이 romaji 뿐인데 (Kimetsu no Yaiba) cache_manga_kr 에 한글 원제가 있다. 붙이면 만화↔웹툰이 1건 → 175건이다.

여기서 멈추면 안 된다(노트 133). 그 175건이 무엇인지 봤다.

웹툰 2,817행 중	
만화와 이름이 붙는 쌍	175
만화가 먼저 시작한 것	23 (0.8%)
나머지	152

152건은 웹툰이 먼저다. AniList 의 MANGA 포맷이 한국 웹툰(만화)을 포함하기 때문이다 — 같은 작품이 두 도메인에 있는 것이지 다른 IP 가 만난 것이 아니다.

3. lab 은 이미 걸러 놓았다

같은 작품이 한쪽은 학습, 한쪽은 채점이면 중복 누출이다. 썼다.

	레코드 전체	lab 만화 도메인
JP	1,789	1,789
KR	556	0
CN	55	0

lab 의 만화 도메인은 일본 것만 쓴다. 웹툰과 붙는 175건은 전부 제외된 KR 556 안에 있다. 그래서

웹툰 유보 × 만화 학습 중복 쌍 = 0개

이다. 누출이 없다. 그 제외가 의도였는지 우연이었는데는 이 노트에서 확인 안 했지만, 결과는 옳다.

그리고 그래서 크로스 링크도 0이다. 같은 제외가 쓸 수 있는 링크도 같이 없앤다. 진짜 크로스 IP 23건도 KR 안에 있어 lab 의 만화 도메인엔 없다. 누출을 막는 벽과 전이를 막는 벽이 같은 벽이다.

도메인이 만나는 자리는 대개 같은 작품이다




Figure 1: 왼쪽 — 별칭 사전이 연 175건을 갈라 본 것. 오른쪽 — 만화 레코드의 국가 분포와 lab 만화 도메인.

4. 그리고 라벨은 어차피 못 쓴다

설령 링크가 있어도 만화의 라벨은 못 쓴다. `y_popularity` 는 AniList 의 지금 굵은 스냅샷이고 (`label_basis` 가 2,400건 전부 비어 있다) 노트 224가 `kitsu_rating · kitsu_rank` 를 막은 것과 같은 이유로 사후다 — 웹툰이 연재를 시작하는 시점에 그 만화의 현재 인기는 존재하지 않는다.

쓸 수 있는 것은 라벨이 아니라 존재와 시점이다: “이 IP 가 웹툰 이전에 만화로 있었다.” 그게 23건이고 웹툰의 0.8% 다. 노트 274가 켜 웹툰의 검출 문턱이 0.046 인데, 행의 0.8% 만 건드리는 축이 그만큼을 낼 수는 없다.

남은 것.

갈래	왜
만화 KR 556 을 도메인으로	웹툰과 중복이라 안 된다
회사 축	게임↔모바일 59개는 아직 안 재 봤다
팝업 허브	노트 291의 조인은 여전히 유효
하네스에서 재기	분해능이 다른 유일한 자리

규약. 도메인이 만나면 전이인지 중복인지 먼저 가른다. “만화↔웹툰 175건”은 얼핏 크로스 도메인 전이의 재료로 보이지만 152건이 같은 작품이었다. 그리고 누출을 막는 설계는 전이도 같이 막는다 — lab 의 만화가 일본 것만 쓰는 것이 중복 누출을 0으로 만들고 동시에 크로스 링크도 0으로 만든다. 둘 중 하나만 고를 수는 없다.