

IP 파운데이션 월드모델 연구 노트 117

가장 큰 이득이 누수였다

평점을 굵어 전수 검정을 돌리자 +0.0384 채택 4/4가 나왔는데, 그 축은 라벨을 재는 두 번째 자였다 ---
검정이 싸지면 누수도 싸게 들어온다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 116이 후보 스무 개를 전부 걸어 채택 0을 냈고, 스무 개의 공통점은 전부 양(□)이거나 정적 메타라는 것이었다. 라벨도 전부 양이다(리뷰 수 · 서재 등록 수 · 관심 수 · 후원자 수 · 방문자 수). 평점은 다르다 — “본 사람들이 얼마나 좋아했나”는 “얼마나 많이 봤나”와 다른 물리량이다. AniList 에서 만화 1,789 · 세계애니 2,948의 평점 · 즐겨찾기 · 트렌딩을 받고, 캐시에서 모바일 · 애니 평점을 뽑아 후보 셋을 더했다(덮개율 99~100%). 전수 검정 403초. 즐겨찾기가 +0.0384로 채택 4/4 — 구간 +0.0352~ +0.0407, 이 프로젝트 최대다. 트렌딩도 +0.0064 채택 4/4. 둘 다 누수였다. AniList popularity 가 만화 · 세계애니의 라벨 그 자체이고($\rho=+1.000$) 즐겨찾기가 그것과 +0.855로 붙는다 — 같은 플랫폼의 같은 사용자가 매긴 두 번째 계수였다. 트렌딩은 라벨 상관 +0.505로 문턱을 빠져나가는데, 계산 자체가 그 플랫폼의 최근 목록 추가 · 투표라서 라벨을 만든 계수기의 미분값이다. 상관 문턱은 필요조건이지 충분조건이 아니다. 두 겹으로 막았다 — 라벨 상관 0.70 문턱과 출처 차단(라벨을 만든 계수기에서 나온 축은 상관이 낮아도 안 쓴다). state/sweep.py 에 넣었다. 막고 다시 돌리니 후보 21개, 채택 0이다. 깨끗한 것은 평점 하나뿐이고(-0.033~+0.386, 물리량이 다르다) Δ 가 -0.0061로 보류다. 노트 116이 “재지 말고 걸어 봐라”로 지침을 뒤집었는데, 그 지침의 필수 짝이 이 검사다.

Table 1: 굵은 것. 실패 0건.

	건수	출처
만화	1,789	AniList meanScore · favourites · trending
세계애니	2,948	"
모바일	2,000	앱스토어 averageUserRating(캐시)
애니	2,073	라프텔 avg_rating(캐시)

Table 2: 전수 검정 23개 · 403초.

	Δ	채택	구간(첫 싸앗)
즐거찾기	+0.0384	4/4	+0.0352 ~ +0.0407
트렌딩	+0.0064	4/4	+0.0024 ~ +0.0134
평점	-0.0061	0/4	-0.0189 ~ +0.0030
나머지 스무 개	노트 116과 같음(채택 0)		

1. 다른 물리량을 굵었다

노트 116의 후보 스무 개는 전부 양이거나 정적 메타였다 — 글자 수 · 문장 수 · 밝기 · 채도 · 임베딩 성분. 라벨도 전부 양이다. 평점은 다른 물리량이다.

2. 프로젝트 최대 이득이 나왔다

+0.0384는 노트 108의 채택(+0.0232)보다 크고 구간이 좁다. 발표할 뻔했다.

Table 3: 누수 사슬.

AniList popularity vs 만화 라벨	+1.000
즐거찾기 vs popularity	+0.855
즐거찾기 vs 만화 라벨	+0.855
즐거찾기 vs 세계애니 라벨	+0.887

3. 둘 다 누수였다

주장 1. 만화 · 세계애니의 라벨은 AniList popularity 그 자체다($\rho=+1.000$). 즐겨찾기는 같은 플랫폼의 같은 사용자가 매긴 두 번째 계수이고 라벨과 +0.855~+0.887로 붙는다. +0.0384는 새 정보가 아니라 라벨을 다시 읽은 것이다.

반증 조건. 라벨이 popularity 라는 것은 처음부터 알던 사실이다(노트 78 · 81). 놓친 것은 같은 API 의 다른 필드가 그것의 사촌이라는 점이었다.

주장 2. 상관 문턱은 필요조건이지 충분조건이 아니다. 즐겨찾기는 0.70 문턱에 걸리지만 트렌딩은 +0.505로 빠져나가면서 싸앗 넷을 통과한다. 트렌딩은 그 플랫폼의 최근 목록 추가 · 투표로 계산되는 순위이므로 라벨을 만든 계수기의 미분값이다.

반증 조건. 평점도 만화 · 세계애니에서 +0.36~+0.39




Figure 1: 왼쪽 — 같은 계수기의 두 번째 자. 가운데 — 채택 둘이 다 누수였다. 오른쪽 — 문턱만으로는 못 잡는다.

Table 4: 후보와 그 도메인 라벨의 상관.

	상관	뒷개울
즐거찾기 · 세계애니	+0.887	100%
즐거찾기 · 만화	+0.855	100%
트렌딩 · 세계애니	+0.505	61%
트렌딩 · 만화	+0.320	30%
평점 · 만화	+0.386	100%
평점 · 세계애니	+0.363	99%
평점 · 모바일	+0.057	100%
평점 · 애니	-0.033	100%

Table 5: 막고 다시 돌린 결과.

후보	21개(누수 둘 제외)
시간	389초
채택	0
가장 나은 것	emb3 +0.0011

로 꽤 붙는다. 문턱을 0.35로 낮추면 평점도 걸린다 — 문턱값 자체가 자의적이다. 그래서 출처 차단을 함께 쓴다.

4. 두 겹으로 막았다

```
state/sweep.py leak_check()
```

- ① 라벨 상관 ≥ 0.70 이면 뺀다
- ② 라벨을 만든 계수기에서 나온 축은 상관과 무관하게 뺀다
(favourites · trending · popularity)

노트 116이 지침을 뒤집었다 — “재지 말고 굶어서 걸어 보라.” 판정이 육 분이면 그것이 옳다. 그런데 검정이 싸지면 누수도 싸게 들어온다. 후보를 손으로 하나씩 만들 때는 그 축이 무엇인지 알고 있었는데, API 필드를 통째로

굶어 다 걸면 모른 채로 들어온다. 빠른 검정의 필수 짝은 빠른 누수 검사다.

5. 한계

- 채택할 것이 없다. 누수 둘을 빼면 채택 0이다.
- 문턱 0.70이 자의적이다. 0.35로 낮추면 평점도 걸린다.
- 출처 차단이 이름 목록이다. 새 API 필드를 굶을 때마다 사람이 판단해 넣어야 한다 — 자동이 아니다.
- 평점의 뒷개울이 네 도메인뿐이다. 웹툰 · 도서 · 편딩 · 게임 · 팝업에는 없다.
- “평점은 다른 물리량”이라는 전제 자체가 만화 · 세계애니에서는 약하다 (라벨 상관 +0.36~+0.39).

6. 다음

1. 출처 차단을 자동화한다 — 지금은 이름 목록이다. 후보를 만들 때 “이 필드는 어느 계수기에서 나왔나”를 함께 적게 하고, 라벨의 계수기와 같으면 자동으로 뺀다.
2. 라벨과 다른 계수기를 찾는다 — 이번 시도의 취지는 옳았다. 평점은 물리량이 다르지만 같은 플랫폼이라 절반만 다르다. 다른 플랫폼의 다른 계수기가 필요하다(예: 만화의 판매 순위, 애니의 방영 시청률).
3. 팝업 레코드 — 열린 노트가 같은 곳을 가리킨다.
4. 텀블벅 API — 편딩만 미디어 홍보 0%다.

참고문헌

- Kaufman, S. et al. (2012). Leakage in data mining: formulation, detection, and avoidance. ACM TKDD, 6(4), 1–21.
- Cawley, G. C., Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. JMLR, 11, 2079–2107.

- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.
- Lord, F. M., Novick, M. R. (1968). Statistical Theories of Mental Test Scores. Addison-Wesley.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.