

IP 파운데이션 월드모델 연구 노트 118

좋아함은 잘 재지는데

다른 플랫폼에서 평점을 2,892건 이어 붙였다 --- 두 플랫폼 평점이 $\rho=+0.969$ 로 일치하는데(라벨은 $+0.555$) 전이는 -0.0005 다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 117의 교훈은 “평점은 물리량이 다르지만 같은 플랫폼이라 절반만 다르다”였다. 다른 플랫폼의 다른 계수기를 찾았다. MyAnimeList(Jikan)는 504로 막혀 있었고 Kitsu 가 열려 있었다. AniList idMal 4,716건을 다리로 세계애니 2,892건(98%)을 이었다. 누수 규칙을 지켜 골랐다 — $\text{userCount} \cdot \text{favoritesCount} \cdot \text{popularityRank}$ 는 라벨과 같은 물리량이라 안 쓰고 $\text{averageRating} \cdot \text{ratingRank}$ 만 썼다. 채택 0이다 — Kitsu 평점 -0.0005 · Kitsu 순위 -0.0005 · 두 플랫폼 평균 -0.0002 , 전부 0 근처 보류다. 대신 새 수치가 나왔다. 두 플랫폼의 평점이 $\rho=+0.969$ 로 일치한다($n=2,864$). 노트 79 · 83이 두 플랫폼 라벨로 갠 것은 $+0.555$ 였다. 신뢰도 천장으로 바꾸면 라벨 0.734 대 평점 0.984다. 시끄러운 것은 축이 아니라 라벨이었다. 그리고 여기서 이 프로젝트가 오래 피해 온 사실이 드러난다 — 평점은 거의 완벽하게 재지는데도 전이를 못 돕는다. 사람들이 무엇을 좋아하는지는 두 플랫폼이 똑같이 말해 주는데, 그것이 얼마나 많이 불지를 안 알려 준다. 노트 93이 “축에 없는 것 0.256”이라 부른 것의 일부는 원리적으로 축에 담길 수 없는 것이다 — 질과 양은 다른 축이고, 질을 아무리 잘 재도 양이 안 나온다.

Table 1: 후보 셋을 두드렸다.

MyAnimeList(Jikan)	504 Gateway Time-out
Kitsu	열려 있다
스팀 메타크리틱	뒷개울 31%(캐시)

Table 2: Kitsu 에서 받은 것과 쓴 것.

averageRating	쓴다	다른 사용자층의 질
ratingRank	쓴다	그 순위
userCount	안 쓴다	라벨과 같은 물리량
favoritesCount	안 쓴다	"
popularityRank	안 쓴다	"

Table 3: 전수 검정 24개 · 422초, 평점 계열만.

	Δ	채택	구간(첫 씨앗)
두 플랫폼 평균	-0.0002	0/4	$-0.0036 \sim +0.0061$
Kitsu 순위	-0.0005	0/4	$-0.0037 \sim +0.0062$
Kitsu 평점	-0.0005	0/4	$-0.0037 \sim +0.0062$
평점(노트 117)	-0.0061	0/4	$-0.0189 \sim +0.0030$

Table 4: 두 플랫폼이 같은 것을 질 때 얼마나 맞다.

	무엇을	ρ	천장 $\sqrt{\rho}$
노트 79 · 83	라벨(양)	$+0.555$	0.734
이번	평점(질)	$+0.969$	0.984

1. 다른 플랫폼을 찾았다

Kitsu 는 MAL 대응을 주므로 AniList idMal 을 다리로 쓸 수 있다. 스무 개씩 묶어 148번 요청, 148/148 성공, 세계애니 2,892/2,945(98%).

노트 117의 출처 차단을 스스로에게 먼저 적용했다 — 셋은 굵어 두고 안 썼다.

2. 채택 0

구간이 매우 좁다(± 0.005). 못 넘는 것이 아니라 아무 일도 안 일어난다.

3. 그런데 질은 거의 완벽히 재진다

AniList 와 Kitsu 는 다른 사이트, 다른 사용자층, 다른 평점 눈금(100점 대 100점)을 쓴다. 그런데 2,864건에서 순위 상관이 $+0.969$ 다.

주장 1. 시끄러운 것은 축이 아니라 라벨이다. 같은 두 플랫폼 구조에서 질은 $+0.969$ 로 맞고 양은 $+0.555$ 로 맞는다. 노트 83의 라벨 천장 0.734는 양을 재는 것이 어렵다는 뜻이지 세상이 예측 불가라는 뜻이 아니다.

반증 조건. 세계애니 하나에서 썼다. 노트 79 · 83은 웹툰/만화와 애니/세계애니 두 쌍에서 $+0.52 \sim +0.56$ 을 얻었으므로 라벨 쪽은 두 번 확인됐지만 평점 쪽은 한 번이다.




Figure 1: 왼쪽 — 질은 거의 완벽히 재진다. 가운데 — 두 플랫폼이 같은 말을 한다. 오른쪽 — 그래도 전이는 0이다.

Table 5: 이 프로젝트가 재는 것.

	물리량	두 플랫폼 일치
라벨	양(방문자 · 리뷰 수 · 후원자)	+0.555
새 축 후보	질(평점)	+0.969
둘의 관계 — 세계애니에서 $\rho = +0.41$		

4. 질과 양은 다른 축이다

평점은 거의 완벽하게 재지는데도 전이를 못 돕는다($\Delta -0.0005$, 구간 ± 0.005). 사람들이 무엇을 좋아하는지는 두 플랫폼이 똑같이 말해 주는데, 그것이 얼마나 많이 볼지를 안 알려 준다.

주장 2. 노트 93이 “축에 없는 것 0.256”이라 부른 것의 일부는 원리적으로 축에 담길 수 없는 것이다. 질을 아무리 잘 재도 양이 안 나온다 — 측정 잡음 때문이 아니라 두 물리량이 다르기 때문이다.

반증 조건. “전이를 못 돕는다”는 이 구조에서 그렇다는 뜻이다. 라벨을 질로 바꾸면(예: 팝업 만족도) 평점 축이 크게 도울 것이다. 다만 사업이 묻는 것은 몇 명 오는가이지 얼마나 좋았는가가 아니다.

질과 양의 상관관계는 +0.41이다. 겹치는 것이 17%뿐이므로 질을 완벽히 알아도 양의 83%는 여전히 모른다.

5. 한계

- 채택할 것이 없다. 평점 계열 넷이 전부 0 근처다.
- 평점 천장 0.984를 세계애니 하나에서 졌다.
- Kitsu를 세계애니에만 붙였다. 만화도 idMal이 있는데 Kitsu의 만화 대응은 안 봤다.
- “질이 양을 안 설명한다”를 상관 +0.41 하나로 말했다. 도메인마다 다를 수 있다.

- 스팀 메타크리틱(전문가 평점)은 덮개를 31%라 안 넣었다. 그것은 사용자가 아니라 비평가라 또 다른 계수기다.

6. 다음

1. 양을 재는 다른 계수기 — 질은 막혔다. 양을 다른 플랫폼에서 재면 라벨 잡음을 줄일 수 있다(노트 83의 천장을 올리는 길). Kitsu userCount를 축이 아니라 라벨 보정에 쓴다 — 두 플랫폼 평균이 참값에 더 가깝다.
2. 팝업 레코드 — 열두 노트가 같은 곳을 가리킨다.
3. 만화에도 Kitsu를 붙인다.
4. 텀블벅 API — 펀딩만 미디어 홍보 0%다.

참고문헌

- Lord, F. M., Novick, M. R. (1968). Statistical Theories of Mental Test Scores. Addison-Wesley.
- Kaufman, S. et al. (2012). Leakage in data mining: formulation, detection, and avoidance. ACM TKDD, 6(4), 1–21.
- Spearman, C. (1904). The proof and measurement of association between two things. American Journal of Psychology, 15(1), 72–101.
- Ben-David, S. et al. (2010). A theory of learning from different domains. Machine Learning, 79(1–2), 151–175.
- Efron, B., Tibshirani, R. J. (1993). An Introduction to the Bootstrap. Chapman & Hall.