

IP 파운데이션 월드모델 연구 노트 122

눈금을 고쳐도 모형은 안 좋아진다

세 출처를 정직한 라벨로 바꾸니 팍업만 +0.0104(보류)이고 나머지 여섯은 -0.0018 --- 효과의 전부가 부풀림이 가장 컸던 게임 하나에서 온다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 121이 관측만 하고 남긴 것을 검정했다 — 세 출처(세계애니 · 만화 · 게임)의 라벨을 다른 플랫폼 것으로 바꾸면 팍업이 오르는가. 라벨이 바뀐 셋은 대상으로 쓰면 정의가 달라지므로 **라벨이 안 바뀐 일곱만 대상으로** 뒀다. 팍업은 +0.0104 오르는데 씨앗 넷 전부 보류다(구간 -0.040 ~ +0.038). 나머지 여섯은 -0.0018이다. 부분집합 일곱을 다 돌리니 원인이 하나로 좁혀진다 — **게임 하나가 효과의 전부다**. 게임만 바뀌도 +0.0100 이고 세계애니만 바꾸면 오히려 -0.0044다. 게임은 노트 120에서 부풀림이 가장 컸던 도메인이다(38%, 다른 둘은 21 · 23%). 그래서 이 **눈금 이야기**(노트 117-122)가 닫힌다. 여섯 노트에 걸쳐 누수를 잡고(117) 다른 플랫폼을 붙이고(118) 정합을 재고(119 · 120) 법칙을 다시 짰는데(121), **측정은 바로잡혔지만 모형은 안 좋아졌다**. 이 프로젝트에서 “원리적으로 옳은 쪽이 지는” 일곱째 사례다(노트 40 · 48 · 85-88 · 103 · 105 · 114, 그리고 여기). 다만 이번 것은 빈손이 아니다 — 수치를 못 올렸지만 수치의 뜻을 바꿨다. 팍업의 +0.4391 은 다른 도메인의 +0.54와 견줄 수 없는 값이었고, 정직한 눈금에서 팍업은 열 중 셋째다(노트 120).

Table 1: 어느 출처의 라벨을 정직하게 바꾸나. 대상은 라벨이 안 바뀐 일곱.

바꾼 출처	Δ팍업	Δ나머지 여섯
세계애니	-0.0044	-0.0015
만화	+0.0042	-0.0002
게임	+0.0100	-0.0010
세계애니 · 만화	+0.0054	+0.0007
세계애니 · 게임	+0.0079	-0.0017
만화 · 게임	+0.0102	-0.0018
셋 다	+0.0104	-0.0018

Table 2: 셋 다 정직하게. 씨앗 넷 · 짝지는 붓스트랩 100회.

	Δ	95% 구간
팍업	+0.0104	-0.0401 ~ +0.0356 -0.0242 ~ +0.0307 -0.0200 ~ +0.0341 -0.0207 ~ +0.0379
나머지 여섯	-0.0018	보류 4/4
보류 4/4 — 채택하지 않는다		

Table 3: 노트 117-122가 한 것.

117	누수를 잡고 두 겹 가드를 넣었다
118	다른 플랫폼(Kitsu)을 붙였다 — 질은 $\rho=+0.969$
119	자기 ρ 의 23%가 같은 플랫폼 정합
120	세 도메인에서 21~38% 확인, 팍업이 셋째로
121	법칙 1은 서고 법칙 2는 반토막
122	그런데 모형은 안 좋아진다

1. 부분집합 일곱을 다 돌렸다

주장 1. 게임 하나가 효과의 전부다. 게임만 바뀌도 +0.0100이고 셋 다 바뀌도 +0.0104다. 세계애니만 바꾸면 오히려 -0.0044다. 게임은 노트 120에서 부풀림이 가장 컸던 도메인이다(38% 대 21 · 23%).

반증 조건. 셋뿐이라 “부풀림이 클수록 효과가 크다”를 말할 수 없다 — 만화(21%)가 세계애니(23%)보다 큰 효과를 낸다. 게임이 다른 이유는 부풀림 말고도 있을 수 있다.

반증 조건. 팍업 구간이 ± 0.035 로 넓다. $n=75$ 의 한 계이고, 이 크기의 효과를 이 표본으로 가를 수 없다(노트 92).

2. 문턱을 못 넘는다

주장 2. 출처를 정직하게 바꾸는 것이 모형을 좋게 하지 않는다. 팍업이 +0.0104 오르지만 씨앗 넷 다 보류이고, 나머지 여섯은 -0.0018로 오히려 미세하게 나쁘다.

3. 눈금 이야기가 닫힌다

주장 3. 여섯 노트에 걸쳐 측정은 바로잡혔지만 모형은 안 좋아졌다. “원리적으로 옳은 쪽이 지는” 일곱째 사례다(노트 40 · 48 · 85-88 · 103 · 105 · 114).




Figure 1: 왼쪽 — 게임 하나가 효과의 전부다. 가운데 — 팝업만 오른다. 오른쪽 — 문턱을 못 넘는다.

반증 조건. 그렇다고 되돌릴 것도 없다 — 라벨을 안 바꿨고 바꾸지도 않는다. 이 여섯 노트는 실정이 아니라 해석을 고쳤다.

다만 이번 것은 빈손이 아니다. 수치를 못 올렸지만 수치의 뜻을 바꿨다. 팝업의 +0.4391은 다른 도메인의 +0.54와 견줄 수 있는 값이 아니었고 — 저쪽은 축과 라벨이 같은 API에서 나와 21~38% 부풀려져 있었다 — 정직한 눈금에서 팝업은 열 중 셋째다. 지난 열다섯 노트가 “팝업이 왜 이렇게 낮은가”를 물었는데, 질문 자체가 틀렸다.

4. 한계

- 채택할 것이 없다. 팝업 +0.0104가 보류 4/4다.
- 부분집합 일곱에서 게임 하나가 지렛대인데 이유를 모른다.
- 남은 다섯 도메인(모바일 · 웹툰 · 도서 · 편딩 · 애니)은 정직한 라벨을 아직 못 구했다 — 노트 120의 순위표 절반이 추정이다.
- 라벨을 바꾸면 표본이 조금 준다(만화 1,789 → 1,596). 표본 변화가 섞여 있다.
- 팝업 구간 ± 0.035 . 이 크기의 효과를 $n=75$ 로 못 가른다.

5. 다음

1. 눈금 이야기를 접고 제품으로 돌아간다 — 여섯 노트가 해석을 고쳤고 성능은 그대로다. `state/score.py`의 자기 검사와 노트 91의 도구 순위표를 정직한 눈금으로 다시 내 문서만 고친다.
2. 게임이 왜 다른가 — 부분집합 실험의 유일한 미해결.
3. 팝업 레코드 — 열여섯 노트가 같은 곳을 가리킨다. 이제 “팝업이 낮아서”가 아니라 “구간이 넓어서”다. 모으는 절차를 설계할 때가 됐다.

4. 남은 다섯의 정직한 라벨.

참고문헌

- Campbell, D. T., Fiske, D. W. (1959). Convergent and discriminant validation by the multitrait-multimethod matrix. *Psychological Bulletin*, 56(2), 81–105.
- Lord, F. M., Novick, M. R. (1968). *Statistical Theories of Mental Test Scores*. Addison-Wesley.
- Efron, B., Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Varoquaux, G. (2018). Cross-validation failure: small sample sizes lead to large error bars. *NeuroImage*, 180, 68–77.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151–175.