

IP 파운데이션 월드모델 연구 노트 123

주최자 주장은 신호가 아니었다

라벨 350건 중 75건만 쓰는 이유를 제니 --- 주최자 주장 98건만으로는 ρ 가 -0.05 다. 발굴은 막혔고 자연
 축적은 스물한 해다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 122가 눈금 이야기를 닫으며 물음을 하나로 좁혔다 — 팝업이 낮은 것이 아니라 구간이 넓다. 그러면
 답도 하나다: 몇 건을 모으면 무엇을 판정할 수 있나. 팝업을 n 건으로 줄여 가며 짝지은 차이의 구간 반폭을
 재고 n^b 를 맞췄다 — 반폭 = $2.28 n^{-0.88}$. 이론값 -0.5 보다 가파르다. 목표별 필요 표본은 $137(\pm 0.030) \cdot$
 $217(\pm 0.020) \cdot 476(\pm 0.010) \cdot 1,046(\pm 0.005)$ 이고, 지금 연 18.8건이 쌓이므로 $+0.01$ 짜리를 가르려면 스물한
 해가 걸린다. 그래서 발굴을 봤다. 관문을 폭포로 세니 레코드 376건, 라벨 있는 것 350건, 실제로 쓰는 것 75
 건이다. 최대 병목은 계수 방법 관문이고 주최자 주장 247건이 여기서 빠진다. 풀면 173건이 되니 구간이 확
 좁아질 터였다. 풀어 봤다. 성적이 무너진다 — ρ 가 $+0.4601$ 에서 $+0.0352$ 로 간다. 주최자 주장만 따로 재면
 $-0.0539(n=98)$ 다. 주최자 주장 방문자 수에는 예측 가능한 신호가 없다. 실측 발자국을 $\rho=0.46$ 으로 맞히는
 축들이 주최자 주장은 $\rho \approx 0$ 으로 맞힌다. 그러므로 발굴은 막혔다 — 있는 라벨의 79%가 쓸 수 없는 라벨이다.
 남은 길은 하나다: 앞으로 여는 팝업에 실측 계수를 붙이는 것. 연 18.8건이 연 40건이 되면 스물한 해가 열
 해가 되고, 그것이 이 프로젝트에서 가장 값싼 지렛대다 — 축을 스물세 개 굵어 채택 0이었는데, 실측 계수
 하나가 그보다 크다.

Table 1: 팝업을 n 건으로 줄이며 켜 짝지은 차이(공통 축 다섯 — 셋)의 구간 반폭.

n	Δ	반폭
25	$+0.0175$	0.1238
35	$+0.0213$	0.1028
45	$+0.0136$	0.0919
55	$+0.0176$	0.0643
65	$+0.0101$	0.0593
75	$+0.0120$	0.0471
반폭 = $2.28 n^{-0.88}$ (이론값 -0.5)		

Table 2: 목표별 필요 표본. 지금 75건, 연 18.8건.

반폭	n	남은 해	무엇을 가르나
0.030	137	3	지금보다 조금 낮다
0.020	217	8	$+0.02$ 짜리
0.010	476	21	$+0.01$ 짜리(대부분)
0.005	1,046	52	노트 72의 문턱

Table 3: 관문 폭포.

	남는 것	여기서 빠지는 것
전체 레코드	376	—
신뢰 등급 A/B	204	172
라벨 유한	193	11
스코프 검증	189	4
계수 방법	75	114
라벨이 있는 것 350건 · 실제로 쓰는 것 75건		
계수 방법: 주최자 주장 247 · 입장 54 · 참여 37		

1. 구간은 이렇게 좁아진다

주장 1. 구간이 $n^{-0.88}$ 로 좁아진다 — $\sqrt{n}$ 보다 빠르다.
 표본이 적을 때는 팝업의 인자 공간 자체가 흔들려 잡음이
 더해지기 때문으로 보인다. 모으는 값이 이론보다 크다는
 뜻이다.

반증 조건. 여섯 점에 직선을 맞췄고 표본 뽑기가 셋뿐
 이다. 그리고 n 을 줄이면 표본이 달라지므로 순수한 크기
 효과가 아니다.

노트 92가 설계 판정에 510건이 필요하다고 썼는데
 여기서 476건이 나온다 — 다른 방법으로 켜 두 수가 맞
 는다.

2. 발굴을 봤다

주최자 주장이 247건이다. 이것만 풀어도 173건이 되고
 구간이 절반으로 준다. 풀어 봤다.

3. 풀었더니 무너졌다


Figure 1: 왼쪽 — 376건에서 75건으로. 가운데 — 주최자 주장은 신호가 없다. 오른쪽 — 반복 = $2.28n^{0.88}$.

Table 4: 계수 방법 관문을 풀면.

	<i>n</i>	팝업 ρ
현행(입장 · 참여)	75	+0.4601
+ 주최자 주장	173	+0.0352
+ 등급 C까지	264	-0.0006
전부	333	+0.0341
주최자 주장만	98	-0.0539
주최자 주장만 · 등급 전부	209	+0.0470

Table 5: 세 가지 길.

길	얻는 것	판정
발굴	라벨 275건	막혔다(신호 없음)
자연 축적	연 18.8건	21년
실측 계수	연 40건?	10년

주장 2. 주최자 주장 방문자 수에는 예측 가능한 신호가 없다. 실측 발자국을 $\rho=+0.46$ 으로 맞히는 축들이 주최자 주장은 -0.05 로 맞힌다. 섞으면 $+0.035$ 로 무너진다.

반증 조건. 주최자 주장 레코드가 다른 종류의 팝업일 수도 있다(작은 행사 · 오래된 것). 축이 아니라 표본이 다른 것일 가능성을 안 갈랐다.

관문은 지나치게 엄격한 것이 아니었다. 그것이 모형을 살려 두는 유일한 것이었다. 그리고 이것은 사업에도 쓰는 말이다 — 주최자가 발표하는 방문자 수로 성과를 건주면 안 된다. 같은 기획 정보로 실측은 맞히는데 주장은 못 맞힌다.

4. 그러면 남은 길은 하나다

Table 6: 무엇을 붙이나. 이미 인정되는 두 계수.

entry	입장 카운터 · 게이트 · 예약 체크인
participation	체험 참여 로그 · POS 영수증 수

주장 3. 앞으로 여는 팝업에 실측 계수를 붙이는 것이 이 프로젝트에서 가장 값싼 지렛대다. 축을 스물세 개 굵어 채택 0이었는데(노트 116 · 117 · 118), 실측 계수 하나를 늘리는 것이 그보다 크다. 연 18.8건이 연 40건이 되면 스물한 해가 열 해가 된다.

반증 조건. “연 40건”은 목표이지 측정이 아니다. 지금 주최자 주장이 연 70건쯤 쌓이므로 그중 절반에 계수기를 붙이면 되는 수치이긴 하다.

5. 한계

- 채택할 것이 없다. 이 노트는 설정을 안 바꾼다.
- 주최자 주장이 신호가 없는 것인지 그 표본이 다른 것인지 안 갈랐다.
- 반복 곡선이 여섯 점이고 표본 뽑기가 셋이다. 21년은 눈금이지 예측이 아니다.
- 연 18.8건은 2023 – 2026의 평균인데 2025년만 40건이라 최근 속도는 더 빠를 수 있다.
- 노트 120의 정직한 눈금으로 도구 문서를 고치는 일은 아직 안 했다.

6. 다음

1. 주최자 주장을 한 번 더 판다 — 신호가 없는 것인지 표본이 다른 것인지. 같은 IP · 같은 자리에서 주장과 실측이 둘 다 있는 짝을 찾으면 바로 갈린다.
2. 도구 문서를 고친다(노트 122가 남긴 것) — state/score.py의 자기 검사와 노트 91의 순위표를 정직한 눈금으로.

3. 계수기 붙이기 지침 — **entry · participation** 으로 인정되는 계수의 최소 요건을 한 장으로 적는다.
4. 남은 다섯 도메인의 정직한 라벨.

참고문헌

- Varoquaux, G. (2018). Cross-validation failure: small sample sizes lead to large error bars. *NeuroImage*, 180, 68 – 77.
- Efron, B., Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Lord, F. M., Novick, M. R. (1968). *Statistical Theories of Mental Test Scores*. Addison-Wesley.
- Halevy, A., Norvig, P., Pereira, F. (2009). The unreasonable effectiveness of data. *IEEE Intelligent Systems*, 24(2), 8 – 12.
- Ben-David, S. et al. (2010). A theory of learning from different domains. *Machine Learning*, 79(1–2), 151 – 175.