

IP 파운데이션 월드모델 연구 노트 125

라벨을 섞자 정렬이 사라졌다

판정치가 방법을 전제하고 있었다 --- 하네스를 방법에서 떼어내자 첫 라운드에서 챔피언이 바뀌었다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

스몰여덟 노트 동안 한 정식화 안에서만 움직였다. 노트 103에서 “구조적 막다른 골목”이라 적어 놓고도 그 안에서 스무 편을 더 돌았다. 이번에 그 기제를 찾았다. 판정치가 방법을 전제한 정의였다. 양상을 판정치는 “출처마다 예측을 받아 순위 평균”이라 적혀 있었고, 그것은 쌍별 정렬 후 전이가 있다고 가정한 문장이다. 그래서 최적수송이든 파운데이션 in-context든 확산 모형이든 점수를 매길 수가 없었다. 대안이 경쟁에 못 들어오면 남는 일은 현행을 손보는 것뿐이다. 그래서 정식화에 요구하는 것을 하나로 줄인 하네스를 짰다 — (도메인, 축, 마스크, 시간)에서 점수 벡터로, 순위만 의미. 여기에 상시 가드 여섯과 챔피언/도전자 루프, 별도 서버의 모니터를 붙였다. 첫 라운드에서 챔피언이 바뀌었다. 정렬을 아예 안 하고 전 도메인을 한 표에 쌓은 뒤 도메인 표시자만 준 F6이 판 $\rho + 0.3413$, 프로크루스테스가 $+0.3400$ — 원점수로는 무승부다. 그런데 가드가 둘을 갈랐다. 출처 라벨을 도메인마다 섞고 99번 다시 적합한 귀무 분포에서 F6은 폭 0.127, F1은 0.178이다. 표준화하면 $+2.84\sigma$ 대 $+2.01\sigma$. 기제도 찾았다 — 치환 라벨에서 F1의 대상별 ρ 가 서로 $+0.418$ 로 같이 움직이는데 (F6은 $+0.166$) $(1 + (m - 1)\bar{c})/m$ 에 넣으면 독립 대비 분산 3.9배이고, 이것으로 예측한 귀무 폭 0.179가 실측 0.178과 맞는다. 정렬은 점수를 사지 않고 자유도를 샀다. 그리고 가드는 나도 잡았다 — 치환 검사를 처음엔 한 번만 섞어 판정했고 “치환해도 $+0.49$ 가 남는다”로 읽었다. 그건 귀무의 평균이 아니라 폭이었다. 팝업 후행 표본이 59건뿐이라 무작위 방향도 $|\rho| 0.5$ 를 예사로 낸다. 대표 수치로 삼던 자리에 분해능이 없었다.

1. 스몰여덟 노트가 제자리를 둔 이유

노트 97부터 124까지, 매 사이클이 “후보 축을 하나 더 붙여 보고 채택 기준을 통과하나 본다”였다. 통과한 것은 노트 108 하나 ($+0.4038 \rightarrow +0.4270$). 나머지는 전부 반증이었고, 반증 자체는 값진 것이었지만 탐색 반경이 한 번도 안 커졌다.

이유가 취향이나 게으름이 아니었다. 판정치의 정의에 있었다.

주장 1. “양상을 판정치”는 방법을 전제한 정의였다. 대상마다 들어오는 출처 예측을 순위 평균한 뒤 스피어만 — 이 문장은 출처가 여럿이고 각각 대상으로 전이된다는 구조를 이미 가정한다. 전이 구조가 없는 정식화(단일 결합 모형, in-context 추론, 동역학 모형)는 “출처별 예측”이라는 항 자체가 없어서 점수를 낼 수 없다.

반증 조건. 정의가 방법을 가둔다는 진단은 사후적이다. 처음부터 그렇게 설계한 것이 아니라 노트 5의 편의가 40 편의 제약이 됐다.

그래서 정식화에 요구하는 것을 하나로 줄였다.

$$(d, A, M, t) \mapsto s \in \mathbb{R}^n, \quad \text{순위만 의미}$$

A는 축 행렬, M은 관측 마스크, t는 시간이다. 이 인터페이스만 지키면 무엇이든 붙는다. 현행 파이프라인도 여기서는 구현 하나다.

Table 1: 모든 실행에 자동으로 붙는 가드. 깨지면 점수는 남되 승격 대상에서 빠진다.

여보기	대상 라벨을 섞어도 예측이 불변해야
치환	출처 라벨을 섞으면 무너져야 (귀무 99회)
분모	대상 집합이 기준과 같아야 (노트 82 · 90)
재현	씨앗 넷의 폭
빈칸	축이 전부 상수인 레코드 비중 (노트 124)
양규약	배포 대 전체의 낙관 편의 (노트 112)

2. 상시 가드 --- 그리고 내가 처음 틀린 방식

노트 87 · 115 · 117 · 124는 전부 내가 낸 수치를 내가 뒤집은 사건이었고, 공통 신호는 “수치가 이상하다”가 아니라 “수치가 너무 깔끔하다”였다. 세 번 다 논문을 내 보낸 뒤에 잡았다. 그래서 검사를 실행 시점으로 옮겼다.

첫 판에서 치환 가드가 F1과 F6을 둘 다 떨어뜨렸다. F1은 라벨을 섞고도 팝업 $\rho + 0.4929$, F6은 $+0.2322$ 였다. “신호의 90%가 라벨에서 오지 않는다”고 읽을 뻔했다.

주장 2. 틀린 것은 결과가 아니라 검사였다. 한 번 섞어 한 값을 보고 판정했는데, 그 값은 귀무의 평균이 아니라 한 표본이다. 99번 섞으니 팝업 귀무는 평균 ≈ 0 , 표준편차 $\pm 0.35(F1) \cdot \pm 0.26(F6)$ 이다. 내가 뽑은 $+0.49$ 는 그 분




Figure 1: 왼쪽 — 판정치의 정의가 방법을 지목하니 대안은 채점 자체가 안 됐다. 오른쪽 — 하네스가 요구하는 것을 하나로 줄이고 가드를 상시화했다.

포의 위쪽 꼬리였다.

반증 조건. $R=99$ 는 p 의 최소 해상도가 0.01이다. 더 촘촘한 판정이 필요하면 R 을 올려야 한다.

3. 대표 수치 자리에 분해능이 없었다

팝업은 제품이 묻는 자리라 대표 수치로 써 왔다. 그런데 배포 규약에서 팝업의 후행 표본은 59건이다.

주장 3. 팝업 단독 ρ 의 절대값은 정식화를 가르지 못한다. 무작위 라벨로 적합한 예측도 $|\rho| 0.5$ 를 예사로 낸다(귀무 폭 $\pm 0.26 \sim 0.35$). 실제 $+0.54$ 는 그 안에서 $1.5 \sim 2.1\sigma$ 자리다.

반증 조건. 과거의 채택 결정이 잡음이었다는 뜻은 아니다. 노트 82 이후의 채택 기준은 절대값이 아니라 같은 표본에 짝지는 차이의 붓스트랩이었고, 짝짓기는 공동 분산을 상쇄해 훨씬 좁다(노트 123의 구간 법칙 $2.28n^{-0.88}$, $n=59$ 에서 0.063). 잘못된 것은 절대값을 순위표의 대표 수치로 쓴 것이다.

그래서 순위 기준을 대상 하나에서 판 전체로 옮겼다. 대상별 ρ 를 채점 표본 수로 가중 평균하면 $n=2,608$ 이고, 여기에 치환 귀무를 세워 표준화한다.

$$z = \frac{\bar{\rho}_{\text{실제}} - E[\bar{\rho}_{\pi}]}{\text{sd}[\bar{\rho}_{\pi}]}$$

4. 첫 라운드 --- 챔피언이 바뀌었다

포트폴리오에 셋을 올렸다. F0 무작위(바다선), F1 프로크루스테스(노트 5-124의 파이프라인), F6 직접 풀링(정렬을 아예 안 하고 전 도메인을 한 표에 쌓은 뒤 도메인 표시자와 관측 표시자만 준다).

주장 4. 정렬 기구는 원점수를 사지 못한다. 겹치는 여덟 대상에서 F6 $+0.3435$, F1 $+0.3399$ 다. 도메인별로 보

Table 2: 배포 규약, $T=2025.0$. 출처는 2025년 이전, 대상은 이후. 팝업은 2025년 이전 표본이 16건뿐이라 어느 쪽도 팝업 과거를 학습하지 않는다 — 순수 교차 도메인 비교다.

	판 ρ	귀무 폭	z	대상
F6 직접 풀링	+0.3413	0.127	+2.84	9
F1 프로크루스테스	+0.3400	0.178	+2.01	8
F0 무작위	+0.0041	—	—	9

면 F6이 게임에서 $+0.171$ 크게 이기고 나머지 일곱에서 $-0.003 \sim -0.047$ 작게 진다.

반증 조건. 한 시간 분할($T=2025.0$) 한 판이다. 분할을 옮기면 순서가 바뀔 수 있다.

주장 5. 그리고 F1은 아이돌을 채점하지 못한다. 완전사레 필터가 25건 중 18건만 남겨 최소 표본 20건을 못 채운다. 분모 가드가 이걸 잡았다 — F1의 대상은 8개, 기준은 9개다.

반증 조건. 분모 불일치는 승격 자격 박탈 사유지 성능 판정이 아니다. 여덟 대상만으로 비교해도 결론은 같다.

5. 정렬이 산 것은 자유도였다

원점수가 같은데 귀무 폭이 1.41배 다르다. 왜인가.

먼저 아닌 것부터. 정렬이 출처들의 오차를 묶었을 것이라 짐작했는데 틀렸다. 실제 라벨에서 아홉 출처의 예측은 서로 $\bar{c} = +0.807$ 로 붙어 있지만, 치환 라벨에서는 -0.001 로 독립이다. 출처들이 붙는 건 공유 신호 때문이지 기구 때문이 아니다. (이 $+0.807$ 은 노트 119-121이 곡선 적합으로 얻은 $\bar{c} \approx 0.82$ 를 전혀 다른 경로로 재확인한다.)

기제는 한 층 위에 있었다.




Figure 2: 왼쪽 — 팝업 하나의 귀무 폭이 $\pm 0.26 \sim 0.35$ 다. 실제값 $+0.54$ 가 귀무의 1.5~2.1 표준편차 밖에 불과하다. 가운데 — 판 전체로 모으면 귀무가 좁아진다. 오른쪽 — 원점수는 무승부인데 표준화하면 갈린다.




Figure 3: 왼쪽 — 도메인별 대결. 오른쪽 — 귀무 폭 차이의 기제.

주장 6. 치환 라벨에서 F1은 대상들을 같이 움직인다. 대상별 귀무 ρ 의 쌍 상관관이 F1 $+0.418$ (96%가 양수), F6 $+0.166$ (69%)이다. 프로크루스테스가 모든 대상을 하나의 정렬된 잠재 공간으로 밀어 넣으니, 무작위 능력 방향 하나가 대상 전체를 같은 쪽으로 기울인다. F6은 도메인 표시자가 그 이동을 흡수한다.

반증 조건. $\bar{c}$ 는 99회 치환에서 켜 것이고 표본 오차가 있다.

이것을 양상블 분산식에 넣으면 판 통계량의 폭이 나온다.

$$\text{Var}(\bar{\rho}) \approx \frac{\sigma^2}{m} [1 + (m-1)\bar{c}]$$

F1은 $m=8$, $\bar{c}=0.418$ 이라 독립 대비 3.9배, F6은 $m=9$, $\bar{c}=0.166$ 이라 2.3배다. 대상별 귀무 폭의 평균(σ : F1 0.256, F6 0.213)을 곱하면 예측 폭이 F1 $0.179 \cdot F6$ 0.108이고, 실측은 F1 0.178 $\cdot$ F6 0.127이다.

주장 7. 정렬은 적합도를 사지 않고 자유도를 샀다. 같은 원점수를 내는데 우연히 그 점수를 별 길이 두 배 가까이

많다. 어떤 간결성 기준으로 보아도 F1은 F6보다 나쁜 모형이다.

반증 조건. F1 예측(0.179 대 0.178)은 거의 정확하지만 F6은 17% 어긋난다 — 판 평균이 표본 수 가중인데 식은 비가중이라 생기는 근사 오차로 본다. 정확한 가중 형태는 아직 안 유도했다.

6. 무엇이 바뀌고 무엇이 그대로인가

바뀐 것은 루프의 크기다. 이제 사이클은 “F1을 개선한다”가 아니라 “도전자를 챔피언에 붙이고, 이기면 승격 지면 은퇴”다. 고정된 것은 목표(IP · 기획 → 소비자 반응)와 하네스뿐이고, 세부 계획은 매 사이클 바뀌어도 된다.

실행은 전부 SQLite에 남고 별도 서버의 모니터가 읽는다 (lab/server.py, 포트 7801, 표준 라이브러리만). 한 라운드가 8초다 — 세 정식화 $\times$ (두 규약 + 가드 여섯 + 붓스트랩 200회).

그대로인 것도 적어 둔다. 표본이 늘지 않았다. 팝업 후행 59건은 그대로고, 귀무 폭 ± 0.26 은 정식화를 바꿔서 줄일 수 있는 양이 아니다. 노트 124가 연 길 — 축이

Table 3: 다음 도전자. 전부 같은 하네스로 채점된다.

F2	결합 위계 잠재 모형 (τ 폴링, 우도 결측)
F3	Gromov-Wasserstein — 정렬 전제 자체를 제거
F4	TabPFN / CARTE — in-context 베이스
F5	확산 — 일자별 곡선 89개에서 M, p, q 세 라벨
F7	anchor regression — 불변 방향만

빈 260건을 매기면 팝업이 75건에서 322건이 된다 — 이 여전히 이 판에서 제일 큰 한 수다. 하네스가 바뀌었으니 그 작업의 값어치는 오히려 더 커졌다. 어느 정식화가 이기든 같은 표본을 나눠 쓴다.