

IP 파운데이션 월드모델 연구 노트 302

섞어도 똑같이 듣는다

하네스에서 유일하게 복제된 층에 위약을 붙였다 --- 신호를 앵커 사이에서 뒤섞어도 이득이 그대로다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 298에서 하네스의 세 층 중 신호 하나만 복제됐다(새 21건에서 $+0.2160$, $t=2.21$). 그런데 그 신호 삼중 중 어느 것도 앵커 자신의 일평균을 못 가른다 — 완판 $\rho=0.085$ ($p=0.23$) · 대기 -0.014 · 예약 0.013 , 카테고리 안에서 중심화한 뒤에도 마찬가지다. 정보가 앵커 성과를 못 가르는데 빼면 예측이 나빠진다면 이득이 신호의 내용이 아니라 모양일 수 있다(노트 133). 위약 팔을 만들었다 — 신호 삼중을 앵커들 사이에서 치환한다. 주변 분포와 프롬프트 모양이 정확히 같고 앵커와의 짝만 깨진다(짝이 그대로인 것 34/229). 시점으로 자른 뒤에 섞는다. 척도 · 문턱 · 실패 조건을 재기 전에 못 박고(`preregister_placebo.json`) 48건에 돌렸다. 결과 — 진짜 대 위약 $t=-0.59$ (미달) · 위약 대 제거 $t=+2.52$ (통과). 내용을 통째로 부수어도 이득이 안 준다. APE 중앙값도 진짜 0.400 · 위약 0.444 · 제거 0.520 으로 앞의 둘이 붙어 있다. 미리 적은 두 가설 중 ‘모양’이 맞았다. 하네스에서 유일하게 살아남은 이득이 어느 앵커가 완판했는지와 무관하다 — बैं크에 수요신호 칸이 있다는 것이 일하지, 그 칸이 누구 것인지는 안 읽힌다.

1. 복제된 층이 아무것도 안 가른다

노트 298이 하네스 짝 셋을 사전 등록해 복제했고 신호 하나만 살았다. 그 층이 무엇인지 봤다 — `market_bank._line` 이 앵커 줄에 붙이는 완판 · 대기 · 예약 셋이다.

앵커 201건	τύ음	ρ (일평균)	p
완판	32%	0.085	0.23
대기	39%	-0.014	0.84
예약	27%	0.013	0.85
카테고리 안에서 중심화한 뒤			
완판		0.065	0.36
대기		-0.031	0.67
예약		-0.031	0.66

아무것도 안 가른다. 대조로, 같은 बैं크에서 카테고리 는 $H=28.8$ ($p=0.0002$)로 다섯 배를 가른다(노트 299).

두 가설을 적었다. 내용 — 신호가 무언가를 말하고 모양 이 그것을 읽는다. 모양 — 이득은 그 칸이 있다는 데서 오고 내용은 안 읽힌다. 예상은 모양 쪽으로 적었다.

그리고 결과 보기 전에 세 번째 경로도 죽였다. 신호가 라벨 신뢰도의 대리일 가능성 — 신호 유무가 등급과 붙 긴 하는데($p=0.024$) 거꾸로다(등급 B 56% · C 76% · E 71%). 잘 켜 앵커를 가리키는 게 아니다.

2. 위약 팔

신호 삼중을 앵커들 사이에서 치환한다(`market_bank.shuffle_signals`, 씨앗 1234).

확인	
주변 분포 같음	True
짝이 그대로인 것	34 / 229 (15%)
두 번 불러 같은가	True

자른 뒤에 섞는다. 전체에서 섞고 시점으로 자르면 팔 마다 남는 신호의 분포가 달라져 모양이 안 맞고, 그러면 위약이 아니다.

3. 내용을 부수어도 이득이 안 준다

사전 등록한 척도 ($\log \frac{\text{비교팔 APE}+0.05}{\text{기준팔 APE}+0.05}$) 와 문턱 ($|t| > z(0.05/4)=2.24$) 으로 읽었다. 48건 중 47건 이 세 팔을 다 가졌다.


비교	효과	짝SE	t	
진짜 대 위약	-0.0763	0.1302	-0.59	미달
위약 대 제거	+0.2843	0.1129	+2.52	통과
진짜 대 제거	+0.2080	0.0902	+2.30	통과

팔	APE 중앙	APE 평균
진짜 (신호 그대로)	0.400	3.142
위약 (섞은 신호)	0.444	3.150
제거 (신호 없음)	0.520	4.145

진짜와 위약이 붙어 있고 제거만 떨어진다. 미리 적은 두 가설 중 ‘모양’이 맞았다.

무엇이 부서졌고 무엇이 남았다. 치환은 어느 앵커가 완 판했는지를 완전히 지운다(짝이 남은 것 15%). 남는 것은 बैं크의 66%에 수요신호 칸이 있다는 사실과 그 칸들의 총량 · 배치다. 그것만 있으면 이득이 다 나온다.

섞어도 똑같이 듣는다

Figure 1: 왼쪽 — 사전 등록한 척도로 겐 세 짝 비교 (± 1.96 짝SE). 오른쪽 — 세 팔의 APE.

4. 그래서 무엇을 배웠다

① 이 이득은 자료의 값어치가 아니다. 노트 298이 “남은 것은 신호 중 하나”로 끝나면서 다음 수를 “어느 신호가 듣나 — 아직 뭉치다”로 적었다. 그 물음이 잘못 놓였다. 셋 중 어느 것도 아니고, 셋을 아무렇게나 섞어도 같다. 신호를 더 잘 모으는 것은 이 이득을 안 키운다.

② 절제 실험이 자료를 재고 있지 않았다. 하네스의 세 팔 (nomkt · nofeat · nosig)은 전부 프롬프트에서 무언가를 지우는 방식이다. 지우면 내용과 모양이 같이 사라진다. 위약 없이는 둘을 못 가른다. 노트 295~298이 겐 것 전부가 이 혼동을 안고 있었을 수 있다 — 시장층과 피쳐에도 같은 위약을 붙여야 한다.

③ 그런데 이득 자체는 진짜다. 위약 대 제거가 $t=2.52$ 로 문턱을 넘는다. 그 칸이 있으면 예측이 나아진다 — APE 중앙 0.520 → 0.444. 왜인지는 이 노트가 답 못 한다. 후보: 줄이 길어져 앵커가 더 오래 붙들린다 · 형식이 촌촌해져 표를 표로 읽는다 · 신호 칸의 유무가 그 앵커의 기록 밀도를 알린다.

남은 것.

갈래	왜
시장층 · 피쳐에 위약	같은 혼동을 안고 있다
빈 칸을 채워 보기	“-”로 자리만 두면?
길이만 늘려 보기	모양의 어느 부분인가
도메인별 빌립	노트 301의 갈래 — 돌고 있다

규약. 지워서 겐 것은 위약으로 다시 재라. 절제는 편하고 싸지만 내용과 모양을 같이 지운다. 치환은 모양을

그대로 두고 내용만 지우므로 둘을 가른다 — 그리고 이 판에서는 모양이 전부였다. 그리고 이득이 복제된다고 해서 그 이득의 원인을 안다는 뜻이 아니다 — 노트 298이 신호 층을 두 번 독립으로 확인했는데, 두 번 다 확인한 것은 “신호 칸을 지우면 나빠진다”이지 “신호가 정보를 나른다”가 아니었다.