

태그는 양쪽으로 거짓말한다

표본 대신 전수를 센 이유

월드모델 실험실 · 노트 667

2026-08-06

1 한 줄

라벨을 켤 수 있나를 재려고 표본 20건을 뽑았는데, 표본이 **내 계산 방법이 틀렸다는 것**을 먼저 잡아 줬다. 고쳐 세니 사전등록의 “표본을 늘려라” 분기였고, 표본을 늘리는 대신 **모집단 92건을 전수 열거**했다 — 드라이브를 열기 전에, 레코드 안의 문서 목록만으로. 결과는 새 라벨 **0건**이고 채굴 경로를 달았다.

2 왜 이걸 했나

노트 663 이 열값(축 하나가 판에서 물어 가는 ρ)이 **학습 행 수에만** 달렸음을 확정했다 — 빈 열은 정확히 0.0000 이다. 노트 665 는 팝업이 판에서 유일하게 **유보(65)가 학습(24)보다 큰** 도메인임을 켜다. 노트 666 은 학습 구간(2024)에 팝업 레코드가 117건 있는데 방문객 값은 25건뿐이라고 켜다.

즉 **92건이 켤 여지**처럼 보였다. 다 캐면 학습 24 → 116 이고 열값이 크게 준다. 그런데 전례가 낮다 — 노트 634 는 192건에서 확실한 라벨 **1건**, 노트 635 는 이미지 PDF 77건에서 **4건**이다. 그래서 전수 채굴 전에 **수확물을 먼저 재기로** 사전등록했다: 고정 씨앗 20건, 문턱 20%/10%, 그 사이면 표본을 40으로 늘린다.

3 표본이 나를 먼저 잡았다

표본 20건에서 `kind == '결과보고서'` 인 문서를 세니 **0/20** 이었다. 그 숫자가 너무 깨끗해서 문서 목록을 직접 열어 봤다. 그랬더니

```
{'doc_id': '...', 'kind': '운영일지', 'title': '(sweetspot)포켓몬고_결과보고서.pptx'}
```

결과보고서 파일의 태그가 ‘운영일지’였다. 태그로 거르면 하나도 못 찾는다. 고쳐 세면 20건 중 **3건**이고, 그것은 사전등록 분기 ③(2~4건이면 표본을 40으로 늘린다)이다.

주장. 메타데이터 오류는 **양방향**이다. 노트 635 는 결과보고서로 태그된 파일 77건 중 **56건(73%)이 요건정의서임**을 켜다 — 있다고 하는데 없다. 노트 667 은 반대다 — 제목이 결과보고서인 실제 파일 43건의 `kind` 가 전부 운영일지다. 없다고 하는데 있다. 그래서 태그는 **근거로도 못 쓰고 거르는 데도 못 쓴다.**

반증 조건. 같은 저장소에서 `kind` 가 제목과 일치하는 비율이 높게 측정되면 이 주장은 과장이다. 다만 이번 43건은 100% 불일치라 표본 오차로 설명되지 않는다.

4 표본을 늘리는 대신 전수를 켜다

사전등록은 “표본을 40으로 늘린다”였다. 그런데 걸림돌이 사라졌다 — 태그가 아니라 **제목 문자열**로 세면 그 계산은 레코드 파일 안에서 끝난다. 드라이브를 한 번도 안 열고 92건 전수를 켤 수 있다. 40건 표본보다 강하고 비용은 더 싸다.

92건의 문서 5,020건을 종류로 가르면 계약서 461 · 정산 279 · 기획서 229 · 기타 106 · 운영일지 72 다. 그 운영일지 72 건 중 **29건이 결과보고서_내용없음.txt** (0바이트 플레이스홀더)이고 실제 파일은 43건, 레코드로는 **24/92 (26%)** 다.

jpeg 14장은 연락처로 붙여 전부 봤다. **모두 현장 사진**이었다 — 부스 조명, 크로스워크 바닥 시트, 굿즈 배치. 파일 이름이 그것을 그대로 말한다: RTPU2446_..._결과보고서_사진대체.jpeg.

같은 메타데이터가 양쪽으로 거짓말한다




Figure 1: 같은 메타데이터가 양쪽으로 틀린다. 왼쪽(노트 635)은 위양성 73%, 오른쪽(노트 667)은 위음성 100%. 위양성만 겪으면 “열어서 확인하라”로 끝나지만 위음성은 **열 후보 자체를 지운다** — 더 조용하고 더 나쁘다.




Figure 2: 24건의 43개 문서를 전부 읽었다(읽기 전용). 텍스트 200자 초과 9 · 이미지 PDF(23~152자) 8 · jpeg 사진 14장 · 404 삭제 8 · 0바이트 txt 1 · 비용 xlsx 1. 숫자가 읽힌 것은 한 건(RXPU2417)이고 그것도 참가자 746 + 483 · 설문 응답자 818 로 **하한값**이다.

5 판정 — 사전등록 분기 ②

새 라벨은 **0건**이다. 이미 노트 634·635 가 비전으로 캔 2건(RXPU2407 23,823 · RTPU2452 18,600)이 이 24건 안에 있으므로 92건의 총 수확은 **2건 = 2.2%** 다. 사전등록 문턱 10% 미만 → **분기 ②: KOPIS 를 기다리는 것이 옳다**. 채굴로 늘 수 있는 학습 행은 24 → 26 이고 열값은 거의 안 준다.

주장. 병목은 채굴 노력이 아니라 **조직이 방문객을 안 센다**는 것이다. 노트 634·635 가 이미 그렇게 진단했고, 이번 전수가 **판의 학습 구간**에 대해서도 같은 것을 확정했다. 92건 중 **68건(74%)은 캔 문서가 아예 없다**.

반증 조건. 학습 구간에 결과보고서가 있는데 안 열어 본 레코드가 남아 있으면 이 주장은 성립하지 않는다. 24건 전수를 열었으므로 남은 것은 이미지 PDF 8건뿐이고, 노트 635 의 수확률 5.2% 를 적용하면 기대 0.4건이라 문턱을 못 바꾼다.

이것은 노트 666 의 **부분 정정**이다. 노트 666 은 92건을 “안 캔 것”으로 읽었다. 정확히는 74%가 캔 것이 없고 26%만 캔 수 있었고 그중 2건이 나왔다. 사전등록의 반증 조건 ③(“문서가 아예 없는 것이 15건 이상이면 정정한다”)이 발동했다.

6 예측이 맞아서 아낀 것

사전등록에 적은 예측은 분기 ②였고 맞았다. 그런데 값은 예측이 아니라 **순서**에 있었다. 노트 634 는 192건을 다 열고 나서 “없다”를 알았다. 이번에는 레코드 안의 문서 목록으로 92 → 24 로 줄인 뒤 24건만 열었다 — 드라이브 요청 43건이다.

주장. 레코드에 문서 목록이 있으면 드라이브를 열기 전에 거를 수 있다. 비싼 원천을 훑을 때 첫 질문은 “무엇을 열까”가 아니라 “무엇을 안 열어도 되나”다.

반증 조건. 문서 목록이 실제 저장소와 어긋나면(삭제·이동) 이 방법이 과소 계수를 낸다. 실제로 이번에 404 가 8건 나왔다 — 목록에는 있고 파일은 없다. 그러므로 이 방법은 상한을 주고, 상한이 문턱 아래일 때만 결론을 낸다. 여기서는 $24 < \text{문턱}$ 이라 방향이 안전한 쪽이다.

7 남긴 것

- 승인 대기에 RXP2417 **하한 818** 을 올렸다. 하한값은 라벨로 쓰면 편의가 생기므로 노트 635 의 선례대로 **사람이 정한다**. 레코드에는 쓰지 않았다.
- 이미지 PDF 8건은 비전으로 안 읽었다. 기대 0.4건이라 판정을 못 바꾼다. 다만 **0 이라고 단정하지 않는다** — 태그 오류율을 다시 짤 때 같이 넣는다.
- 코드에 물린 것 둘: 감사의 메타 신뢰 항목에 **양방향** 오류를 적었고, `DriveText.meta()` 를 더해 `supportsAllDrives=true` 를 빼먹지 못하게 했다. 그것이 없어 43개 문서가 전부 404 로 왔고 파일이 없는 것처럼 보였다 — 이 논문의 주제가 코드에서 한 번 더 반복된 셈이다.