

검증은 자기가 본 세계까지만 말한다

노트 126은 시간이었고 이번은 종류다 --- 태거가 배운 레코드 안에서는 맞고 다른 종류 앞에서 무너진다

Sweetspot 월드모델 연구

2026년 7월 29일

초 록

노트 126의 F8은 “병목은 축”이라 했고 F11은 “한 도메인에만 있는 축은 도움이 안 된다”고 했다. 남은 처방은 하나 — 전 도메인이 공유하는 축의 빈칸을 메운다. 노트 124가 그 빈칸을 세어 놓았고(팝업 380건 중 축이 매겨진 것 95건) “매기면 75건이 322건이 된다”고 적었다. 그래서 태거를 만들었다. 먼저 노트 124의 산수를 고친다. 빈 260건은 거의 전부 organizer_claim(247)과 media_estimate(13)이고, 그 둘은 계수 방법 필터가 이미 걸려 내고 있다. 축만 매겨서 들어오는 것은 17건이다. 322이라는 숫자는 태깅이 아니라 계수 필터를 푸는 것을 전제한 값이었고, 그건 다른 질문이다. 태거는 만들었고 작동한다. 기획서 글에서 열 축을 되찾는데, 교차검증($n=95$, 5점 $\times$ 12회) ρ 가 체험 밀도 +0.58 · 포토존 +0.54 · 굿즈 규모 +0.52부터 타깃 폭 +0.09까지 갈린다. 라벨은 한 번도 안 본다(코드로 강제). 그런데 다른 종류의 레코드에 대면 무너진다. 학습은 내부 레코드(계약서에서 뽑은 것)로 했고 적용 대상은 시장 레코드(기사에서 뽑은 것)다. 축을 비워 둔 채로는 팝업 ρ +0.4562인데 자동 태깅을 채우면 +0.1150으로 무너진다. 같은 종류 안에서만 재는 교차검증은 이걸 못 잡는다. 노트 126과 같은 모양이다 — 거기서는 검증 창 뒤에 오는 변화를 못 봤고 여기서는 검증 모집단 밖의 글을 못 본다. 마지막으로 표본을 넓은 값을 분해했다. 분모를 59건에 고정하면 +0.3688이 +0.4495로 오르는데, 그 값은 레코드가 늘어서가 아니라 팝업이 학습 풀에 들어가서 생긴 것이다 — 팝업을 학습에서 빼면 오히려 +0.3244로 내린다.




Figure 1: 축마다 글에서 되찾히는 정도가 다르다. 막대는 12회 반복의 평균, 수염은 90% 구간. ●은 전 도메인 공통 축 다섯.

1. 먼저 노트 124의 산수를 고친다

노트 124는 팝업 축이 빈 260건을 세고 “매기면 75건이 322건”이라 적었다. 저장소를 열어 계수 방법별로 갈라 보니 조건이 하나 빠져 있었다.

Table 1: 빈 축은 계수 방법과 거의 완전히 겹친다.

계수 방법	전체	축 매김	축 빈
entry	54	45	9
participation	37	29	8
unknown	20	17	3
exposure	5	4	1
organizer_claim	247	0	247
media_estimate	13	0	13

주장 1. 현행 파이프라인은 계수 방법이 entry · participation인 것만 쓴다. 그 안에서 축이 빈 것은 17건뿐이다. 260건 대부분은 태깅 이전에 계수 필터에서 이미 빠져 있다. 노트 124의 322은 “축을 매기고 또 계수 필터를 푼다”를 전제한 값이었고, 그건 태깅이 아니라 라벨 품질 문제다.

반증 조건. 노트 124가 틀린 것은 결론이 아니라 산수다. “축이 260건 비어 있다”는 여전히 맞다.

2. 태거는 만들었고, 작동한다

기획서 쪽 글만 읽는다 — 콘셉트 · 브랜드명 · 체험 요소 · 프로모션 · 연출 태그 · 장소 · 문서 제목과 종류. 다 국어 문장 임베딩을 24차원으로 줄이고 세는 것들(체험 요소 개수, 평수, 운영일수, 장소 등급 등)을 붙여 축마다

Table 2: 계수 필터를 푼 189건에서, 채점 대상은 후행 116건.

	측 관측률	팝업 ρ
측 비율 (마스크 0)	0.43	+0.4562
자동 태깅으로 채움	1.00	+0.1150
믿는 측만 ($\rho > .3$)	0.54	+0.4551

능형으로 맞춘다.

주장 2. 태거는 라벨을 한 번도 보지 않는다. 레코드에서 “outcome” 키를 아예 지우고 넘긴다(PLAN_ONLY). 노트 87과 117이 라벨 누수로 두 번 뒤집힌 뒤로는 규약을 코드로 강제한다.

반증 조건. 누수의 다른 경로 — 예컨대 문서 제목에 실적이 적힌 경우 — 는 따로 안 봤다.

되찾히는 정도가 측마다 크게 다르다. 체험 밀도 +0.58 · 포토존 +0.54 · 굿즈 규모 +0.52 · 계절 적합 +0.42는 쓸 만하고, 장소 위상 +0.17 · IP 인지도 +0.17 · 타깃 폭 +0.09는 사실상 못 맞힌다. 반복 표준편차가 0.015~0.086이니 이 순서 자체는 믿을 만하다.

3. 그리고 다른 종류의 레코드 앞에서 무너진다

빈 측이 있는 레코드는 거의 전부 시장 레코드(MKT—)다. 기사에서 뽑은 것이고, 태거가 배운 내부 레코드(계약서에서 뽑은 것)와 글의 결이 다르다. 그리고 시장 레코드 쪽에는 사람이 매긴 측이 하나도 없어서 거기서 직접 짤 방법이 없다. 그래서 하네스로 간접으로 잴다 — 측을 채운 판과 마스크로 비운 판을 나란히 붙인다.

주장 3. 자동 태깅이 점수를 무너뜨린다. 측을 비워 두면 +0.4562인데 채우면 +0.1150이다. 그런데 원래 있던 59건 위에서만 재면 +0.3917로 멀쩡하다. 무너지는 것은 새로 들어온 시장 레코드 쪽이다. 태거는 배운 종류 안에서만 맞는다.

반증 조건. 시장 레코드에 참값이 없으니 “태거가 틀렸다”를 직접 확인한 것은 아니다. 하네스를 통한 간접 증거다.

주장 4. 교차검증은 이것을 못 잡는다. $n=95$ 내부 레코드 안에서 12회 반복해도 나오는 것은 “내부 레코드에서 ρ 0.35” 뿐이다. 다른 모집단에서 얼마나 맞는지는 그 절차가 대답할 수 있는 질문이 아니다.

반증 조건. 믿는 측만 채우면($\rho > .3$) +0.4551로 비율과 같아진다. 즉 잘 되찾히는 측은 해가 되지도 않지만 도움도 안 된다.

4. 노트 126과 같은 모양이다

두 번 다 검증 절차가 잘못된 게 아니라 대답할 수 있는 질문의 범위가 좁았다. 그리고 두 번 다 그 범위를 넘는 일반화가 필요했다. 노트 126은 문턱을 표류량에서 끌어와 대응했고, 여기서는 대응할 방법이 아직 없다 — 시

Table 3: 검증이 보지 못하는 두 방향.

	검증이 본 것	못 본 것
노트 126	학습 기간 안	그 뒤의 체제 변화
노트 127	학습 모집단 안	그 밖의 글의 결

Table 4: 전부 같은 59건 위에서. 팝업의 2025년 이전 레코드가 40건 문턱을 넘으면 팝업 자신이 학습 풀에 들어간다.

	팝업 학습?	ρ
현행 (이전 16건)	아니오	+0.3688
현행 · 문턱을 15로	예	+0.3814
+주장 (이전 73건)	예	+0.4495
+주장 · 팝업을 학습에서 뺌	아니오	+0.3244

장 레코드에 참값이 없으면 태거의 전이 오차는 켈 수가 없다.

주장 5. 그러므로 다음 수는 태거를 고치는 것이 아니라 참값을 만드는 것이다. 시장 레코드 스무 건쯤에 사람이 측을 매기면 태거의 전이 오차를 처음으로 켈 수 있다. 그 전에는 태그를 쓰지 않는다.

반증 조건. 스무 건이면 측당 ρ 의 표준오차가 0.22쯤이라 거친 판정만 된다. 정밀한 보정에는 더 필요하다.

5. 늘어난 값은 어디서 왔다

계수 필터를 풀면 팝업 ρ 가 오른다. 그런데 대상 집합이 59건에서 116건으로 같이 바뀌므로 그대로 비교하면 안 된다(노트 82 · 90의 분모 규칙). 분모를 원래 59건에 고정하고 다시 잴다.

주장 6. 늘어난 값은 레코드가 늘어서가 아니라 팝업이 학습에 들어가서 생긴 것이다. 팝업을 학습에서 빼면 주장 레코드를 더해도 +0.3244로 내린다. 주장 레코드의 값어치는 “출처가 하나 늘었다”가 아니라 “팝업 자신의 이력이 문턱을 넘었다”에 있다.

반증 조건. 노트 126의 법칙이 여기에도 걸린다 — 팝업 고유 구조는 팝업의 표류에 노출된다. 팝업 이력이 짧아 안쪽 분할로 그걸 확인할 수가 없다.

6. 남긴 것 --- 묶음 가드

이 조사에서 한 번 속았다. 측이 하나도 관측 안 된 레코드는 모형이 구별을 못 해 전부 같은 점수를 받는데, 스피어만은 그런 묶음이 있어도 숫자를 내놓는다. 측 없는 51건을 더했더니 점수가 “올랐고”, 묶음만 떼어 재면 정의가 안 된다($\rho=\text{nan}$).

주장 7. 그래서 묶음 가드를 상시화했다. 한 값에 뭉친 예측이 15%를 넘으면 실패로 적는다. 위 판에서는 51/116 = 44%가 걸린다.

반증 조건. 이 판에서는 묶음을 빼고 다시 재도 +0.4461로 거의 같았다 — 즉 결론은 안 바뀌었다. 가드는 결론을




Figure 2: 왼쪽 — 같은 59건 위에서만 비교하면 늘어난 값의 출처가 같린다. 오른쪽 — 태거를 다른 종류의 레코드에 대면 무너진다.

바뀌서가 아니라 바뀔 수 있었기 때문에 건다.