

# 문을 세어 닫고, 썰 수 있는 것을 찾아 연다

월드모델 실험실 · 노트 679 · 680

2026-08-06

## 1 한 줄

일곱 트랙 중 셋이 “사람이 KOPIS 를 신청해야 한다”에 묶여 있었다. 그것이 정말 유일한 길인지 한 번도 안 켜므로 문 넷을 다 두드려 닫았다. 그리고 그 확정이 새 문제를 만든다 — T1 이 무한정 대기하게 된다. 그래서 T1 에서 행이 안 늘어도 썰 수 있는 것을 찾아 썰다: 판의 신호가 텍스트에 있다. 답은 챔피언의 51%다.

## 2 왜 이 둘이 한 논문인가

이 실험실이 반복해서 얻은 값이 “닫은 것을 닫았다고 적는 것”이다(노트 667 이 팝업 채굴을, 674 가 방문자 측 확장을 그렇게 닫았다). 그런데 닫기만 하면 트랙이 말라 죽는다. 닫는 행위와 여는 행위는 같은 사이클에 있어야 한다 — 이 논문의 방법이 그것이다.

## 3 닫기 — 문 넷과 대조 하나

**주장.** 공연별 관객수 라벨은 **사람 승인 없이 얻을 수 없다**. 라벨 있는 행을 0건 얻었다. 놀려야 하는 것은 정확히 하나 — `kopis.or.kr` 오픈API 활용신청이다. **`data.go.kr` 키는 재발급이 필요 없다**(같은 계정에서 서비스만 추가 신청하면 지금 키가 쓰인다).

**반증 조건.** KOPIS 가 무인증 엔드포인트를 새로 열거나, 제3자가 공연별 관객수를 재배포하면 이 주장이 무너진다. 지금 확인한 문은 넷이고 그 넷이 전부라고는 주장하지 않는다.

## 대조가 없었으면 반대로 적었을 것이다

세 번째 문(`NO_OPENAPI_SERVICE`)을 처음 보고 “서비스가 폐기됐다”로 읽었다. 그런데 대조를 안 세웠다. 그래서 `ingest/visitors` 의 되는 것으로 확인된 경로를 같은 키 · 같은 헤더로 불렀다.

HTTP 200 · 종로구 현지인 98,007명 · `totalCount` 792

키는 멀쩡하다. 그러므로 세 번째 문의 뜻은 “**`data.go.kr` 은 서비스별로 승인된다**”이고 우리는 관광(B551011)만 신청했다는 것이다.

**주장.** 실패를 해석하기 전에 성공하는 호출을 하나 세운다. 대조가 없으면 같은 응답이 “키가 죽었다”와 “이 서비스만 안 된다”를 구분하지 못한다 — 그리고 두 읽기의 처방이 정반대다(키 재발급 대 서비스 추가 신청).


**반증 조건.** 되는 경로가 하나도 없는 원천에서는 이 방법이 안 쓰인다. 그때는 응답 코드의 의미를 문서로 확인해야 하고, 문서는 이 실험실이 두 번 틀렸던 근거다(노트 637 · 639).

## 4 열기 — 행이 안 늘어도 썰 수 있는 것

T1\_모델의 물음은 “어떤 모델을 쓰나 — 파인튜닝하나, 안 하나”이고 상태가 두 해 동안 막힘이었다. 사유는 “T4 가 행을 늘리기 전까지 대기”. 그런데 방금 T4 를 사람 승인으로 확정했으므로 그 대기가 무한정이 된다.

문 넷을 두드리고 대조를 세웠다  
키는 멀쩡하다 — data.go.kr 은 서비스별 승인

|                   |                                  |
|-------------------|----------------------------------|
| KOPIS 자체 API      | SERVICE KEY IS NOT REGISTERED    |
| 문화포털 api.kcisa.kr | HTTP 403<br>API Key is not valid |
| 포털 B553457        | NO_OPENAPI_SERVICE               |
| KOPIS 공개 웹        | 열린다 —<br>집중값만                    |
| 대조: B551011 방문자   | HTTP 200<br>종로구 98,007명          |



**Figure 1:** 왼쪽: KOPIS 자체 API 는 자체 서비스를 요구하고, 문화포털은 403, 공공데이터포털 B553457 은 NO\_OPENAPI\_SERVICE, KOPIS 공개 웹은 열리지만 시장 전체 집계만 있다(2026 상반기 공연 10,658건 · 티켓 1,141만 매 · 8,095억원). 오른쪽: 텍스트 단독 성적.

그래서 물음을 바꿨다. 언어모델을 파인튜닝한다는 것은 텍스트를 기질로 쓴다는 뜻이다. 그러면 행이 안 늘어도 물을 수 있는 것이 있다 — 우리 판의 신호가 텍스트에 있나, 표 형식 속에 있나.

제목 문자열을 문자  $n$ -gram TF-IDF(2~4자)로 벡터화하고 능형회귀로 라벨 순위를 예측했다. 학습 구간에서만 적합하고 유보에서 채점했고(노트 568), 도메인 안에서만 했다(제목 길이 · 언어가 도메인 지시자가 되는 것을 막는다).

|                         | 텍스트만 $\rho$   |
|-------------------------|---------------|
| 애니                      | <b>0.4910</b> |
| 모바일                     | 0.2928        |
| 펀딩                      | 0.2469        |
| 세계애니                    | 0.1927        |
| 웹툰 · 게임                 | 0.097         |
| 만화                      | 0.0590        |
| 판(유보 가중 · 7 도메인 2,962행) | <b>0.2399</b> |
| 챔피언(11 도메인 3,369행)      | 0.4689        |

사전등록 규칙 ②(0.10~0.30)가 발동한다 — 하이브리드만 후보이고 파인튜닝은 아니다. 예측이 맞았다.

## 누출 검사를 실제로 했다

사전등록에 “판정이 양성이면 상위  $n$ -gram 을 눈으로 보고 사후 정보인지 확인한다”를 적었고, 했다. 애니의 최상위가 '1기' 이고 음수 쪽이 '2' '5' 다 — 모형이 시즌 번호를 배웠다.

시간 게이트 위반은 아니다(1기/2기는 방영 전에 정해진다). 그런데 2기가 있다는 것은 1기가 성공했다는 뜻이므로 이것은 엔티티 이력의 대용물이고, 챔피언에는 이미 ip\_history.prior\_count 가 있다.

**주장.** 텍스트 신호의 상당 부분이 기존 추과 검칠 수 있다. 그러므로 T1 의 진짜 물음은 “텍스트가 얼마나 맞이나”가 아니라 “텍스트가 챔피언 추 위에 무엇을 더하나”다. 노트 675 가 관문 ③ 을 용량 함수로 세웠으므로 (겹침 ↔ 신호 몫 스피어만 -1.000) 그 증분을 재기 전에 예측을 적을 수 있다.

**반증 조건.** 겹침을 재 보니 낮으면 이 주장이 약해지고 텍스트는 새 정보다. 그것이 다음 실험이다.

## 5 정직한 한계

- TF-IDF 는 언어모델보다 훨씬 약하다. 그러므로 0.2399 는 하한 이고, 규칙 ③(0.10 미만)이 나왔더라도 “언어모델도 못 한다”로는 못 읽는다 — 그것을 사전등록에 미리 적었다.

- **팝업 계열이 빠졌다**(제목 원천이 없어 판의 88%만 덮었다). 이 논문을 쓰는 사이에 세 원천을 찾아 붙였다 — 팝업 `intervention.brand_name` · 시장팝업 `event_name` · 아이돌 `group_name`, 덮음  $0.907 \cdot 1.000 \cdot 1.000$ . **다시** 재면 숫자가 바뀌고, 7 도메인 판과 11 도메인 판을 견주지 않는다.
- 문 넷이 전부라고는 주장하지 않는다.