

IP 파운데이션 월드모델 연구 노트 133

기준선을 바꾸면 부호가 바뀐다

팝업 표본을 넓히는 것이 이득인지 손해인지 --- 한 시간 안에 두 번 뒤집혔고, 뒤집은 것은 자료가 아니라
무엇과 견졌느냐였다

Sweetspot 월드모델 연구

2026년 7월 30일

초 록

노트 132가 팝업의 병목을 2025년 이전 레코드 16건으로 확정했다. 노트 127에 그 벽을 넘는 측정이 이미 있었다 — 계수 방법 필터를 풀어 organizer_claim 까지 넣으면 이전 이력이 16건에서 73건이 되고, 분모를 고정해도 팝업 ρ 가 +0.3688에서 +0.4495로 오른다. 채택하지 않고 넘어갔던 것을 이번에 하네스에 정식으로 붙였다. 그런데 처음 낸 값은 손해였다 — 넓은 판이 +0.4995에서 +0.4130으로 내렸다. 원인이 셋 있었고 셋 다 내 쪽이었다. ① 넓은 팝업에 검색·달력 값을 안 붙이고 중립으로 채워서 넓은 판이 정보가 더 적었다. ② 분모를 (라벨, 시간)으로 맞췄는데 두 경로가 시간을 다르게 계산해 0건이 맞았다. ③ 라벨을 float32로 캐스팅하는 경로가 있어 정확 비교가 1건만 맞았다. 셋을 고치고 같은 코드 경로로 견주니 부호가 뒤집혔다 — 부스팅 +0.3690 → +0.4202, 짝 순위 +0.3698 → +0.4300, 직접 폴링 +0.3698 → +0.4173. 확장은 이득이다 (+0.048~+0.060, 셋 다). 그런데 이득의 출처를 갈라 보니 채택할 것은 확장이 아니었다 — 주장 라벨은 ρ 0.02~0.07로 예측이 안 되고, 짝 순위 우도는 학습 문턱을 40에서 15로 낮춰 검증된 16건만 넣어도 같은 +0.4300을 얻는다. 그리고 그 길에 뜻밖의 것을 봤다. 노트 124가 “사람이 안 매긴 것”이라 판정한 팝업 8건의 마스크를 내리면 팝업 ρ 가 +0.4995에서 +0.3698로 내린다. 값은 어차피 중립이라 바뀌는 것은 관측 표시자뿐인데, “모른다”고 표시하는 것이 “중립이라고 관측했다”고 두는 것보다 나쁘다.

Table 1: 노트 127의 분해 — 분모를 원래 59건에 고정.

	ρ	팝업이 학습에?
현행	+0.3688	아니오
현행 · 문턱 15	+0.3814	예
+ 주장 (이전 73건)	+0.4495	예
+ 주장 · 팝업 뺀	+0.3244	아니오

1. 이미 낸 것을 안 쓰고 있었다

노트 127이 팝업 표본을 넓히는 세 갈래를 재고 분해까지 해 놓았다.

이득이 “레코드가 늘어서”가 아니라 “팝업이 학습 풀에 들어가서”라는 것도 그때 확인했다. 그런데 채택하지 않고 노트 128의 검색 축으로 넘어갔다. 노트 132가 병목을 다시 그 16건으로 짚고 나서야 돌아왔다.

2. 처음 낸 값은 손해였다

하네스에 자료 갈래로 붙이고(--axes wide_trendcal) 켜더니 팝업이 +0.4995에서 +0.4130으로 내렸다. 노트 127과 정반대다.

원인이 셋이었고 셋 다 내 쪽이었다.

주장 1. ① 넓은 판이 정보가 더 적었다. 부가 축(검색·달력)을 좁은 팝업 기준으로 만들어 놓고, 넓은 팝업 행에는

중립 0.5 · 표시자 0으로 채웠다. 검색 관측률이 0.89에서 0.00이 됐다. 축 생성기가 넓은 id 목록을 쓰도록 고쳤다.

반증 조건. harness.load 가 행 수가 안 맞는 축을 조용히 중립으로 채우는 설계라 눈에 안 띄었다. 조용히 채우는 대신 경고를 내는 편이 나았을 것이다.

주장 2. ② 분모가 0건 맞았다. 두 경로가 시간을 다르게 계산한다 — 하나는 연도 정수, 하나는 소수 연도다. (라벨, 시간) 쌍으로 맞추니 59건 중 0건이 맞았다.

반증 조건. 라벨만으로 맞추도록 바꿨다. 같은 라벨이 둘 이상이면 순서대로 소진한다.

주장 3. ③ 라벨이 float32와 float64로 갈려 있었다. load_popup 이 y.astype(np.float32) 로 캐스팅한다. 1e-9 허용오차로 맞추니 59건 중 1건만 맞았다. 소수 다섯 자리로 반올림해 해결했다.

반증 조건. 그 전에 “audit 이 라벨을 변환한다”고 잘못 읽고 변환식을 찾느라 시간을 썼다. 변환이 아니라 정밀도였다.

3. 고치고 나니 부호가 뒤집혔다

주장 4. 확장은 이득이다. 정식화 셋 모두




Figure 1: 왼쪽 — 같은 코드 경로로 견주면 확장이 셋 다 돕는다. 오른쪽 — 어느 좁은 판과 견주느냐로 같은 확장이 -0.070 이 되기도 $+0.060$ 이 되기도 한다.

Table 2: 같은 코드 경로 · 같은 59건 위에서, 판 ρ 는 참고.

	좁은 판	넓은 판	차
F8 부스팅	+0.3690	+0.4202	+0.0512
F9 짝 순위	+0.3698	+0.4300	+0.0601
F6 직접 풀링	+0.3698	+0.4173	+0.0475

Table 3: F9 팝업 ρ , 전부 같은 59건.

audit 좁은 판 (빈 축 마스크 꺼짐)	+0.4995
같은 경로 좁은 판 (빈 축 마스크 꺼짐)	+0.3698
넓은 판	+0.4300

$+0.048 \sim +0.060$. 노트 127이 맞았고, 처음의 “손해”는 비교가 틀린 것이었다.

반증 조건. 판 ρ 는 거의 안 움직인다(F8 $+0.4318 \rightarrow +0.4217$, F9 $+0.3546 \rightarrow +0.3527$) — 팝업은 아홉 대상 중 하나이고 넓은 팝업의 채점 집합 116건 자체가 더 어렵기 때문이다. 이득은 제품 지표에 있지 판에는 없다.

4. 그런데 기준선이 답을 바꾼다

같은 확장인데 무엇과 견주느냐로 부호가 갈린다.

넓은 판을 첫 줄과 견주면 -0.070 , 둘째 줄과 견주면 $+0.060$ 이다. 자료도 모형도 그대로인데 결론이 반대가 된다.

두 좁은 판의 차이는 하나뿐이다. 노트 124가 “열 축이 전부 상수 2.0이라 사람이 안 매긴 것”이라 판정한 팝업 8건을, 하나는 관측으로 두고 하나는 마스크를 내린다. 축 값은 어차피 중립(0.5)이라 같고, 바뀌는 것은 관측 표시자뿐이다.

주장 5. “모른다”고 표시하는 것이 “중립이라고 관측했다”고 두는 것보다 나쁘다. 마스크를 내리면 팝업 ρ 가 $+0.4995$ 에서 $+0.3698$ 로 0.13 내린다. 표시자를 켜 두면 그 열이 상수라 아무 정보도 안 주는데, 내리면 열이 변화

면서 모형이 거기서 무언가를 배우고 그것이 지평 너머에서 해가 된다.

반증 조건. 여덟 건의 사례다. 그리고 노트 124의 판정 (“안 매겼다”)이 틀렸다는 뜻은 아니다 — 그 판정은 맞고, 그 사실을 모형에 알리는 것이 손해라는 것이다.

이것이 이번 노트에서 제일 불편한 결과다. 정직하게 결측을 표시하는 쪽이 점수가 낮다. 다만 그 낮음이 “정직해서 손해”인지 “여덟 건에서 우연히” 인지는 이 표본으로 안 갈린다.

5. 그리고 가드가 걸렸다 --- 걸린 것은 가드였다

넓은 판을 정식 라운드에 올리자 옛보기 가드가 실패했다. 대상 라벨을 섞으면 예측이 안 변해야 하는데 최대 1.14 움직였다.

주장 6. 가드가 틀렸다. 옛보기는 대상 라벨을 통째로 섞었다. 그러면 이력이 충분해서 학습 풀에 정당하게 들어간 도메인은 무조건 실패한다 — 그 도메인의 T 이전 라벨은 써도 되는 것이다. 팝업 이력을 16건에서 73건으로 넓히자마자 걸렸고, 걸린 쪽이 자료가 아니라 가드였다. T 이후만 섞도록 고치니 넷 다 통과한다.

반증 조건. 이 버그는 팝업이 한 번도 학습 풀에 못 들어갔던 덕에 스물여덟 노트 동안 잠들어 있었다. 가드는 걸릴 일이 생겨야 검정된다.

6. 주장 라벨은 예측이 안 된다

넓은 판의 후행 116건을 계수 방법으로 갈라 채점했다. 노트 124가 미검정으로 남긴 라벨 품질의 첫 직접 측정이다.

주장 7. organizer_claim 라벨은 예측이 안 된다 — ρ $0.02 \sim 0.07$ 이다. 같은 모형이 검증 계수는 $+0.42$ 로 맞는데 주장은 못 맞힌다.

Table 4: 같은 모형, 같은 예측. 후행 116건을 계수 방법으로 가른 것뿐.

	검증 계수 (59)	주장 · 추정 (57)
F8 부스팅	+0.4202	+0.0715
F9 짝 순위	+0.4300	+0.0297
F6 직접 폴링	+0.4173	+0.0199

Table 5: 전부 같은 59건 위에서.

	F8 부스팅	F9 짝 순위
좁은 · 문턱 40 (팝업 학습 밖)	+0.3690	+0.3698
좁은 · 문턱 15 (검증 16건만)	+0.3307	+0.4300
넓은 · 문턱 40 (주장까지 73건)	+0.4202	+0.4300

반증 조건. “라벨이 나쁘다”와 “그 팝업들이 원래 어렵다”를 이 자료로는 못 가른다. 다만 추과 달력은 두 무리가 같은 방식으로 붙어 있다.

7. 그러면 확장의 이득은 어디서 왔나

주장 라벨이 예측 불가라면, 그것으로 학습해서 검증 계수가 좋아질 이유가 없다. 그래서 이득의 출처를 갈랐다 — 학습 문턱을 40에서 15로 낮추면 주장 레코드 없이도 팝업의 검증된 16건이 학습 풀에 들어간다.

주장 8. 짝 순위 우도는 검증된 16건만으로 이득 전부를 얻는다. +0.4300으로 넓은 판과 똑같다. 주장 레코드 114건이 더하는 것이 없다.

반증 조건. 부스팅은 다르다 — 문턱만 낮추면 오히려 +0.3307로 내리고 넓은 판에서만 +0.4202가 된다. 트리는 16행으로 못 배운다.

8. 채택

주장 9. 학습 문턱을 40에서 15로 낮춘다. 한 줄이고, 좁은 라벨을 하나도 안 들이고, 짝 순위 우도가 이득 전부를 얻는다. 넓은 판은 트리 계열을 위한 갈래로 남긴다.

반증 조건. 첫 양수를 보고 바로 채택했다면 주장 레코드 114건을 들이는 쪽을 골랐을 것이다. 어디서 왔는지를 갈라 보니 그럴 필요가 없었다.

넓은 판을 기본으로 삼지 않는 이유가 하나 더 있다. 그 판의 채점 집합 116건 중 57건이 $p < 0.03$ 으로 예측 불가라, 판 위의 팝업 수치가 +0.24로 떨어진다. 못 맞히는 것을 분모에 넣으면 지표가 무엇을 말하는지 흐려진다.

문턱을 낮추면 팝업만 들어오는 것이 아니다. 아이돌 (2025년 이전 54건)은 이미 들어와 있지만 다른 도메인의 경계도 움직일 수 있다. 채택은 전 판을 다시 재고 확정한다.

Table 6: 남은 것.

문턱 15	다른 도메인에도 영향 — 전 판으로 다시 재기
주장 라벨	실측 대조가 있어야 “나쁘다”를 확정한다
마스크	여덟 건 사례 — 표본이 늘면 다시