

1.6 σ 와 6.2 σ 같은 “2 σ ” 라고 적힌 문턱을 참값 0 으로 재니 짝마다 네 배 어긋나 있었다

월드모델 실험실 · 노트 714 · 715

2026-08-06

1 한 줄

채택 문턱을 위약 대 위약으로 잰다 — 참값이 0 인 두 팔의 차. 기록된 문턱이 앱에서 1.6 σ (오탐률 27.8%)이고 KR 만화에서 6.2 σ (실제 신호를 놓친다)다. 행수로 설명되지 않는다 — 두 짝이 1,600과 1,716행인데 참값 0 차의 SD 가 네 배 다르다.

2 왜 이것을 잰나 — 규약에 구멍이 있었다

규약 아홉이 “규약이 요구하는 다섯 자”를 말하는데 몇 개가 통과해야 채택인지는 대장 어디에도 없었다. 그리고 지금 상태가 하필 갈리는 자리다 — 둘 통과(판 2.6배 · 앱 3.5배) 둘 미달(CN · KR).

이 상태를 보고 규칙을 정하면 그것이 체리피킹이다. “과반”이라 하면 채택되고 “전부”라 하면 보류된다. 그래서 결과와 독립적인 근거로 도출하고 그 도출을 측정으로 검증했다.

도출 — 계산에서 나온다

자 여섯은 두 갈래다. 집안 셋(판 · 낱파 통제 판 · 무리 안 판 — 같은 3,369행)과 집 밖 셋(KR · CN 만화 · 비게임 앱 — 판이 한 줄도 학습하지 않은 행). 둘은 다른 물음이라 대체할 수 없다 — 집안은 “이 판이 좋아졌나”, 집 밖은 “웁겨 가나”. 그리고 노트 629 가 집 밖 세 짝이 거의 완전 독립(2.99/3)임을 잰다. 각 문턱이 2 σ ($\approx$ 5%)이고 독립이면 우연히 넘는 확률은 ≥ 1 이 14% · ≥ 2 가 0.7% · ≥ 3 이 0.01% 다. 도출되는 규칙:

$$\text{집안} \geq 1 \text{ 이고 집 밖} \geq 2$$

이 규칙을 결과 보기 전에 사전등록했다(노트 714). 그리고 그 계산이 가정한 “문턱이 5% 를 가르다”를 검증한 것이 이 논문이다.

3 위약 대 위약 — 참값이 0 인 자

같은 판에서 독립적인 위약 셔플 넷을 만들고 그 쌍들의 “신호 몫”을 냈다. 참값은 0 이므로, 그 분포가 문턱을 넘는 비율이 실제 오탐률이다. 배선은 비싼 쪽을 공유한다 — 씨앗마다 판을 한 번만 적합하고 짝 셋 $\times$ 위약 넷을 그 위에서 예측한다(짝마다 따로 적합하면 여섯 배 든다).

짝	행	문턱	참값 0 차 SD	문턱이 몇 σ	오탐률
비게임 앱	1,600	0.024	0.0154	1.6σ	27.8%
KR 만화	1,716	0.025	0.0040	6.2σ	0.0%
CN 만화	352	0.022	0.0120	1.8 σ	8.3%
전체 (위약 쌍 18개 중 2개가 문턱 밖)					11.1%

사전등록 예측은 “오탐률이 5% 보다 클 것 — 8-20%” 였고 11.1% 로 맞았다. 근거도 맞았다 — 문턱은 노트 583/586 때 잡은 값이고 그 뒤 자료가 자랐다.




Figure 1: 왼쪽: 참값 0 분포와 기록된 문턱. 같은 “2σ”가 실제로는 1.6~6.2σ다. 가운데: 그 자로 읽은 신호. KR 이 옛 문턱에서 미달인데 2.3σ다. 오른쪽: “집 박 ≥ k”의 우연 확률 — 가정 대 실측.

주장. “2σ” 라고 적힌 문턱이 실제로 몇 σ 인지는 **딱마다 다르고, 어긋나는 방향도 다르다**. 앱에서는 너무 낮아 27.8%를 통과시키고 KR 에서는 너무 높아 실제 신호를 놓친다. 그러므로 문턱을 인용할 때 그것이 몇 σ 인지 같이 적어야 한다.

반증 조건. 참값 0 차 SD 를 씨앗 6 · 위약 4 로 켜다. 위약 8 · 씨앗 12 로 늘렸을 때 SD 가 크게 달라지면 이 표가 흔들린다 — 특히 KR 의 0.0040 은 작아서 표본에 민감할 수 있다.

행수로 설명되지 않는다

앱 1,600행과 KR 1,716행은 거의 같은데 참값 0 차 SD 가 0.0154 대 0.0040 으로 **네 배**다. 노트 712 는 CN(352행)이 씨앗 3 에서 안정되지 않은 것을 행수로 설명했는데 **그 설명이 여기서는 안 통한다**.

주장. **짜의 잡음 크기는 행수가 아니라 다른 것이 정한다**. 후보 둘 — **라벨 분포**(노트 691 이 라벨 자리폭을 딱마다 켜다)와 **텍스트 예보의 퍼짐**(노트 712: 앱 0.158 대 KR 0.0967). 다만 예보 퍼짐은 두 배 차이인데 SD 는 네 배라 그것만으로는 안 맞는다.

반증 조건. 행수를 통제한 짜 짜(비슷한 행수 · 다른 라벨 분포)을 더 만들어 재면 갈린다. 지금은 $n = 3$ 이고 그중 둘이 행수가 비슷하다.

4 규칙은 살아남았다 — 그리고 더 필요해졌다

실측 오탐률로 다시 계산하면:

	문턱이 5% 라 가정	실측 오탐률로
집 박 ≥ 1	14.3%	33.8%
집 박 ≥ 2	0.7%	2.3%
집 박 ≥ 3	0.01%	0.00%

“**집 박 하나만 통과**”는 세 번에 한 번 우연히 일어난다. 규칙이 필요하다는 것이 훨씬 강하게 확인됐다. 그리고 ≥ 2 는 2.3%로 5% 안이므로 **도출한 규칙은 그대로 선다**(다만 계산했던 0.7% 보다 세 배 느슨하다).

독립 확인 — 노트 710 이 같은 것을 말한다

CN 의 참값 0 차 절대값 최대가 **0.0214** 이고 문턱이 0.022 다. 노트 709 가 씨앗 3 에서 켜 CN 신호 몫 **+0.0271** 은 그 바로 위였고, 노트 710 이 씨앗 12 로 **+0.0053** 으로 무너뜨렸다. **두 측정이 서로 모르고 같은 것을 말한다** — 그 통과는 참값 0 분포의 꼬리였다.

5 KR 을 지금 통과로 바꾸지 않는다

새 문턱을 $2 \times (\text{참값} - 0 \text{ 차 SD})$ 로 잡으면 $\text{애플} 0.0308 \cdot \text{KR} \mathbf{0.0080} \cdot \text{CN} 0.0240$ 이다. 그러면 판정이 **애플 통과 · KR 통과 · CN 미달**이 되어 **집 밖** $2/3$ 이고 도출한 규칙을 충족한다.

주장. 그렇게 선언하지 않는다. 노트 714 사전등록에 “문턱은 기록된 표본 2σ 를 그대로 쓴다 — 이 실험이 그것을 검증하는 것이므로 바꾸지 않는다”고 적었다. **지금 고치면 결과를 보고 규칙을 바꾸는 것이고, 그것이 노트 133 이 막으려는 바로 그 일이다.** 문턱 개정은 **다음 사이클의 사전등록 대상**이다.

반증 조건. 사전등록에 그 문장이 없었다면 이 논문에서 개정해도 됐다. 있으므로 안 한다 — 그 문장의 커밋 시각이 이 측정보다 앞선다는 것이 이 절이 설 수 있는 근거다.

그리고 개정 전에 셋을 채워야 한다. ① 참값 0 SD 를 **위약 8 · 씨앗 12**로 굳힌다. ② KR 이 0.0092 대 0.0080 으로 1.15 배인데, 그것은 노트 710 에서 무너진 CN(1.23배)과 같은 거리다. ③ **왜 짝마다 SD 가 네 배 다른지** 모른다.