

IP 파운데이션 월드모델 연구 노트 146

결정적이라고 적혀 있던 스무 노트

노트 145가 “다른 가드도 극값 통계를 쓰고 있나”를 남겼다. 있었다 --- 그런데 그 가드의 더 큰 문제는 극값이 아니라 재는 시늉만 하고 있었다는 것이다

Sweetspot 월드모델 연구

2026년 7월 30일

초 록

가드 열하나를 훑었다. 극값을 쓰는 것은 둘 — 재현(씨앗 넷의 최대-최소)과 묶음(최대 묶음 크기)이다. 묶음은 정당하다(재는 대상 자체가 최대 묶음이다). 재현을 들여다보다 극값보다 큰 것을 찾았다. 그 가드는 씨앗을 바꾸려고 `np.random.seed(s)`를 부르는데, 이 판의 정식화는 전부 생성자에서 받은 씨앗으로 `np.random.default_rng`를 만든다. 전역 씨앗은 아무것도 안 바꿨다. 그래서 스무 노트 동안 모든 정식화가 “씨앗 넷 폭 0.0000”으로 — 즉 결정적이라고 — 보고됐다. 실제로 재 보니 F18 배경은 팝업 ρ 가 씨앗에 0.0590 움직이고 F8 부스팅은 0.0266, F9는 0.0148이다. 고쳤다. 검사검사 판정도 극값에서 예측 자기상관으로 바꿨다 — k 개 표본의 범위는 기대값이 k 와 함께 커지므로 ($d_2=1.13$, $d_4=2.06$), 예산 안에서 두 번만 돈 비싼 정식화가 자동으로 유리했다. 그리고 순위표를 다시 봤다. 판 ρ 의 씨앗 표준편차가 F8에서 0.0047, 두 정식화 차이의 짝 표준편차가 0.0087이다. 순위표 상위 열셋의 연속 격차 열둘 중 열이 그 값보다 작다. 위 여섯은 순위가 없는 것과 같다. 노트 145도 고친다 — 거기서 “판 ρ ”로 나란히 적은 두 표가 사실 다른 통계였다(문턱 40은 단순 평균, 문턱 15는 순위 지표). 순위 지표로 통일하면 문턱 40의 배경 이득이 +0.0185가 아니라 +0.0063 $\pm$ 0.0087이다. 노트 145의 결론(“채택 근거는 점수가 아니라 귀착이다”)은 그대로고, 오히려 더 맞다 — 점수 이득은 어느 설정에도 없다.

Table 1: 가드가 쓰는 통계.

	통계	판정
치환	$R=99$ 귀무	괜찮다 (노트 125에서 고침)
분해능	붓스트랩 400 백분위	괜찮다
집단	평균 · 모의 보정	괜찮다 (노트 137)
평탄	단일 적합 사분위	반복이 아니라 괜찮다
묶음	최대 묶음	재는 대상이 최대다
재현	씨앗 넷 최대-최소	고쳐야 한다

Table 2: 팝업 ρ . 씨앗 넷.

	고치기 전	고친 뒤
F6 능형	.0000	.0000 (진짜 결정적)
F9 순위우도	.0000	.0148
F8 부스팅	.0000	.0266
F18 배경	.0000	.0590

스무 노트 동안 “씨앗 넷 폭 0.0000”을 달고 채택 심사를 통과했다.

1. 가드 열하나를 훑었다

주장 1. 극값을 쓰는 것은 둘뿐이고 하나는 정당하다. 묶음 가드가 재는 것은 “같은 값에 뭉친 제일 큰 덩어리”이므로 최대가 곧 대상이다. 재현만 남는다.

반증 조건. 노트 145의 걱정이 절반은 기우였다. 다만 남은 하나가 켜다.

2. 재는 시늉만 하고 있었다

주장 2. 전역 씨앗은 아무것도 안 바꿨다. 가드는 `np.random.seed(s)`를 부르는데 정식화는 `default_rng(self.seed)`를 쓴다 — 두 난수원은 서로 모른다. 이제 객체의 씨앗 속성을 직접 알아 끼운다.

반증 조건. F6 능형만 진짜로 결정적이다. 나머지 셋은

주장 3. 판정도 극값에서 자기상관으로 바꿨다. k 개 표본의 범위는 기대값이 k 와 함께 커진다. 예산 안에서 두 번만 도는 비싼 정식화가 네 번 도는 짠 것보다 자동으로 좁게 나왔다 — 비쌀수록 유리한 판정이었다.

반증 조건. 자기상관은 라벨을 안 본다. 귀착 가드(노트 144 · 145)와 같은 통계이고, 둘의 차이는 무엇을 혼드느냐뿐이다 — 재현은 씨앗, 귀착은 풀.

3. 순위표에 띠를 없으면

주장 4. 순위표 위 여섯은 순위가 없다. 상위 열셋의 연속 격차 열둘 중 열이 짝 표준편차 0.0087보다 작다. 1위와 2위의 격차는 0.0013이고 그것은 씨앗을 바꾸면 뒤집힌다.




Figure 1: 왼쪽 — 씨앗 따를 없은 순위표. 오른쪽 — 고치기 전 재현 가드는 전부 0을 보고했다.

Table 3: 판 ρ 의 씨앗 흔들림. 문턱 40 · 검색+달력, 씨앗 다섯.

	평균	sd
F8 부스팅	+.4281	.0047
F18 배경	+.4345	.0063
차	+.0063	.0087

Table 4: 배경 대 부스팅. 순위 지표로 통일.

	노트 145가 적은 값	순위 지표
문턱 40	+.0185 (평균)	+.0063 ± .0087
문턱 15	-.0013	-.0013

Table 5: 남은 것.

순위표	위 여섯이 겹친다 — 가르려면 표본이 필요하다
씨앗	채택 문턱 0.05 는 어디서 왔나 — 교정 안 됨
비용	배경은 여덟 배인데 사는 것이 귀찮뿐이다

뿐이다 — 대상을 늘리거나 (팝업 59건이 병목이고 노트 132가 상한을 202로 줬다), 판정치의 분산을 줄이거나. 후자는 방법 문제이고, 씨앗 평균을 판정치로 쓰는 것부터가 그 한 수다.

반증 조건. 판 ρ 자체가 여러 대상의 가중 평균이라 개별 대상보다는 안정적이다. 그래도 이 정도다.

이제 실행마다 씨앗 흔들림과 귀찮 자기상관을 요약에 같이 싣는다. 순위표에 따가 없으면 순위가 해상도를 넘어서 읽힌다.

4. 노트 145를 고친다

노트 145의 두 표에 “판 ρ ”라고 나란히 적었는데 서로 다른 통계였다 — 문턱 40 표는 대상 평균(board), 문턱 15 표는 순위 지표(pooled)다. 순위 지표는 노트 126 이후 이 판의 판정치이므로 그것으로 통일한다.

주장 5. 점수 이득은 어느 설정에도 없다. 노트 145는 “문턱 40에서는 오르고 15에서는 안 오른다”로 읽었는데, 순위 지표로 보면 40에서도 안 오른다. 결론(“채택 근거는 점수가 아니라 귀찮이다”)은 그대로이고 더 깨끗해진다.

반증 조건. 배경의 귀찮 이득(0.906 → 0.948)은 그대로다 — 그 값은 라벨을 안 보므로 이 정정에 안 걸린다.

첫 줄이 다음 자리다. 순위표를 가르는 길은 두 가지