

IP 파운데이션 월드모델 연구 노트 150

아무 문서나 붙이고 있었다

노트 149의 위키 축을 한국어판으로 넓히려다 스물다섯 건 중 스물한 건이 같은 문서에 붙은 것을 봤다 ---
 찢어 내니 이득이 오히려 커졌다

Sweetspot 월드모델 연구

2026년 7월 30일

초 록

노트 149가 위키백과 조희수로 축을 만들고 “애니 · 웹툰은 한국어 제목이라 영문 위키가 안 붙는다”를 남겼다. 한국어판을 붙이러 갔다가 표본 스물다섯 건을 눈으로 보고 멈췄다 — 스물한 건이 전부 “네이버 웹툰” 한 문서에 붙어 있었다. 원인은 제목 해석의 마지막 줄이었다. 겹치는 후보가 없으면 검색 1위를 그냥 썼는데, 그러면 힌트 단어(“웹툰”)가 이겨서 목록 문서 · 플랫폼 문서로 간다. 전체를 감사하니 붙은 3,489건 중 1,002건(29%)이 겹침 0이었다 — 모바일은 “WhatsApp”과 “App store”, 만화는 “2026 in anime”, 세계애니는 성우 이름(“Tomoaki Maeno”)으로 갔다. 여러 레코드가 한 문서를 나눠 쓰면 그 축은 레코드를 안 재고 날짜만 켜다. 고치는 길에 둘째 것도 나왔다 — 비교용 정규화가 $[\wedge a-z0-9]$ 를 다 지우고 있어서 한글 제목은 빈 문자열이 됐다. 겹침 점수가 언제나 0이 되니 한국어판을 붙이는 순간 100%가 오염됐을 것이다. 넷을 했다 — 겹침 0은 안 붙인다, 정규화가 한글을 남긴다, 오염된 1,002건을 지우고 다시 굶는다, 그리고 shared()를 만들어 “한 문서를 몇이 나눠 쓰나”를 상시로 적는다. 남은 공유는 프랜차이즈다 — 애니 최대 27이 “원피스(애니메이션)”, 세계애니 최대 10이 “My Hero Academia”다. 그리고 찢으니 이득이 커졌다. 판 ρ 이득이 +0.0092에서 +0.0104 $\pm$ 0.0041($t=2.5$)이 됐다. 덮음은 29% 줄었는데 신호는 늘었다 — 지운 것이 잡음이었다는 직접 증거다. F8 부스팅은 +0.0000 $\pm$ 0.0064로 여전히 안 움직인다.

Table 1: 고치기 전. 웹툰 표본 25건.

붙은 문서	건	
네이버 웹툰	21	플랫폼 문서
참교육	1	맞춤(창은 빔)
못 찾음	3	

Table 2: 겹침 0으로 붙은 문서. 전체 감사.

	건	
점수 1.0 (제목 같음)	1,935	
점수 0.8/0.9 (품음)	552	
점수 0.0 (안 겹침)	1,002	29%

1. 스물다섯 건을 눈으로 봤다

한국어판을 붙이고 웹툰 스물다섯 건을 시험 삼아 굶었다. 채움이 21/25로 좋아 보였다. 그런데 붙은 문서를 찍어 보니 —

주장 1. 채움률만 봤으면 못 봤다. 21/25는 세계애니(22/25)와 거의 같은 수치다. 값을 찍어 보고서야 스물한 건이 같은 문서라는 것이 보였다.

반증 조건. 노트 133 · 142에서 같은 자리에 두 번 걸렸다 — 이름과 값이 갈리는 곳. 이번에는 “덮음”이라는 요약 하나가 스물한 건의 동일성을 감췄다.

2. 29퍼센트였다

주장 2. 여러 레코드가 한 문서를 나눠 쓰면 그 축은 날짜만 켜다. 같은 문서의 조희수를 서로 다른 창으로 자를 뿐이므로, 남는 변이는 시점뿐이다. 그것을 “오픈 이전

Table 3: 겹침 0이 간 곳.

웹툰	네이버 웹툰	17
모바일	List of video games released in 2026	7
모바일	WhatsApp	6
만화	List of yuri works	5
세계애니	Tomoaki Maeno (성우)	4
모바일	App store	4

관심도”라고 부르면 안 된다.

반증 조건. 그렇다고 공유가 다 나쁜 것은 아니다 — 2기 · 3기가 프랜차이즈 문서를 같이 쓰는 것은 의도한 바다. 그래서 판정이 아니라 분포를 적는다.

3. 한글이 지워지고 있었다

주장 3. 정규화가 한글을 지웠다. 비교용 정규화가 $[\wedge a-z0-9]$ 를 전부 없애서 “나 혼자만 레벨업”이 빈 문자열이




Figure 1: 왼쪽 — 뒷음의 29%가 아무 문서였다. 가운데 — 남은 공유는 프랜차이즈다. 오른쪽 — 잡음을 빼니 신호가 커졌다.

Table 4: 고침.

- ① 검침 0 이면 안 붙인다 (문서 없음으로 적는다)
- ② 정규화가 한글을 남긴다
- ③ 오염된 1,002건을 지우고 다시 긁는다
- ④ `shared()` — 한 문서를 몇이 쓰나를 상시로

Table 5: 고친 뒤. 나눠 쓰기.

	최대	5+ 문	최대 공유 문서
애니	27	10.3%	원피스 (애니메이션)
세계애니	10	6.3%	My Hero Academia
만화	3	0%	
웹툰	3	0%	
게임	2	0%	

됐다. 빈 문자열은 아무것도 안 겹치니 점수가 언제나 0이고, 그러면 위 규칙에 따라 모든 한국어 제목이 검색 1 위로 갔을 것이다.

반증 조건. 영문 도메인에서는 이 버그가 안 보인다. 한국어판을 붙이는 그 순간에만 터진다 — 그리고 그때 100%가 오염된다.

4. 넷을 고쳤다

주장 4. 남은 공유는 전부 프랜차이즈다. 원피스 27건 · 명탐정 코난 16건 · 나의 히어로 아카데미아 13건 — 장수 시리즈가 시즌마다 레코드를 갖고 문서를 하나 쓴다.

반증 조건. 웹툰의 “연애”가 3건인데 이진 제목이 일반 명사라 한국어 위키의 다른 문서에 정확히 걸린 경우다. 제목 겹침만으로는 이런 것을 못 거른다.

5. 찢으니 이득이 커졌다

주장 5. 뒷음은 29% 줄었는데 신호는 늘었다. +0.0092

Table 6: 위키 축이 주는 판 ρ 이득. 씨앗 셋 평균 · 짝 재추출 400.

	이득	짝 sd	
F18 · 오염된 축	+0.0092	.0034	t=2.7
F18 · 찢은 축	+0.0104	.0041	t=2.5
F8 · 찢은 축	+0.0000	.0064	t=0.0

Table 7: 도메인별. F18 배경, 찢은 축.

	위키 뒷음	현행	+ 위키
게임	49%	+0.410	+0.472
세계애니	55%	+0.494	+0.555
애니	43%	+0.475	+0.483
모바일	12%	+0.566	+0.562
웹툰	12%	+0.358	+0.343
팝업	0%	+0.451	+0.470

에서 +0.0104로. 지운 1,002건이 잡음이었다는 직접 증거다 — 잡음 축은 이득을 깎는다.

반증 조건. 짝 sd 가 0.0034에서 0.0041로 늘어 t 는 2.7 에서 2.5로 조금 내렸다. 관측 수가 줄었으니 당연하다. 여전히 갈린다.

주장 6. 뒷음이 얇으면 값진다. 게임(49%)과 세계애니(55%)가 +0.06씩 오르고, 웹툰(12%)과 모바일(12%)은 조금 내린다. 축을 절반도 못 채우면 그 열은 관측된 소수에만 쓰이고 나머지는 중립으로 채워진다.

반증 조건. 팝업의 +0.019는 여전히 주장 안 한다 — 팝업에는 위키 축이 없다(노트 144의 귀착 전파).

셋째 줄을 적어 둔다. 웹툰의 `wiki_peak_ratio` 와 라벨의 상관이 0.376으로 이 축 세트에서 제일 높다. 문턱 0.70 아래지만, 웹툰 라벨이 네이버 즐겨찾기이고 위키 조회수도 “화제가 된 정도”를 재드로 같은 것을 두 번 채는 쪽에 가깝다. 뒷음 12%로 이득도 안 나니 웹툰은

Table 8: 남은 것.

웹툰·모바일	뒷음 12% — 붙일지 말지를 도메인마다
일반 명사	“연애” 같은 제목은 제목 겹침으로 못 거른다
누수	웹툰 $ r =.376$ 이 제일 높다 — 문턱 아래지만

안 붙이는 쪽이 낫다 — 다만 그 결정을 점수로 하면 노트 126이 잡은 그 잘못이니, 뒷음 문턱으로 정하는 편이 맞다.