

이미 걸러 둔 것을 다시 걸렀다

원천 열 29개를 새 후보로 썼는데 다섯 도메인은 노트 324가 이미 걸렸다 — 그래도 세 도메인이 남는다

월드모델 실험실 · 노트 774 · 775 · 777

2026-08-07

1 한 줄

논문 153이 팝업 방문객 갈래를 내리고 T7의 물음을 바꿨다 — “판의 두꺼운 도메인 원천에 아직 안 쓰는 열이 있나”. 세었다: 8/8 도메인이 문턱을 넘고 후보 29열.

그리고 그 셈이 대부분 이미 된 일이었다. lab/rawaxes.py의 머리말이 노트 321·324의 표를 적어 두고 있었다 — 후보 43개 중 출처가 32개(74%)를 막았고 그 목록에 내가 “가장 값 있는 발견”으로 꼽은 n_tag가 있다(“사후 의심 — 쌓인다”).

그래도 남는 것이 있다 — rawaxes.SPEC이 훑은 도메인은 다섯이고 만화 · 게임 · 도서는 없다. 그 셋의 11열이 진짜 새 후보다.

2 먼저 나온 배선 사실 — 도메인 전용 열이 거의 없다

판이 쓰는 특징을 찍었다. 도메인마다 36개이고 전 도메인이 같다.

팝업에서 온 $5(\text{target_breadth} \cdot \text{venue_prominence} \cdot \text{entry_friction} \cdot \text{media_push} \cdot \text{goods_scale}) + \text{trend}_*3 + \text{cal}_*6 + \text{wiki}_*3 + \text{tag}_c*10 + \text{meta}_c*2 + \text{fund}_*2 + \text{mob}_*3 + \text{gen} \cdot \text{grp}$

도메인 전용은 게임 4개뿐(price · age_rating · ram_gb · n_category — 실은 앱 자료다). 즉 웹툰 · 애니 · 만화 · 펀딩 · 세계애니에는 그 도메인만의 열이 하나도 없다.

3 세었고, 게이트를 두 번 조였다

원천은 data/state/{도메인}_records.json이다.

도메인(유보)	원천 열	안 쓰는 열	느슨한 통과	조인 통과
웹툰(650)	17	17	11	5
애니(606)	22	21	14	7
펀딩(529)	19	19	12	5
모바일(441)	18	17	11	3
세계애니(300)	22	22	13	4
만화(258)	18	18	9	4
게임(180)	20	19	10	3
도서(163)	19	18	10	5

주장. 정규식만으로는 라벨이 샌다. 첫 게이트가 통과를 11~15개로 냈다. y_접두 라벨 넷이 통과했고(y_positive · y_w30 · y_favorite · label_basis) favourites · amount · sale도 통과했다. 목록을 눈으로 읽어야 잡힌다 — 읽어서 is_ending(완결)과 n_episode · n_chapter · n_volume(최종 편수는 결과다)을 더 떨어뜨렸다.

반증 조건. 눈으로 읽는 것도 놓친다 — 그것이 다음 절이다. 내가 눈으로 읽고도 n_tag를 통과시켰고, 저장소는 그것을 이미 막아 뒀다.

떨어뜨린 갈래: 결과성(라벨 포함) · 텍스트(T5가 “도메인 안 전용”으로 확정 · 노트 719·729) · 날짜(cal_* 여섯 열에 있다) · 이름만 다른 것(max_price=fund_maxprice · n_lang=mob_nlang · advisory=mob_advisory 등).




Figure 1: 왼쪽: 8/8 도메인이 문턱을 넘는다. 가운데: 게이트가 무엇을 떨어뜨렸나 — 정규식만으로는 y_ 접두 라벨이 됐다. 오른쪽: 그 섀미 이미 된 일이었다 — 그리고 남은 세 도메인.

4 그리고 그 섀미 이미 된 일이었다

lab/rawaxes.py 를 읽었다. 머리말이 표를 적어 두고 있었다.

후보	43	축 파일 + 원천 레코드에서 검사 ①③④ 통과(노트 321 · 324)
- 출처가 막음	32	74% — 사후 라벨 · 지금 굵은 스냅샷 · 식별자 · 끝나야 붙는 것 · 사후 의심으로 쌓이는 것(n_episode · n_tag)
= 남은 것	11	그중 10이 검사 ②(시간 조각 다섯 부호 일치) 5/5
묶음으로 판	-0.0027	서랍에 넣었다(노트 324)
갈라서 넷만	+0.0068	12/12 · 편딩 +0.0521 · 모바일 +0.0135(노트 348)
		= loop.RAW_KEEP

주장. 내가 “가장 값 있는 발견”으로 꼽은 열이 이미 막힌 열이었다. n_tag 는 “사후 의심 — 쌓인다” 로 분류돼 있다. 나는 그것을 두고 “4 도메인에 이름이 같아 T5 가 찾던 공유할 것의 후보”라고 적었다. 규율: 후보를 세기 전에 그 후보를 이미 걸러 둔 코드를 찾는다. 노트 763(“기제를 세우기 전에 채점 규칙을 읽는다”)의 짝이고 이 계열이 이 세션에서 세 번째다 — 노트 738(가드의 시험대를 안 적음) · 노트 763(채점 규칙을 안 읽음) · 여기(이미 한 섀미를 다시 함).

반증 조건. 다시 섀민 것이 완전한 낭비는 아니다 — 배선 사실 하나(판 특징 36개가 전 도메인 동일 · 전용 열이 게임 4개뿐)와 안 좋은 세 도메인이 그 덕에 나왔다. 그러나 그 둘은 rawaxes.py 를 먼저 읽었어도 나왔을 것이고, 더 빨리 나왔을 것이다.

노트 348 의 교훈을 되찾았다

묶음으로는 못 쓰고 갈라면 쓴다 — 지는 여섯이 이기는 넷을 덮고 있었다.

이것은 논문 146 이 켜 것과 같은 총이다 — 열을 많이 넣는 것이 싸다는 것과 도움 되는 열만 골라야 한다는 것은 다른 문장이다. 그리고 논문 144 가 소스 고르기는 잡음 예산 안에서만 이득임을 켜다. 여기서는 고르기가 -0.0027 → +0.0068 을 냈다 — 도메인이 클러스터이고 클러스터가 12개라 고르기의 잡음이 작았기 때문이다.

5 그래도 세 도메인이 남는다

rawaxes.SPEC 의 도메인은 모바일 · 웹툰 · 애니 · 세계애니 · 편딩 다섯이다. 만화 · 게임 · 도서는 없다.

만화(258)	format · is_adult · n_author	3열
게임(180)	is_free · n_dlc · n_platform	3열
도서(163)	book_format · pages · width_mm · height_mm · weight_g	5열
11 열 · 유보 채점 601 = 판 유보의 17.8%		

주장. 도서의 물리 치수가 가장 깨끗하다. 쪽수 · 판형 · 폭 · 높이 · 무게는 출간 시점에 확정되고 인기와 함께 자라지 않는다 — `n_tag` 가 막힌 이유가 정확히 “쌍인다”였다. 그리고 그것은 지금까지 이 판이 한 번도 안 써 본 종류의 정보다 (물리적 형태).

반증 조건. 도서는 유보 163행으로 얇다 — 논문 146 이 얇은 도메인에서 열당 비용이 0.02~0.025라고 적었으므로 5열은 그 도메인에서 비쌀 수 있다. 그래서 노트 348 의 순서를 지켜 도메인별로 갈라 놓고, 그 도메인 점수가 위약을 이기는지를 먼저 본다.

다음 실험을 값으로 적었다

갑(만들기)	세 도메인 11 열을 <code>rawaxes</code> 관례로 축으로 만든다 범주형은 집단 크기 순 0~1 · 20건 미만 마스크 0 · 수치형은 관측값만 백분위 라벨을 한 번도 안 본다
을(재기)	☒ 묶음으로 넣지 않는다(노트 348) — 도메인 하나씩 그 도메인 열만 위약 3 뽑기(규약 20) · 씨앗 6 · 창 안 백분위(규약 27) · 유보 덮음을 1.000(규약 22)
판정	그 도메인 점수가 위약 3 뽑기 전부보다 크고 판이 문턱 안에서 안 나빠지면 남긴다 셋 다 지면 원천이 말랐고 외부 API 가 유일한 길이다

그리고 `n_tag` 는 안 쓴다.