

IP 파운데이션 월드모델 연구 노트 156

절반만 흔들었더니 순서가 반대였다

노트 155가 “판 2위가 부호를 뒤집는다”고 했다. 아니었다 --- 내 측정자가 0을 내고 있었고, 제대로 재니 판 순위와 손잡이 충실도가 -0.87 로 어긋난다

Sweetspot 월드모델 연구

2026년 7월 30일

초 록

노트 155는 축을 모든 행에서 한 칸 올리고 예측의 평균 변화를 개입 효과로 삼았다. 순위를 내는 정식화에서 그 값은 항상 정확히 0이다 --- 단조 이동은 순위를 안 바꾸니까. F18 배경은 그걸 알아채고 뻘했는데, F10 도메인수축도 같은 이유로 0인 것을 못 알아봤다. 부호를 비교하니 $\text{sign}(0)$ 이 $+1$ 과도 -1 과도 안 같아서 일치율이 $5/36 = 14\%$ 로 나왔고, 나는 그것을 “뒤집는 것이 규칙”이라고 적었다. 역전이 아니라 무측정이었다. 설계를 고쳤다 --- 무작위 절반만 올리고 그 절반이 나머지에 견주어 순위가 올랐는지 본다. 개입의 뜻과도 맞고 (“이 팝업의 굿즈를 키우면 남들 사이에서 위로 가나”) 순위를 내든 눈금을 내든 똑같이 쥔다. 다시 재니 F10 은 64%로 동전 위이고 오히려 자료와 제일 잘 맞는다 ($+0.136$). 그리고 챔피언 F18 도 이제 쥔 수 있다 --- 81%다. 노트 155의 핵심은 살아남는다. 다섯 정식화 전부, 모형이 함의하는 개입 효과와 그 도메인의 부분상관 사이 순위상관이 $|r| \leq 0.136$ 이다. 그런데 새로 보이는 것이 있다. 판 ρ 와 “자료 부호와 맞은 비율”의 순위상관이 -0.872 다. 판 1 · 2위인 부스팅 둘(F18 · F8)이 자료 부호를 69% · 67%로 제일 못 맞히고, 판 4 · 5위인 선형 둘(F6 · F9)이 83%로 제일 잘 맞힌다. 반대로 “내 상식과 맞은 비율”은 판과 $+0.564$ 로 같이 간다. 두 잣대가 갈리는 자리가 이야기다 --- 부스팅은 도메인을 건너 평균낸 강한 신호(굿즈 크면 좋다)를 배우고 그것이 상식과 맞는다. 도메인 안의 조건부 구조는 안 배우고, 손잡이에 필요한 것은 그 조건부다.

1. 정정 --- 역전이 아니라 무측정이었다

주장 1. 노트 155의 “F10 은 부호를 뒤집는 것이 규칙 (14%)”은 틀렸다. F10 의 `_mix` 는 두 능형 예측을 각각 `rankdata` 로 바꾼 뒤 섞는다. 축을 모든 행에서 같이 올리면 두 순위가 다 그대로이므로 출력이 한 비트도 안 변한다 --- 평균 차가 정확히 0.0000이다.

반증 조건. 직접 확인했다: 세계애니 · 굿즈 규모에서 자르든 안 자르든 F10 과 F18 은 $+0.0000$, F8 만 $+0.0641$ 이다. 노트 155가 F18 을 뻘 그 이유가 F10 에도 그대로 있었는데 표에는 숫자가 찍히니 못 봤다.

Table 1: 다시 쥔 개입. 씨앗 셋 × 절반 여덟 번.

	판 ρ	사건	자료	자료상관
F18 배경	$+0.4391$	81%	69%	-0.027
F8 부스팅	$+0.4341$	83%	67%	-0.002
F10 도메인수축	$+0.3735$	64%	75%	$+0.136$
F6 능형	$+0.3532$	78%	83%	$+0.033$
F9 순위우도	$+0.3519$	78%	83%	$+0.032$

반증 조건. 그래도 $+0.136$ 은 작다. 순위표를 뒤집을 값은 아니고 “제일 덜 나쁘다”는 뜻이다.

2. 고친 설계 --- 절반만

주장 2. 무작위 절반만 올리고 그 절반의 순위 이동을 본다. 상대 순위가 실제로 바뀌므로 순위를 내는 정식화에서도 쥔 수 있고, 개입의 뜻과도 맞는다.

반증 조건. 절반을 여덟 번 다시 뽑아 평균한다. 효과 크기가 $0.033 \sim 0.039$ (순위 비율 눈금)로 작지만 방향은 안정적이다.

주장 3. F10 은 64%로 동전 위고 자료와는 제일 잘 맞는다 ($+0.136$). 노트 155가 최악이라고 적은 그 정식화가 다섯 중 자료 충실도 1 위다.

3. 노트 155의 핵심은 살아남는다

주장 4. 다섯 전부 손잡이가 아니다. 모형이 함의하는 개입 효과와 그 도메인의 부분상관 사이 순위상관이 $-0.027 \sim +0.136$ 이다. 제일 좋은 것도 0.14 다.

반증 조건. 부분상관도 인과가 아니다 --- 통제 안 된 교란이 남는다. 그러니 여기서 말하는 것은 여전히 “자료 와도 안 맞는다”까지다.

4. 새로 보이는 것 --- 두 잣대가 갈린다

주장 5. 판을 잘 맞힐수록 자료 부호를 못 맞힌다(-0.872).




Figure 1: 왼쪽 — sign(0) 을 역전으로 읽었다. 가운데 — 판 순위와 자료 부호 일치가 반대로 간다. 오른쪽 — 판 위쪽은 상식을 따르고 자료를 안 따른다.

Table 2: 판 ρ 와의 순위상관. 정식화 다섯.

자료 부호와 맞은 비율	-.872
자료와 순위상관	-.600
내 상식과 맞은 비율	+.564

Table 3: 남은 것.

판정치	판 ρ 하나로는 손잡이 쪽이 안 보인다
F10	자료 충실도 1위 — 도메인별 계수가 이유인가
효과 크기	0.033~0.039 — 한 칸이 순위를 3%밖에 못 옮긴다

판 1 · 2위인 부스팅 둘이 69% · 67%, 4 · 5위인 선형 둘이 83% · 83%다. 그런데 상식과는 반대로 같이 간다 (+0.564) — 부스팅이 상식을 제일 잘 따른다.

반증 조건. 정식화가 다섯뿐이라 순위상관 -0.872의 표준오차가 크다. 다만 부스팅 둘과 선형 둘이 깨끗하게 갈리는 것은 우연으로 보기 어렵다.

주장 6. 읽는 법. 부스팅은 도메인을 건너 평균낸 강한 신호를 배운다 — “굿즈가 크면 좋다”는 전 도메인에서 참이고 내 상식과도 맞는다. 도메인 안의 조건부 구조(웹툰에서는 굿즈 규모가 오히려 음수)는 안 배운다. 그래서 줄은 잘 세우고 손잡이는 못 돌린다.

반증 조건. 노트 139가 “폴링은 지켜 주고 희석한다”를 값으로 잡았고, 노트 148이 “섞어도 안 오른다”를 보았다. 이 노트가 그 대가를 처음으로 손잡이 쪽에서 켜다 — 보호받는 대신 잃는 것이 조건부 구조다.

마지막 줄이 다음 자리다. 축 한 칸을 올려도 순위가 3%밖에 안 움직인다. 사람이 매긴 축의 실제 분산이 그만큼 크이라면 정상이지만, 모형이 축을 거의 안 쓰고 있다는 뜻일 수도 있다. 검색 · 달력 · 위키 축이 열아홉 개고 손 축은 다섯이다 — 그 비율부터 재야 한다.