

아무 말도 안 하는 쪽이 낫다

판정선은 넘나드는데 기후값은 못 넘는다

월드모델 실험실 · 노트 791 ~ 792

2026-08-07

1 한 줄

노트 691 이 능력 자를 재고 T6 판정을 발동시켰다 — 자릿수 오차 41.95% 가 30% 선을 넘었으니 이 판의 예보는 순위 전용이다. 그런데 그 결론은 **되돌림 하나**(등백분위)에서 나온 것이었다.

되돌림을 넷으로 늘려 봤다. **판정선은 넘나드나** — 41.95% ↔ 18.80%. **같은 판, 같은 자료, 같은 자인데 되돌림만 바꿔 T6 의 선을 하나는 넘고 하나는 안 넘는다.**

그리고 **진짜 기준선을 세우니 전부 못 넘는다. 기후값** — 학습 라벨 평균을 늘 말하고 구간은 학습 라벨 10~90분위 — 이 자릿수 오차 **0.1656** · 덮음 **0.8448** 이다. 가장 좋은 되돌림이 0.1880 으로 **비긴다**.

예보를 절대값으로 엮는 것은 아무 말도 안 하는 것과 같다. 그리고 구간에서는 **아무 말도 안 하는 쪽이 낫다**(0.8448 대 0.40).

2 먼저 — 재는 코드가 또 없었다

노트 789 가 **규약 41**(법칙을 재는 코드는 저장소에 둔다)을 세운 게 한 사이클 전이다. **능력 자도 같은 상태였다** — `serve/capability.py` 는 **결론만** 담고 노트 691 의 재는 코드는 스크래치패드와 함께 사라졌다. 그래서 이번엔 `lab/calib.py` 를 저장소에 만들고 거기서 잤다.

그리고 다시 만들면서 노트 691 의 전제가 틀린 것을 찾았다. 691 은 “예보는 도메인 안 백분위 꼴(SD 0.126)”이라 적었는데, 챔피언 F18_bagboost 는 그렇지 않다 — 만화 8.19 ~ 5,621.27 · 팝업 1.56 ~ 22.62 이고 **예보 SD 가 도메인마다 5.6 ~ 1,581 로 300배 다르다.**

그 자에서 내 분위회귀가 발산했다

첫 실행에서 분위회귀가 자릿수 오차 **0.998** 을 냈다 — 거의 전부 틀린다는 말이라 명백히 고장이다. 고정 학습률이 SD 1,581 인 자에서 안 먹은 것이다.

주장. 내 검증이 너무 쉬웠다. 손으로 쓴 분위회귀를 $x \text{ SD} = 1$ 에서만 시험하고 통과시켰다(덮는 몫 0.100·0.500·0.900 정확). **자가 300배 다른 데 쓸 자를 SD 1 에서만 검증하면 안 된다.** 표준화해서 풀도록 고치고 $x \text{ SD } 1 \cdot 700 \cdot 0.01$ 세 자에서 다시 확인했다.

반증 조건. 그래도 고장이 눈에 띈 것은 운이 좋았다 — 0.998 은 말이 안 되니까 보였다. 0.35 **쯤 나왔으면 그대로 실었을 것이다.** 이 논문의 다른 숫자 중에 그런 것이 없다는 보장은 없다.

3 되돌림 넷과 위약

되돌림	자릿수 오차 진짜	위약	덮음 진짜	위약
등백분위(노트 691)	0.4367	0.4458	0.4122	0.8310
OLS	0.3269	0.1696	0.3730	0.8347
분위회귀	0.3117	0.1715	0.4026	0.8294

위약이 이긴다 — 전부 씨앗 SD 3배 밖이다. 사전등록한 판정 셋이 (가) 되돌림이 문제였다 (나) 셋 다 위약과 붙는다 (다) 구간만 걸린다 였는데 **어느 것도 발동하지 않았다.**




Figure 1: 왼쪽: 되돌림 넷 — 점선(T6 판정선)은 넘나들고 초록선(기후값)은 안 넘긴다. 가운데: 예보의 자가 옮겨 간다 — 라벨은 안 옮긴다. 오른쪽: 도메인 구간은 이름값을 하고 작품 구간은 아니다.

주장. 내 규칙 셋이 전부 “진짜 $\geq$ 위약”을 전제했다. 위약이 이기는 경우를 안 적었다 — 노트 770 에서 같은 종류의 구멍을 냈고 두 번째다.

반증 조건. 규칙에 구멍이 있어도 측정은 멀쩡하다. 다만 구멍 난 규칙은 결과를 보고 매우게 되고 그것이 곧 사후 판정이다 — 이번엔 메우는 대신 넷째 결과를 그대로 적고 다음 사전등록에서 양방향을 다 적었다.

그 위약이 무엇인지 확인했다 — 기후값이다

OLS 위약의 기울기가 $10^{-6} \sim 4 \times 10^{-2}$ 이고 예측 SD 가 0.0005 $\sim$ 0.17 이다. 즉 위약은 정확히 “학습 라벨 평균을 늘 말하는 상수”이고 구간은 학습 라벨 10~90분위다.

주장. 노트 691 의 위약은 약한 상대였다. 등백분위에서 섞은 예보는 라벨 분포에서 무작위로 뽑는 것이라 기후값보다 훨씬 나쁘다. 그 약한 상대와 비겨서 “구분 안 된다”로 적었다. 같은 위약이 OLS 에서는 기울기 ≈ 0 으로 무너져 기후값이 된다 — 위약의 세기가 되돌림에 따라 변한다. 그래서 위약이 아니라 이름 붙이고 값을 못박은 기준선이 필요하다 (규약 43).

반증 조건. 기후값도 하나의 선택이다 — 학습 평균이 아니라 학습 중앙값을 쓰면 자릿수 오차가 달라진다. 다만 그것은 결과를 보기 전에 정할 수 있는 선택이고, 섞은 위약은 그렇지 않다.

4 원인 — 예보의 자가 시간에 따라 옮겨 간다

	예보 평균 옮김 (학습 SD 단위)	라벨 평균 옮김 (학습 SD 단위)	되돌린 중심 오차 (log10)
팝업	+3.69	-0.23	+0.963
도서	+2.29	-1.33	+0.832
만화	-1.70	-0.03	-0.824
세계애니	-1.60	-0.42	-0.283
아이돌	-1.12	+0.71	-1.473

예보는 $-1.7 \sim +3.7$ SD 옮겨 가는데 라벨은 거의 안 옮긴다(만화 -0.03 · 애니 $+0.00$ · 게임 -0.02). 학습에서 맞춘 되돌림 선을 유보 예보에 먹이면 중심이 통째로 어긋난다 — 최대 1.47 log10, 즉 30배.

주장. 이것이 노트 691 이 못 준 기제다. 691 은 “순위 정보가 절대값으로 번역이 안 된다”로 적었고 왜인지는 몰랐다. 스피어만은 유보 안에서만 계산되므로 드리프트에 면역이고, 절대값 되돌림은 학습 자에 묶여 있어 면역이 아니다. 판 ρ 0.4689 가 멀쩡한 채로 절대값이 무너지는 이유가 이것이다.

반증 조건. 드리프트가 정식화의 성질인지 자료의 성질인지 안 갈랐다 — 유보에 새 도메인 조합이나 다른 축 덮음이 들어오면 예보 자가 움직일 수 있다. 다른 정식화로 같은 드리프트가 나오나 안 켜다.

만화가 결정적 사례다

만화의 진짜 구간이 기후값 구간보다 좁다(1.109 대 1.484). 그런데 덮음이 0.012 대 0.992 다. 좁아서 못 덮는 게 아니라 엉뚱한 데 있어서 못 덮는다.

5 드리프트를 없애면 — 86% 가 닫히고 거기서 멈춘다

유보 예보의 순위를 유보 안에서 매기면 드리프트가 상쇄된다(라벨 쪽은 학습만 본다). 전이적이라 배치 채점에만 쓸 수 있고 그 한계를 결과 보기 전에 적었다.

OLS(학습 자에 묶임)	0.3269
유보 안 백분위(드리프트 상쇄)	0.1880
기후값	0.1656
차	+0.0224 씨앗 SD 3배 0.0275 안 — 비긴다

총 격차 0.1613 중 0.1389(86.1%)를 드리프트 제거가 닫았다. 남은 0.0224 가 정보 부족이고 그것은 기후값과 구분이 안 된다.

주장. 그래서 T6 판정선 30% 는 근거가 못 된다. 되돌림에 따라 41.95% ↔ 18.80% 로 움직이고 선을 하나는 넘고 하나는 안 넘는데 둘 다 기후값과 비긴다. 절대 자는 이름 붙인 기준선 없이 읽으면 판정이 뒤집힌다 — 규약 43.

반증 조건. 도메인 4/11 에서는 기후값을 이긴다 — 게임 0.547 대 0.644 · 아이돌 0.363 대 0.510 · 도서 0.175 대 0.209 · 애니 0.136 대 0.150. 전부 라벨이 넓은 도메인이다. 그러나 그 넷은 결과를 보고 고른 것이라 그대로 쓰면 체리피킹이다 — 다음 사전등록에서 IQR 문턱을 값으로 먼저 정하고 갈라야 한다.

6 그래도 하나는 팔 수 있다

도메인 구간(그 도메인 학습 라벨의 10~90분위)은 덮음 **0.8448** 로 이름값을 한다.
작품 구간(예보를 엮은 것)은 **0.40** 으로 무너진다.

serve/capability.py 를 고쳤다 — “그 도메인의 80% 구간”을 허용 끝로 올리고, “그 작품의 80% 구간”을 금지에 남기고, 자기 검사 문구가 둘을 이름으로 가르게 했다(12/12 통과).

주장. T6 이 처음으로 팔 수 있는 것을 하나 늘렸다. 노트 691 이후 이 트랙은 금지만 늘어 왔다. “이 도메인의 팝업은 80% 가 300~8,000명 사이입니다”는 정직한 문장이다 — 실측이 뒷받침한다.

반증 조건. 그리고 그 문장은 작품에 따라 안 움직인다. 쓸모가 작다는 뜻이고, 예보를 엮는 순간 거짓이 된다. 파는 쪽에서 그 경계를 지킬 수 있느냐가 남은 물음이고 그건 측정이 아니라 규율의 문제다.

그리고 IQR 가설이 맞았다

노트 691 의 예측 ②(자릿수 오차가 라벨 **자리폭**과 정렬한다)가 틀린 뒤 그 자료를 보고 만든 가설이다 — 자리폭이 아니라 **집중도(IQR)**다.

자릿수 오차와의 스피어만: **IQR** 0.727 ~ 0.909 대 자리폭 0.145 ~ 0.409 (되돌림 셋 전부)

주장. 사후 가설이라 같은 자료로는 판정 못 한다고 먼저 적었고, 기제가 내는 독립 예측을 대신 걸었다 — 자릿수 오차가 라벨 분포의 자라면 위약의 자릿수 오차도 IQR 과 똑같이 정렬해야 한다. 2/3 통과(등백분위 0.909/0.927 · 분위회귀 0.845/0.909 · OLS 0.727/0.900 은 차 0.173 로 미달).

반증 조건. 2/3 는 통과 기준을 내가 0.15 로 정한 결과다. 도메인이 11 개라 스피어만의 표준오차가 크고($n=11$ 에서 ρ 0.73 과 0.90 은 잘 안 갈린다), 이 시험은 약하다.