

IP 파운데이션 월드모델 연구 노트 171

일관성과 정확성이 같린다

걸음 불변 칸으로 정식화를 가를 수 있는지 물었다. 같린다 --- 그런데 일관성으로 세운 순위와 정확성으로 세운 순위가 정반대다

Sweetspot 월드모델 연구

2026년 7월 30일

초 록

노트 162가 “18칸으로는 정식화를 못 가른다”고 하고 노트 170이 걸음 불변 칸 28개를 만들었다. 가를 수 있다. 잣대를 바꾸면 같린다. 다섯 정식화에서 걸음 불변 칸의 비율이 78%~100%로 폭 0.222다 — 노트 162가 고른 상위절반(0.056)의 네 배이고, 36칸에서 $p \approx 0.9$ 의 2se(0.10)를 처음으로 넘는다. 판과의 순위상관이 -0.791이고 씨앗 순위 일치가 +0.973이다. 그리고 이 잣대는 라벨도 사전 부호도 안 본다 — “걸음을 바꿔도 같은 답을 내나”만 묻는다. 그런데 여기서 멈추면 안 된다. 같은 불변 칸에서 정확도를 재면 순위가 뒤집힌다 — F18 배경 · F8 부스팅이 93%이고 선형 셋이 75~89%다(판과 +0.564). 이걸 잣대가 아니라 조건화의 산물이다 — 트리는 불변 칸이 78%뿐이고 그 골라낸 28칸이 깨끗한 것이고, 선형은 100%가 불변이라 애매한 칸까지 다 들어간다. 분모가 다른 두 수를 견준 것이다. 분해하면 맞는다: 전체 정확도 = 불변비율 × 불변정확 + 흔들비율 × 흔들정확이고, F18은 $0.78 \times 0.93 + 0.22 \times 0.50 = 83\%$, F9 순위우도는 $1.00 \times 0.89 = 89\%$ 다. 읽는 법은 이렇다 — 선형은 고루 맞히고 트리는 몰아 맞힌다. 트리는 자기가 어느 답을 믿어도 되는지 알려 주는 대신(불변 28칸 93%) 나머지 8칸에서 동전이고, 선형은 전 칸에서 89%로 고르다. 둘 중 무엇이 나은지는 쓰임이 정한다 — 한 기획서에 답을 줘야 하면 트리의 “이 칸은 못 믿는다”가 값지고, 전 도메인 평균이 필요하면 선형이 낫다.

Table 1: 손잡이 잣대 넷. 폭 · 판과의 상관 · 씨앗 안정.

	폭	판상관	씨앗
단순	.139	-.667	+1.000
불변비율	.222	-.791	+.973
불변정확	.179	+.564	+.975
상위절반(노트 162)	.056	-.866	+1.000
2se(36칸)	.100		

Table 2: 정식화 다섯.

	판 ρ	불변비율	불변정확	전체
F18 배경	+.4491	78%	93%	83%
F8 부스팅	+.4341	78%	93%	83%
F10 도메인수축	+.3735	100%	75%	75%
F6 능형	+.3671	97%	89%	86%
F9 순위우도	+.3519	100%	89%	89%

Table 3: 분해. 전체 = 불변×정확 + 흔들×정확.

	불변에서	흔들에서	전체
F18 배경	.78×.93	.22×.50	83%
F6 능형	.97×.89	.03×.00	86%
F9 순위우도	1.0×.89	—	89%
F10 도메인수축	1.0×.75	—	75%

1. 불변비율은 가른다

주장 1. 불변비율이 처음으로 잡음을 넘는다. 폭 0.222가 36칸 2se 0.100의 두 배다. 노트 162가 고른 상위절반은 0.056으로 1se였다.

반증 조건. 게다가 이 잣대는 라벨도 사전 부호도 안 본다 — “걸음을 0.05에서 1.0까지 바꿔도 같은 부호를 내나”만 묻는다. 순환이 원천적으로 없다.

2. 그런데 정확도로 세우면 뒤집힌다

주장 2. 불변정확의 판상관이 +0.564다 — 다른 셋과 반대 방향이다. 트리 둘이 93%로 제일 높다.

반증 조건. 여기서 “역시 부스팅이 손잡이도 낫다”로 읽으면 안 된다.

주장 3. 조건화의 산물이다. 트리는 불변 칸이 78%뿐이라 골라낸 28칸을 채점하고, 선형은 100%가 불변이라 애매한 칸까지 36칸을 다 채점한다. 분모가 다른 두 수를 견준 것이다.

반증 조건. 노트 162가 상위절반을 고를 때 같은 합정을 피했었다 — 그때는 모든 정식화가 같은 18칸을 썼다. 이번엔 필터가 정식화마다 다르다.




Figure 1: 왼쪽 — 불변비율만 잡음을 넘는다. 가운데 — 일관성과 정확성이 반대로 간다. 오른쪽 — 트리는 몰아 맞히고 선형은 고루 맞힌다.

Table 4: 남은 것.

공통 칸	다섯 정식화가 다 불변인 칸으로 다시 재면
F10	100% 일관되게 75% — 무엇을 일관되게 틀리나
쓰임	기획서 한 건에 답할 때의 정확도를 따로 잴다

3. 선형은 고루, 트리는 몰아

주장 4. 트리는 자기가 어느 답을 믿어도 되는지 알려 준다 — 불변 28칸에서 93%, 나머지 8칸에서 50%(동전)다. 선형은 전 칸에서 89%로 고루다.

반증 조건. F10 도메인수축은 100% 불변인데 75%다 — 일관되게 틀릴 수도 있다. 일관성은 정확성의 보증이 아니다.

주장 5. 둘 중 무엇이 나은지는 쓰임이 정한다. 한 기획서에 답을 줘야 하면 “이 칸은 못 믿는다”는 정보가 값지고 (트리), 전 도메인 평균이 필요하면 고른 쪽이 낫다(선형).

반증 조건. 이 판의 순위표는 판 ρ 하나로 세우니 그 구분을 못 담는다. 노트 144 · 146 · 147 · 159 · 170 에 이어 여섯 번째로 같은 결론이다 — 한 숫자로는 못 담는다.

첫 줄이 공정한 비교다. 다섯 정식화가 모두 불변인 칸만 골라 채점하면 분모가 같아지고 조건화가 사라진다. 그 칸이 몇이고 거기서 순위가 어떻게 되는지가 다음이다.