

IP 파운데이션 월드모델 연구 노트 232

한 행이 도메인을 죽였다

노트 231이 기준선이 죽은 것을 찾고 가드를 세웠다. 왜 죽었는지는 안 봤다. 짐작 셋이 틀리고 넷째에서 계속했더니 하네스 한 줄이었다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 231이 “F1 이 아홉 도메인 중 여덟에서 죽었다”를 찾고 덮음 보고와 가드를 세웠지만 왜 죽었는지는 안 봤다. 봤다. 짐작 셋이 차례로 틀렸다. ① 완전사레 필터 — `_keep_rows` 를 그대로 적용하니 모든 축 판에서 8/10 도메인이 20행 이상 남는다. ② F1 내부 — 도메인별 분해와 쌍별 정렬이 두 축 판 모두에서 7~9개 출처에 성공한다. ③ 출처 부족 — 9/10 도메인이 출처가 된다(못 되는 것은 팝업 하나, 학습 16행). 넷째로 계속해서 찾았다: `scipy.rankdata` 의 기본 정책이 NaN 전파다. `rank.predictions` 가 예측 벡터에 `rankdata` 를 그대로 걸어서, 못 매기는 행을 정직하게 NaN 으로 돌려주는 정식화가 도메인 전체를 잃는다. 크기가 이렇다 — 웹툰은 711건 중 7건을 못 매겨서 711건을 다 잃는다. 애니 21/606 · 도서 2/163 · 팝업 5/59 도 마찬가지고, 살아남은 것은 버린 행이 정확히 0 인 편딩 하나였다. 노트 231이 본 “판 +0.1472” 가 바로 그 편딩 80건이다. 고쳤다 — `_rank_nan` 은 유한한 것만 순위 매기고 나머지는 NaN 으로 둔다. 부분 결측은 부분으로 남아야 `coverage` 가 무엇이 빠졌는지 적을 수 있다. 효과가 정확히 같린다: F1 이 1/9 도메인 (표본 80)에서 8/9(2,230)로 부활하고 판이 +0.1472 → +0.2447 인데, 살아 있던 것들은 소수 넷째 자리까지 안 움직인다(F21 +0.4321 · F18 +0.4523). 노트 187의 제일 값싼 검사를 반대로 쓴 것이다 — 거기서는 “안 움직이면 안 닿은 것”이었고 여기서는 “안 움직여야 맞는 것”이다.

Table 1: 차례로 확인한 것.

짐작	잔 것	
완전사레 필터	8/10 도메인이 20행 이상	×
F1 내부(정렬)	출처 7~9개 정렬 성공	×
출처 부족	9/10 도메인이 출처가 됨	×
rankdata NaN	한 행이 벡터 전체를	○

Table 2: trendcalwiki 에서 F1 이 못 매기는 행.

	유보	못 매김	결과
웹툰	711	7	711건 전부 잃음
애니	606	21	전부 잃음
모바일	441	178	전부 잃음
세계애니	300	91	전부 잃음
게임	180	6	전부 잃음
도서	163	2	전부 잃음
팝업	59	5	전부 잃음
편딩	80	0	살아남음

1. 짐작 셋이 틀렸다

주장 1. 짐작 셋이 차례로 틀렸다. 축이 늘수록 F1 이 죽는 것을 보고 “완전사레 필터가 조이는구나”로 읽었는데, 그 필터는 모든 축 판에서 8/10 도메인을 살려 둔다.

반증 조건. 노트 133의 규칙이 세 번 걸렸다 — 그리고 이번에는 판정치가 아니라 기전에 대한 짐작이었다. 노트 218이 “결론 옆에 적은 까닭이 결론보다 잘 틀린다”를 여덟 번째로 썼고 노트 225가 아홉 번째였는데, 한 노트 안에서 세 번은 처음이다.

는다(0.98%). 도서는 2건 때문에 163건을 잃는다(1.2%). 살아남은 것은 버린 행이 정확히 0 인 편딩 하나이고, 노트 231이 본 “판 +0.1472” 가 그 80건이다.

2. 한 행이 도메인 전체를 죽인다

주장 2. `scipy.rankdata` 의 기본 `nan_policy` 가 전파다. `rank.predictions` 가 예측 벡터에 그대로 걸어서 한 행이 NaN 이면 벡터 전체가 NaN 이 된다.

반증 조건. 웹툰은 711건 중 7건 때문에 711건을 다 잃

주장 3. F1 은 잘못된 것이 없다. 못 매기는 행을 NaN 으로 돌려주는 것은 정직한 설계다 — 완전사레 분해라 일부 행은 원래 점수가 없다.

반증 조건. 하네스가 그 정직함을 발했다. 부분 결측을 허용하지 않는 순위 함수가 “부분”을 “전무”로 바꿨다.

3. 고침




Figure 1: 왼쪽 — 못 매긴 행이 하나라도 있으면 전부 읽는다. 가운데 — 짐작 셋이 틀렸다. 오른쪽 — 고침이 달아야 할 곳에만 달는다.

Table 3: `_rank_nan` — 유한한 것만 순위.

	고침 전		고침 후	
	판	도메인	판	도메인
F1	+0.1472	1/9	+0.2447	8/9
F21	+0.4321	9/9	+0.4321	9/9
F18	+0.4523	9/9	+0.4523	9/9

231이 붙인 덮음 보고는 그 관행을 되살리는 것이지 새로 만드는 것이 아니다.

Table 4: 남은 것.

옛 수치	F1 을 인용한 노트가 둘(125 · 126)
F17	IndexError — 아직 안 봤다
같은 병	부분 NaN 을 내는 다른 정식화가 있다

주장 4. F1 이 1/9 도메인(표본 80)에서 8/9(2,230)로 부활하고 판이 +0.1472 → +0.2447 이다. 그리고 살아 있던 것들은 소수 넷째 자리까지 안 움직인다.

반증 조건. 노트 187의 제일 값싼 검사를 반대로 쓴 것이다 — 거기서는 “판이 안 움직이면 모형에 안 닿은 것”이 경고였고, 여기서는 “안 움직여야 맞는 것”이 확인이다. 고침이 달아야 할 곳에만 닿았다.

주장 5. F1 의 진짜 기준선은 +0.24~0.26 이다(base +0.2591 · trendcalwiki +0.2447). 여전히 포트폴리오 꼴찌이고, 그것이 노트 125의 결론과 맞는다 — 옛 파이 프라인이 도전자들에게 진다.

반증 조건. 다만 +0.1472 는 그 결론의 근거가 아니었다 — 그 수는 편당 하나였다. 결론은 맞았고 근거는 우연이었다.

첫 줄은 이미 값이 작아졌다. F1 을 실질적으로 인용한 노트는 125와 126 둘뿐이고, 노트 125는 덮음을 적었다 — 표에 도메인 수 8 이 있고 “F1 은 아이들을 채점하지 못한다”고 본문에 썼다. 그때는 8/9 로 살아 있었고 관행도 있었다. 그러니 이 사고는 “덮음을 안 적어서”가 아니라 “적던 것을 그만두서”다 — 노트 125 이후 죽이 셋 늘고 정식화가 열여섯 늘면서 표가 간소해졌고, 그 간소함이 기준선이 죽는 것을 백 노트 동안 가렸다. 노트