

바닥 검사가 아홉 중 여섯에서 틀린 답을 줬다 — 그리고 판에서 제일 높은 도메인은 위 0.36%다

월드모델 실험실

노트 382 · 2026년 8월 1일

초 록

노트 381이 “다른 도메인 균일 수집이 지금 제일 값이 크다”로 끝났다. 어느 도메인부터인지 정하려고 노트 375의 바닥 검사를 아홉 도메인에 돌렸다. 검사가 틀렸다.

노트 375는 최소÷1분위가 1에 가까우면 절단이라 했다. 그것이 잡는 것은 벽(급격한 단절)이지 바닥(그냥 낮은 데서 멈춤)이 아니다. 라벨이 아래쪽에 자연스럽게 물리는 도메인은 벽이 없어도 비가 1이 되고, 꼬리가 길면 한참 위에서 멈춰도 비가 0에 가깝다.

고친 검사는 관측 최소를 그 라벨의 자연 바닥과 견주는 것이다. 아홉 라벨이 전부 샘플(관심 수 · 리뷰 수 · 후원자 수 · 판매지수)이라 자연 바닥은 1이다. 그러면 판정이 아홉 중 여섯에서 뒤집힌다:

바닥까지 내려간다	애니 (1) · 모바일 (1) · 펀딩 (1)	—
멈춰 있다	웹툰 19 · 게임 82 · 만화 633 · 아이돌 772	
	도서 950 · 세계애니 19,533	

제일 큰 것을 걱정할 필요는 없었다. 무게 711로 판에서 제일 무거운 웹툰은 수집이 네이버 웹툰 요일별 연재작 전부 + 완결 아카이브라 사실상 전수조사다 — 최소 19는 우리가 자른 게 아니라 플랫폼에 그보다 낮은 작품이 없는 것에 가깝다. 바닥이 있다고 다 우리 잘못은 아니다.

게임은 우리 잘못이고, 바닥이 둘이다. `game_domain.top_appids` 가 스팀 검색을 `filter=topsellers` 로 걸고 앞에서 600건을 받는데, 같은 검색이 보고하는 전체가 167,368건이다 — 위 0.36%. 그 위에 `build()` 가 “리뷰 총계 50 미만은 라벨이 못 된다”로 한 번 더 자른다. 남은 것이 482행. 그리고 게임은 지금 판에서 제일 높은 도메인이다(+0.6040).

노트 379가 펀딩에서 같은 모양을 재니 도메인 점수가 4배 부풀어 있었다. 게임 균일 표본 2,000건을 모으는 중이다.

1. 검사가 왜 틀렸나

노트 375가 수집 편향을 셋으로 나눴다 — 절단(자연 바닥 위에 벽) · 구역 편향(바닥은 열렸는데 한 구역만 뿔다) · 열림. 절단의 검사로 최소÷1분위를 썼다. 그 비가 1에 가까우면 최소 바로 위에 1%가 몰려 있다는 뜻이고, 곧 벽이다. 벽과 바닥은 다르다. 두 가지로 어긋난다.

첫째, 자연스러운 물림을 벽으로 읽는다. 펀딩 라벨은 후원자 수라 1명짜리 프로젝트가 2.2%다. 최소도 1분위도 $\log_{10} 1 = 0$ 이라 비가 정확히 1이 되고 검사는 “절단”이라 답한다 — 그런데 이 도메인은 바닥까지 내려가 있다. 애니 (리뷰 1건) · 모바일(평점 1건)도 같다.

둘째, 긴 꼬리를 열림으로 읽는다. 웹툰은 최소 19 · 1분위 474 라 비가 0.040 이고 검사는 “열림”이라 답한다. 벽은 없다 — 그런데 19에서 멈춘다. 자연 바닥은 1이다.

고침은 견주는 상대를 바꾸는 것이다 — 1분위가 아니라 그 라벨이 가질 수 있는 제일 작은 값. 아홉 라벨이 전부 샘플이라 그 값은 1이다.




Figure 1: (가) 도메인별 관측 라벨 최소(원값, 로그축)와 자연 바닥 1. 초록 셋만 바닥에 닿는다. (나) 노트 375 판정과 고친 판정 — 아홉 중 여섯이 뒤집힌다. (다) 게임의 바닥 둘. 스텝 검색이 보고하는 167,368건에서 topsellers 앞 600을 받고, 다시 리뷰 50 미만을 잘라 482행이 남는다.

2. 바닥이 있다고 다 우리 잘못은 아니다

멈춰 있는 여섯을 하나씩 열어 보면 두 종류다.

모집단이 거기서 끝나는 것. 웹툰 수집은 `titlelist/weekday`(요일별 연재작 전부)와 `titlelist/finished`(완결 아카이브, 갱신일 순 60쪽)다 — 인기순으로 자른 데가 없다. 네이버 웹툰 정식 연재작에 관심 19 미만이 거의 없는 것은 우리 표본이 아니라 그 플랫폼의 성질이다. 무게 711로 제일 무거운 도메인이 여기 있는 것은 다행이다.

우리가 자른 것. 게임이 그렇고, 아래에서 따로 본다. 도서는 이미 알려진 베스트셀러 스크래피고(수집순↔라벨 -0.4652) 아이돌도 구역 편향이 같이 뜬다($+0.3513$). 만화 · 세계애니는 AniList 인기 순위 상위를 받은 것이라 파일이 라벨 순으로 정확히 정렬돼 있다(수집순 상관 -1.0000) — 그래서 이 둘에는 수집순 검사를 쓸 수 없다. 정렬된 파일에서 수집순↔라벨은 표본이 아니라 정렬을 쟀다. 노트 375의 두 번째 검사도 조건이 붙는다.

세계애니는 노트 376이 이미 답했다 — 바닥 아래를 받아 봤더니 신호가 $+0.0223$ 으로 없어서 안 넓혔다. 절단이 곧 고쳐야 할 것은 아니라는 반례가 이미 있다.

3. 게임 --- 바닥이 둘이고 둘 다 우리 것이다

	게임 수	자른 것
스텝 검색 전체	167,368	—
filter=topsellers 앞 600	600	위 0.36%
build(): 리뷰 총계 ≥ 50	482	반응 적은 것

두 선택 다 근거가 적혀 있다. 원본 주석이 “서블웨어를 피하면서 연도 분포도 얻는 방법이다 — 2024년 한 해에만 116,830개가 출시됐고 대부분은 반응 자체가 없다”고 쓰고, `build()` 는 “반응이 거의 없는 것은 라벨이 못 된다”고 쓴다. 둘 다 말이 되는 이유고, 이 노트는 그것을 뒤집지 않는다.

뒤집지 않는 대신 크기를 쟀다. 노트 379가 편딩에서 정확히 같은 모양 — 목록이 정렬돼 있고 우리는 앞을 떼다 — 을 재니 도메인 점수가 $+0.4195$ 에서 $+0.0866$ 으로 4.8배 부풀어 있었다. 게임은 지금 판매에서 제일 높은 도메인 ($+0.6040$)이고 무게 180이다.

서블웨어를 모집단에 넣을지는 과제를 바꾸는 결정이라 점수로 정하지 않는다(노트 224). 이 노트가 하는 것은 그 결정을 모르고 내리지 않게 하는 것뿐이다 — 지금은 아무도 정한 적 없이 기본값으로 되어 있다.

`ingest/game_sample.py` 를 새로 썼다. 씨앗 고정(20260801)으로 목록 전체에서 쪽을 뽑고, 리뷰 50 문턱은 여기서 안 자른다 — 두 바닥의 값을 따로 재려면 잘린 것도 받아 되야 한다(`below_old_cut` 으로 표시만 한다). 2,000 건 목표로 들고 있다.

4. 남은 것

항목	왜 값이 큰가	어떻게
게임 균일 2,000	판 최고 도메인이 위 0.36% 다	수집 중 · 노트 379 절차로 켄다
리뷰 50 문턱 따로	바닥이 둘이라 값도 둘이다	<code>below_old_cut</code> 으로 갈라 켄다
도서 · 아이돌	절단 + 구역이 겹친 둘	목록 구조부터 확인
정렬된 파일의 수집순	만화 · 세계애니에 검사가 안 통한다	수집 시각 등 다른 순서를 찾는다