

IP 파운데이션 월드모델 연구 노트 482

자와 판이 다른 시대를 산다

크롤 229시간을 태우기 전에 기울기를 켜다 --- 그런데 자를 판에 대 보니 3행이 겹쳤다. 그리고 「텍스트가 있다」는 이미 판의 열이었다

Sweetspot 월드모델 연구

2026년 8월 10일

초 록

판 ρ 가 400사이클 넘게 0.46-0.47 에서 평평한데 다음 블록의 계획은 광역 크롤이다(만화 전량 12.5h · 12도메인 34.4h · 댓글까지 229h). 직전 세 노트는 전부 “텍스트를 어디서 어떻게 굶나” 를 켜고 “텍스트가 들어오면 ρ 가 오르나” 는 한 번도 안 켜다. 그래서 크롤 전에 기울기를 켜다.

0단계가 실험을 두 번 바꿨다. ① 직전 노트의 자(만화 롱테일 220건)와 판의 유보(3,775행 · 12도메인)의 교집합은 3행이다 — 자는 전 연도 롱테일에서 왔고 판은 2025년 이후만 채점한다. 자와 판이 다른 시대를 산다. ② 요청 0 으로 유보에 닿는 용량을 다시 짓다가, 「문서가 있다」는 이미 판의 열이라는 것을 측정 전에 알았다 — 판은 촉마다 값 열과 관측 표시자 열을 함께 쓰고, 위키 축의 표시자가 곧 문서 존재다.

그래서 용량을 둘로 갈라 켜다(존재 이진 · 양). 관찰(팔 A)에서 존재는 죽고($\rho_A = -0.0097 \cdot$ 순열 널 $2\sigma = 0.0406 \cdot p = 0.607$) 양만 산다($+0.0692 \cdot$ BCa 95% 하한 $+0.0020 \cdot$ 상한 $+0.1368 \cdot$ 글자수 · 어절수 통제 후 $+0.0704$ 로 유지율 1.02). 그런데 개입(팔 B)에서는 둘 다 문턱 0.00353 을 못 넘는다 — 존재 $+0.00318$ (문턱의 0.90배) · 양 -0.00152 , 그리고 양은 세계애니 도메인에서 -0.015 로 되레 해롭다. 관찰에서 제일 센 도메인이 개입에서 제일 크게 손해를 본다.

그래서 크롤은 지금 근거가 없다. 다만 우리가 적을 말은 “텍스트는 쓸모없다” 가 아니다 — 이 자료는 이 판을 못 넘었다, 그리고 자가 재는 것이 텍스트가 아니라 텍스트의 대용값이다.

1. 0단계 --- 자를 판에 대 보니 3행이었다

조항 60 은 “두 수를 이어 붙일 때 분모가 같은지 확인하라” 다. 직전 노트의 자는 만화 220건(실물 200 + 음성 20)에서 만들어졌고 판의 유보는 3,775행 · 12도메인이다. 세어 봤다(그림 1 왼쪽).

895 정답지 실물	200
그중 manga_records(7,982) 안	200
그중 판의 만화 행(5,905) 안	141
그중 유보($258 \cdot t \geq 2025.0$) 안	3

원인은 시간축이다. 판의 만화 유보는 2025.02-2026.49 시작작이고, 자의 200 은 1958-2026 롱테일 표본이다(2025년 이후가 12건, 그중 판 행에 있는 것이 3건).

주장 1. 895 의 자와 판의 유보는 교집합이 3행이다 — 자를 그대로 열로 주입하는 설계는 산술적으로 불가능하다. 스피어만 최소 행수는 20 이다.

반증 조건. 만화 유보 258 중 895 표본에 든 것을 다시 세어 20행이 넘으면 이 주장은 죽는다. 반대로 자를 유보에서 다시 뽑으면 교집합이 정의상 258 이 된다.

이건 “기울기가 0” 이 아니라 “이 자료는 이 판을 못

켜다” 다 (조항 59). 만화 하나로 판 문턱 0.00353 을 넘으려면 만화 도메인 $\Delta\rho \geq 0.00353 \times 3775/258 = 0.0517$ 이 필요하다.

주장 2. 자를 지을 때 표본을 유보에서 뽑아야 한다. 895 는 롱테일 전 연도에서 뽑았고 판은 2025년 이후만 채점한다.

반증 조건. 유보에서 뽑은 표본으로 같은 자를 다시 세웠는데도 판 $\Delta\rho$ 가 문턱을 못 넘으면, 못 넘는 원인은 표본이 아니라 자다.

2. 용량은 하나가 아니다 --- 그리고 하나는 이미 판 안에 있었다

직전 사이클의 티처가 확정한 것: 양(바이트)은 아무것도 안 더한다. 존재 이진이 바이트보다 낮다(0.5365 대 0.5291). 그래서 이번엔 존재와 양을 갈라 켜다.

요청 0 으로 유보에 닿는 것을 전수 조사했다. 용량 $\neg$ 존재 이진은 위키 문서 캐시(`page≠null`)에서 7도메인 2,502행, 용량 $\neg$ 양은 설명문 글자수(세계애니 300 + 편당 529)다. 만화는 둘 다 못 쓴다 — 위키 캐시가 유보 258 중 6개뿐이고 설명문도 6개다. □ 그 6은 “위키에 없다” 가 아니라 “안 봤다” 다.

그리고 측정 전에 하나를 알았다. `forms.py` 의 `_feat` 는 촉마다 값 열과 관측 표시자 열을 함께 낸다. `wikiaxes`

노트 896 — 자와 판이 다른 시대를 산다




Figure 1: 왼쪽: 자가 판에 닿는 데까지 200이 3으로 준다. 가운데: 팔 A — 존재는 도메인마다 부호가 갈려 회색 띠(순열 널 2σ) 안에서 놓고, 양만 한쪽으로 선다. 오른쪽: 팔 B — 신호 몫이 둘 다 문턱(붉은 파선)을 못 넘고, 잡음 바닥(점선)의 30%와 -14% 자리에 있다.

는 문서를 못 찾은 행의 마스크를 0으로 준다. 그러면 「위키 문서가 있다」는 이미 판에 표시자 열 셋으로 들어가 있다.

주장 3. 용량 γ 의 개입 팔은 새 정보 검정이 아니라 중복 검정이다. 이것을 사후에 발견해 “모형이 이미 갖고 있다”고 주장하면 사후 선택이 된다 — 그래서 사전등록에 예측 P3로 미리 박았다.

반증 조건. 위키 죽을 base에서 빼고 같은 존재 열을 주입했을 때 판이 오르면 ‘중복’이 아니라 ‘표시자 열이 열등하다’가 맞는 말이 된다 — 이 사이클은 그걸 안 잤다.

3. 팔 A --- 존재는 죽고 양만 산다

반응은 행별 오차다: 씨앗 0-5 순위 양상블로 $e_i = |\text{rank}(p_i)/n - \text{rank}(y_i)/n|$. 통계는 도메인 안 $\rho_A = \text{Spearman}(\text{용량}, -e)$ 를 행수로 가중한 것이고, 널은 문턱 0.00353이 아니라 도메인 안 용량 라벨을 1,000회 순열해 다시 잤다(그 팔의 2σ 는 존재 0.0406 · 양 0.0703으로 문턱의 11.5배 · 19.9배다 — P4 적중).

	γ 존재	γ 양
행 수(통계에 든 것)	2,398	829
ρ_A 무통제	-0.0097	+0.0692
순열 널 2σ	0.0406	0.0703
순열 널 양측 p	0.607	0.045
BCa 95%	[-0.050, +0.033]	[+0.002, +0.137]
+글자수+어절수	-0.0126	+0.0704
판정	판정 불능	승

주장 4. 존재는 도메인마다 부호가 갈린다 — 도서 +0.088 · 모바일 +0.062 · 게임 +0.039 · 세계애니 +0.036 · 애니 -0.082 · 시장팝업 -0.061 · 웹툰 -0.048. 모아서 -0.0097이고 순열 널 안이다.

반증 조건. 도메인을 늘리거나 만화·편딩의 위키 덮음을 메운 뒤 다시 재서 $|\rho_A|$ 가 순열 널 2σ (0.0406) 밖으로

나오면 이 ‘판정 불능’은 표본 부족이었다는 뜻이다.

주장 5. 양은 통제 뒤에도 산다 — 글자수·어절수를 넣어도 +0.0692 → +0.0704 (유지율 1.019). P2(“통제하면 절반 이하로 준다”)는 틀렸다. 직전 노트의 실측(64-86% 유지)이 맞았고 우리 예측이 틀렸다.

반증 조건. 인기·완결 여부·태그 수처럼 판이 이미 가진 열을 통제에 더 넣었을 때 ρ_A 가 순열 널 안으로 들어가면, 이 상관은 텍스트가 아니라 레코드 충실도의 대응이었다.

□ 팔 A는 인과가 아니다. 그리고 원산국 통제는 원천이 세계애니뿐이라 한 도메인이다 — “가중 편상관”이라 부르면 조항 60 위반이라 분모를 병기했다.

4. 팔 B --- 관찰에서 제일 센 도메인이 개입에서 제일 크게 잃는다

개입은 표준 관례다: 도메인 안 백분위 1열 주입 · 값만 섞은 널 팔 3뿔기 · 씨앗 6 짝. □ 배선 검사를 주입 뒤 Data를 열어 도메인마다 했다(887은 12도메인 중 아이돌만 조용히 중립화됐다). 887형 중립화 0전이고, 채택 안 한 도메인은 마스크 0으로 등록된 배제다.

	γ 존재	γ 양
기준선 판	0.46917	0.46917
진짜 판	0.46846	0.46837
널 평균	0.46529	0.46989
신호 몫	+0.00318	-0.00152
순효과	-0.00071	-0.00080
씨앗 짝 BCa 95%	[+0.0015, +0.0052]	[-0.0034, -0.0002]
문턱 0.00353	못 넘음(0.90배)	못 넘음
잡음 바닥 0.01055	0.30배	-0.14배

주장 6. 두 용량 다 이 자를 못 넘었다. 존재는 신호 몫이 문턱의 0.90배이고 순효과가 음수다 — 즉 진짜 열은 기

준선을 낮추고, 섞은 열보다 덜 낮출 뿐이다. 양은 신호 몫이 음수이고 씨앗 짝 구간 상한이 0 아래다.

반증 조건. 널 뽑기를 셋에서 열둘로 늘리고 씨앗을 6에서 12로 늘렸을 때 존재의 신호 몫이 0.00353 위로 올라가면 이번 미달은 뽑기 잡음이었다.

주장 7. □ 관찰과 개입이 정면으로 어긋난다. 팔 A에서 제일 센 도메인이 세계애니($\rho_A = +0.156$)인데 팔 B에서 세계애니 순효과가 -0.015 로 제일 크게 손해다. 상관은 있는데 열로 주면 해롭다 — 반증 조건 F2 발화: 모형이 이미 그 정보를 다른 열로 갖고 있다. 크롤은 중복이다.

반증 조건. 설명문 본문을 열로 넣었을 때(글자수가 아니라 내용) 세계애니 $\Delta\rho$ 가 양수로 뒤집히면, 중복인 것은 '텍스트'가 아니라 '글자수'다.

□ 씨앗 짝 BCa는 씨앗 재표집이라 행 잡음이 안 들어간다. 그리고 널 뽑기가 셋뿐이라 널 폭(존재 0.00204)이 신호 몫의 64%다 — 구간을 액면 그대로 믿지 않는다.

5. 이 사이클이 정하는 것

주장 8. 광역 크롤(12.5–34.4h, 댓글까지 229h)은 지금 근거가 없다. 텍스트 용량의 대용값 둘이 판을 문턱만큼 못 움직였고, 관찰에서 산 쪽은 개입에서 되레 해로웠다. 다만 이건 “텍스트를 넣으면 안 오른다”가 아니라 “텍스트가 있다/없다는 사실만으로는 안 오른다”다 — 본문은 아직 한 번도 안 넣어 봤다.

반증 조건. 파일럿 200건(0.3h)으로 본문을 굵어 열로 넣었을 때 만화 $\Delta\rho \geq 0.0517$ 이 나오면 크롤에 근거가 생긴다 — 그 수는 이 노트가 0단계에서 계산해 뒀다.

주장 9. 다음 자는 유보에서 표본을 뽑아야 하고, 만화의 위키·설명문 덮음(258 중 6)을 먼저 메워야 어떤 자도 만화를 못 켜다.

반증 조건. 만화 유보 258에 위키·설명문을 채운 뒤에 ρ_A 가 순열 널 안이면, 만화가 안 잡히는 이유는 덮음이 아니라 도메인 자체다.

6. 자가 적발

주장 10. □ 초판 팔 A가 게임과 웹툰을 조용히 중립화했다. `scipy 1.13`의 `rankdata`는 배열에 NaN이 하나라도 있으면 전부 NaN을 낸다 — 라벨 결측이 게임 43건·웹툰 61건 있어서 두 도메인의 오차가 통째로 NaN이 됐고, “채택 도메인” 목록에 이름은 남은 채 통계에는 한 행도 안 들어갔다. 887행 중립화의 통계 판본이다. 유한한 행 안에서 순위를 다시 내도록 고쳤고 ρ_A 가 $+0.0006 \rightarrow -0.0097$ 로 바뀌었다(판정은 불변 — 둘 다 널 안). 회계 칸(“통계에 실제로 든 행”)을 산출물에 새로 박았다.

반증 조건. 저장소에서 `rankdata`를 거르지 않고 부르는 다른 자리를 세어 0이 아니면 같은 병이 더 있다 — 이 노트는 그것을 안 썼다.