

IP 파운데이션 월드모델 연구 노트 484

자가 두 개였다 --- 판과 자가 서로 다른 스피어만을 쓰고 있었다

동물을 배열 순서로 깨는 통계량은 통계량이 아니라 정렬의 함수다. 행을 섞으면 12/12 도메인에서 값이 같았다

Sweetspot 월드모델 연구

2026년 8월 10일

초 록

이 실험실의 모든 판정은 한 문장으로 끝난다 — “판 Δ 를 채택 문턱에 댄다.” 그 문장이 성립하려면 판과 문턱이 같은 자로 재져야 한다. 안 그랬다.

판(`state/rank_test.py`)은 스피어만을 `argsort(argsort(v))` — 서수 순위로 켜다. 동물을 배열 순서로 켜다. 자(`runners/ruler890.sp · thresh891` 전량)는 처음부터 동물 평균(`midrank`)이었다. 둘은 동물이 없을 때만 같은 물건이다.

동물은 예외가 아니었다. 챔피언의 예측은 자루 순위 평균이라 같은 값이 흔하다 — 시장팝업은 채점행 126개에 예측 고유값이 15, 영화는 406개에 139뿐이다.

그래서 판 ρ 가 자료의 정렬에 의존했다. 같은 (예측, 라벨) 짝을 스무 번 섞기만 해도 옛 함수는 12/12 도메인에서 값이 같았고 폭이 최대 0.15616 였다. 동물 평균은 0/12 · 폭 정확히 0 이다.

어느 쪽이 큰지 보기 전에 골랐다. 사전등록한 규칙은 크기가 아니라 원칙이다 — 통계량은 행 순서에 의존하면 안 된다. 그 규칙이 같았고, 결과로 정본이 0.46982 $\rightarrow$ 0.47034 로 옮겨갔다(12씨앗 짝 $\Delta + 0.00051922 \pm 0.00003993$, 군집 BCa [+0.00044, +0.00059], 12/12 양수). 개선이 아니라 편의 제거다 — 서수는 동물에서 순위를 무작위로 갈라 상관을 아래로 끈다.

움직인 것은 사실상 한 도메인이다. 시장팝업이 판 기여의 98.4% 다. 그리고 동물이 많다고 움직이는 게 아니다 — 영화는 동물 비율이 65.8% 인데 판 기여가 $+1 \times 10^{-5}$ 다. 문제는 비율이 아니라 동물 블록의 크기다.

그리고 직전 사이클의 진단을 뒤집는다. 이슈 #112 는 옛 값과의 차를 “적합 함수가 GBM 씨앗을 갈아 끼운다”로 설명했다. 물리적으로 불가능하다 — 자루마다 그 값이 자루 색인으로 덮인다(실측: 7 을 넣었는데 자루 32개가 0, 1, ..., 31). 진짜 원인은 이 논문이 고친 그 스피어만이다. 숫자는 맞았고 이름이 틀렸다: +0.00052 라는 크기는 정확했는데 그것이 잔차에 붙인 이름이었다.

자는 안 움직였다 — 문턱을 짓는 두 성분이 처음부터 동물 평균이었다. 반대로 통일했다면 문턱이 +2.8% 커졌을 것이다. 못 켜 것도 적는다: 행 군집 자료는 이 Δ 가 판정 불능이고, 그 자에는 편향이 있다 — 재표집이 동물을 스스로 만든다.

경로	순위 함수	자리
챔피언 판정	서수	<code>rank_test.py:44</code>
자 (890 · 891)	동물 평균	<code>ruler890.py:59</code>
837 재적합	동물 평균	<code>refit112.py:48</code>

Table 1: 판과 자가 다른 함수를 쓴다. 세 경로 중 판만 서수다.

주장 1. 판과 자가 서로 다른 스피어만을 쓰고 있었다. 그래서 이 실험실의 판정 문장 — “판 Δ 를 문턱에 댄다” — 은 두 개의 자를 섞어 대는 문장이었다. 문턱을 짓는 `thresh891` 은 씨앗 성분도 행 성분도 전부 동물 평균으로 계산한다.

반증 조건. `rank_test.spearman` 을 부르는 경로가 챔피언 채점(`harness.py:267`) 말고 문턱 계산 쪽에도 있으면 이 주장은 약해진다. 전수 `grep` 으로 세었고 `thresh891` 의 다섯 통계는 전부 `ruler890.sp` 를 지난다.

1. 두 개의 자

1.1 배선을 먼저 켜다

측정 전에 저장소에서 스피어만을 부르는 자리를 전수로 세었다.

1.2 동물은 예외가 아니다

그림 1(a). 채점행 3,775개를 도메인별로 갈라 예측의 고유값 수를 세었다. 시장팝업은 126행에 15개, 영화는 406행에 139개다. 나머지 열 도메인은 동물 비율이 0.011 ~ 0.043 이다.




Figure 1: (a) 도메인별 동물 비율. (b) 12쌍의 전향의 짝 Δ — 두 팔이 같은 적합·같은 예측을 공유하므로 완전 짝이다. (c) 판 기여 Δ 를 10^{-4} 단위로. 값은 전부 산출물 json 에서 읽었다.

2. 그래서 무엇이 깨졌다

2.1 판 ρ 가 자료의 정렬에 의존했다

사전등록한 첫 규칙이 이것이었다: 측정 러너가 도메인마다 (예측, 라벨) 짝을 스무 번 섞어 두 함수로 ρ 를 재고 값의 가짓수를 센다.

주장 2. 옛 판 ρ 는 통계량이 아니라 정렬의 함수였다. 서수 순위는 12/12 도메인에서 값이 같았고 폭이 최대 0.15616 다. 동물 평균은 0/12 이고 폭이 정확히 0 이다(그림 2a).

반증 조건. 한 도메인이라도 동물 평균에서 값이 같으면 이 주장은 틀린다. 반대로 서수가 어느 도메인에서도 안 같으면 그 도메인엔 동물이 없다는 뜻이고, 그때는 두 함수가 같은 물건이다.

2.2 판정은 크기를 보기 전에 정해 두었다

사전등록 문서(측정 전 커밋 6373373c1 · 21:55:49)에 원칙 셋과 규칙 다섯을 적었다. 규칙 R-4 가 명시한다 — “어느 쪽이 큰가는 판정에 안 쓴다. 정본이 얼마나 옮겨지는지는 결과로만 보고한다.” 팔 B 를 못 고르는 실패 조건도 하나만 미리 적었다: 887형 중립화 (midrank 가 NaN 하나로 열을 통째 NaN 으로 만드는 경로). NaN 을 심어서 확인했고 — 마스크 없이는 실제로 nan 이 나온다 — harness.py:265 의 ok 마스크가 막는다. 발화하지 않았다.

3. 그 결정이 정본을 얼마나 옮기나

두 팔은 같은 적합·같은 예측 벡터를 공유한다. 채점 함수만 다르므로 완전 짝이고, 씨앗마다 한 번만 적합했다.

주장 3. 정본이 0.46982 $\rightarrow$ 0.47034 로 옮겨간다. 짝 Δ +0.00051922 · 12/12 양수 · 씨앗 짝 BCa 가 0 을 안 묻다. 새 SE 의 0.86 배 · 채점 문턱의 0.147 배다. 개선 주장이 아니다 — 서수는 동물에서 순위를 무작위로 갈라 상관을 아래로 끄는 편의가 있었고, 그 편의를 뺀 것이다. 손잡이가 아니라 통계량의 정의가 바뀌었으므로 “첫 양수를 채택하지 않는다”는 조항의 대상이 아니다.

팔 A (서수 · 옛 정본)	0.46982330 $\pm$ 0.0020371
팔 B (동물 평균 · 새 정본)	0.47034252 $\pm$ 0.0020895
짝 Δ (12쌍)	+0.00051922 $\pm$ 0.00003993
$\Delta > 0$ 인 씨앗	12 / 12
씨앗 짝 BCa 95%	[+0.00044404, +0.00059359]
행 군집 BCa 95%	[-0.00290, +0.00342]

Table 2: 12도메인 · 유보 3,775 · 씨앗 0–11. 팔 A 는 챔피언 경로의 기록값을 5.6×10^{-17} 안에서 재현한다.

반증 조건. 도메인 기여의 합이 짝 Δ 와 안 맞으면(실측 차 1.8×10^{-17}), 또는 팔 A 가 챔피언 기록값을 10^{-12} 안에서 재현하지 못하면 배선이 다른 것이다.

3.1 못 쥔 것을 못 쥔다고 적는다

행 군집 BCa 는 판정 불능이다([−0.0029, +0.0034]). 그리고 그 자에는 편향이 있다 — 행을 재표집하면 동물이 새로 생기고, 이 논문이 재는 대비가 바로 동물 처리이므로 폭이 위쪽으로 부른다. 노트 890 이 이미 자기 코드 주석에 그 사실을 등록해 두었다.

주장 4. “행이 달랐다면 두 정의가 같았을까”는 아직 모른다. 씨앗 짝 자는 승이라고 말하고 행 군집 자는 판정 불능이라고 말한다. 둘 다 적는다. 결정은 어느 쪽 자에도 안 걸려 있다 — 원칙으로 골랐기 때문이다.

반증 조건. 재표집이 만든 동물과 자료가 원래 가진 동물을 가르는 자를 만들면 이 칸이 채워진다. 이 사이클에 서는 안 만들었다.

3.2 움직인 것은 사실상 한 도메인이다

그림 1(c). 시장팔업 하나가 판 기여의 98.4% 다. 아이돌이 10.2%, 펀딩이 −18.7%(유일하게 반대로 간다), 나머지 아홉은 합쳐서 1% 미만이다.

주장 5. 동물이 많다고 움직이는 게 아니다. 영화는 동물 비율이 65.8% 인데 판 기여가 $+1.1 \times 10^{-5}$ 로 사실상 0 이다. 시장팔업(88.1%)과 갈리는 것은 비율이 아니라




Figure 2: (a) 행을 스무 번 섞었을 때 나온 ρ 의 폭(로그 축). 동물 평균은 정확히 0 이라 그려지지 않는다. (b) 두 순위 함수 아래의 채점 문턱.

동물 블록의 크기다 — $126/15 = 8.4$ 대 $406/139 = 2.9$. 무작위 타이브레이크가 상관을 끄는 정도는 블록 안에서 섞이는 순위의 수에 달렸다.

반증 조건. 블록 크기가 비슷한데 기여가 크게 다른 도메인 짝이 나오면 이 설명은 부족하다. 현재 열두 도메인으로는 블록 크기가 큰 사례가 둘뿐이라 표본이 둘이다.

4. 잔차의 크기는 맞았고 이름이 틀렸다

옛 정보와 그 이전 값의 차를 12씨앗 전량으로 갈랐다. 네 조합을 따로 적합해 갈랐다 — 직전 사이클은 도메인을 갈라 잔차에 이름을 붙였고, 그 분해는 구성상 항등식이라 검증이 아니었다(그 러너가 자기 파일에 그렇게 적어 두었는데 인쇄물은 그 단서를 떼고 단정했다).

$$\underbrace{+0.00117370}_{\text{총}} = \underbrace{+0.00065447}_{\text{채점 배치}} + \underbrace{+0.00051922}_{\text{스피어만 구현}}$$

합 계산은 정확히 0 이고 두 성분 모두 12/12 씨앗에서 양수다. 첫 항은 노트 855 가 적어 둔 $+0.00065$ 와 소수 다섯째 자리까지 같다. 둘째 항의 크기도 직전 사이클이 적은 값과 같다. 틀린 것은 그 크기가 아니라 그것에 붙인 인과였다.

주장 6. ‘적합 함수가 GBM 씨앗을 갈아 끼운다’는 기전은 물리적으로 불가능하다. 자루마다 그 값이 자루 색인으로 덮인다. 일부터 어긋나게 주고(7) 자루를 찍으니 $0, 1, \dots, 31$ 이었다. 그 인과가 여덟 자리에 인쇄돼 배포됐고, 진짜 원인은 오늘의 정보 자신의 결합이었다.

반증 조건. 자루의 `random_state` 가 주입한 값과 같게 나오면 이 주장은 틀린다. 단, 같은 함수가 설정하는 다른 속성(자루 부트스트랩 `rng`)은 무연산이 아니고, 그것은 양쪽 경로가 똑같이 한다.

정정 표시.. 이 절이 인용하는 0.4710 은 837 시대 값이고 판정에서 내려온 수다. 837 규약(라벨 배치 채점 + 동물 평균)으로는 오늘도 재현되지만(0.4709970), 챔피언 규약으로는 안 나온다. 이 논문에서 그 수는 분해의 대상으로만 쓰이고 어떤 판정에도 안 들어간다.

	씨앗	행 짝	문턱
동물 평균	0.00099	0.00146	0.0035242
서수	0.00105	0.00148	0.0036223

Table 3: 성분은 다섯째 자리까지 기존 값을 정확히 재현한다.

5. 자는 움직였다

사전등록에 반증 가능한 예측으로 적었다 — “문턱을 짓는 두 성분이 전부 동물 평균이므로 팔 B 는 문턱을 안 움직인다.” 문턱 러너의 적합 캐시를 읽기만 해서(재적합 0회) 같은 난수·같은 뽑기 순서로 두 함수를 돌렸다.

주장 7. 팔 B 는 자를 안 움직인다 — 자는 처음부터 동물 평균이었다. 반대로 서수로 통일했다면 문턱이 $+2.8\%$ 커진다($0.0035242 \rightarrow 0.0036223$). 즉 이 선택은 판만 옮기는 것이 아니라 어느 쪽으로 통일하느냐에 따라 문턱도 움직였을 선택이었다.

반증 조건. 문턱 러너의 다섯 통계 중 하나라도 서수 함수를 지나면 이 주장은 틀린다. 캐시를 읽어 두 함수로 각각 다시 계산했고 동물 평균 쪽이 기존 성분을 재현했다.

결 발견 --- 문턱은 반올림한 수로 지어져 있었다.. 인쇄된 문턱 0.00353 은 다섯 자리로 반올림한 성분을 $2\sqrt{a^2 + b^2}$ 에 넣어 나온 값이다(0.0035280). 반올림 없이는 0.0035242 다. 차 4.0×10^{-6} 로 어떤 판정도 안 바뀌고 방어 대역 안이지만, 판정을 가르는 상수가 반올림한 입력 위에서 있었다는 사실 자체가 기록될 값어치가 있다.

6. 한계

- 행 군집 자는 판정 불능이고 편향 방향이 알려져 있다. 편향 없는 행 자를 안 만들었다.
- 같은 함수를 쓰는 다른 열여덟 모듈의 산출물을 다시 안 돌렸다. 그 값들은 전부 서수 시대의 수다.
- 옛 함수는 비유한 값을 맨 뒤로 밀어 조용히 숫자를 냈다. 새 함수는 막는다 — 그 가드가 열여덟 모듈 중 어디서 발화하는지 안 세었다. 발화하는 곳이 있으면 그건 원래 틀린 값이었다는 뜻이다.
- 블록 크기 설명의 표본이 둘이다(시장팝업 · 영화).
- 정보를 나르는 자리 일곱 곳은 다른 작업자가 동시에 만지는 파일이라 내가 못 고쳤다. 정보 대조기가 설계대로 소리를 냈고 이슈로 열었다.