

IP 파운데이션 월드모델 연구 노트 500

「무관 배경」은 배경이 아니라 도메인 이름표였다

상태 s 를 세 층으로 갈라 한 층씩 붙여 재니, 이득의 전부가 도메인 사이에 있었다

Sweetspot 월드모델 연구

2026년 8월 13일

초 록

이 실험실의 상태 s 는 오래 채널 하나였다 — 학습쌍 1,063개 전부에서 s 는 「액션 앞 90일 일별 위키 조회수」다. 사용자 지시는 그것을 셋으로 가르라는 것이었다: ① 개체 자신 · ② 물리 장(서울 생활인구 250m 격자 · 19개월 · 8.5GB) · ③ 무관 배경(같은 도메인 · 같은 날짜의 무관한 개체 N_p 개의 평균 대비 편차). 한 층씩 붙이며 $\Delta\rho$ 를 잰다. 층 ②는 판정 불능이다 — 격자에 실제로 붙는 쌍이 47이고 그중 층 ①·③이 다 있는 것이 39(서로 다른 격자 21)이라, 이 표본에서 가를 수 있는 최소 효과가 $\Delta\rho 0.2843$ 이다. 층 ③은 합산에서 $+0.0598$ 로 문턱 0.0452 를 넘는다. 그런데 도메인별로 가르면 아홉 중 하나도 문턱을 못 넘고 쌍 가중 도메인 안 평균은 $+0.00163$ 이다. 도메인 지시자를 ① 옆에 넣으면 그 지시자 자신이 $+0.0876$ 을 벌고 그 위에서 ③은 -0.0075 (빼는 칸)로 죽는다. 즉 「무관 배경」은 그 시기의 배경을 걷어낸 것이 아니라 도메인 규모의 대리변수였다. 텀으로, 우리가 900노트 동안 써 온 문턱 0.00353 은 이 자에서 12.8~80.5배 작아 쓸 수 없었다 — 문턱은 자와 함께 와야 한다.

1. 물음과 자

물음은 사용자의 것이다 — 「state 라는 게 단순히 몇몇 정보가 아니라 그 시기의 관련상황, 혹은 아예 관련없는 상황까지 다 종합되어 나오는 정보들이 반영되어야.」 그 말을 실험으로 옮기면 층을 하나씩 붙이며 예측력이 오르는지이다.

자는 ρ_{sao} — 능형회귀의 교차검증 밖(OOF) 스피어만이다. 겹은 개체로 묶어 같은 개체가 훈련과 시험에 함께 서지 않게 했고, 씨앗 10개의 평균을 값으로 삼는다. 표적은 들림 $y = \log_{10}(1 + \bar{o}_{0:14}) - \log_{10}(1 + \bar{s}_{-14:})$ 다. 수준값($\log_{10}(1 + \sum o)$)을 안 쓴 이유는 측정 전에 적어 두었다 — s 의 자기상관이 그것을 $\rho 0.9334$ 로 이미 맞춰 천장에 붙기 때문이다.

주장 1. 판 ρ 의 문턱 0.00353 은 이 자에서 쓸 수 없다. 짝지은 군집 부트스트랩 2,000회로 잦 SE($\Delta\rho$) 가 팔 B 에서 0.0226, 팔 A 에서 0.1421 이다. 사전등록한 $T = \max(0.00353, 2SE)$ 는 네 자리 전부에서 2SE 가 이겼다 (12.8배~80.5배).

반증 조건. 같은 자에서 $2SE < 0.00353$ 이 되면 이 주장은 죽는다 — 팔 B 를 쌍 ~41,000 규모로 키우면 그렇게 된다.

2. 층 ② --- 자료는 있고 표본이 막는다

서울 생활인구는 19개월치(2025-01~2026-07)가 이미 디스크에 있었고 쓰는 쌍은 0개였다. 압축을 풀지 않고 쓸 격자 23개의 줄만 뽑아(468,017행) 붙였다. 붙는 쌍은 47, 층 ①·③이 다 있는 것이 39, 서로 다른 격자가 21.

주장 2. 층 ②는 이 표본에서 원리상 판정 불능이다. $\Delta\rho = +0.0701$ 이고 $T = 0.2843$ · 부트스트랩 95% 구간이 $[-0.2710, +0.3007]$ 이다. 「안 들었다」가 아니라 「못 가른다」로 적는다.

반증 조건. 쌍을 늘려 $T < |\Delta\rho|$ 가 되면 판정이 생긴다. 지금 좌표가 있는 개체는 133뿐이므로 다음 걸음은 생활인구를 더 깊이 읽는 것이 아니라 좌표를 늘리는 것이다.

배선은 심은 열로 확인했다 — ② 자리에 y 에서 만든 열 하나를 넣으면 ρ 가 $-0.0257 \rightarrow +0.5529$ 로 오른다. 모형은 열을 받을 수 있다. 이 검사는 결론의 동어반복이 아니다: 「장이 든다」가 거짓이어도 통과해야 하는 검사이고, 이것이 붙었다면 위 문장을 쓸 자격이 없었다.

3. 층 ③ --- 이득이 어디에 있었다

합산(464쌍)에서 ρ 는 0.6400 $\rightarrow$ 0.6998, $\Delta\rho = +0.0598$ 로 문턱 0.0452 를 넘고 부트스트랩 95% 구간 $[+0.0180, +0.1064]$ 가 0을 안 묻다. 그런데 사전등록한 채택 조건 셋 중 라벨 순열 바닥(상위 5% = 0.0891)을 못 넘어 채택하지 않았다. 그리고 더 중요한 것이 도메인별 표에 있었다.

주장 3. 층 ③의 이득은 도메인 사이의 것이다. 도메인 아홉 중 문턱을 넘는 도메인이 0이고, 쌍 가중 도메인 안 평균 $\Delta\rho$ 가 $+0.00163$ 이다(합산 $+0.0598$ 의 2.7%). 도메인 지시자를 ① 옆에 넣으면 지시자 자신이 $+0.0876$ 을 벌고 그 위에서 ③은 -0.0075 ($T = 0.0066$ · 빼는 칸)다.

반증 조건. 어느 한 도메인 안에서 $\Delta\rho > T$ 가 나오면 이 주장은 좁아진다. 표는 그 반대를 보인다 — 음수 넷 · 양수 넷 · 전부 $\pm 2SE$ 안.




Figure 1: 왼쪽 — 도메인 안에서는 아홉 중 아무 데도 안 든다(가로선 $\pm 2 \cdot SE$). 빨간 네모가 합산이다. 가운데 — 도메인 지시자를 먼저 넣으면 층 ③은 음수 칸으로 내려간다. 오른쪽 — 빌려온 문턱과 이 자가 실제로 가를 수 있는 최소 효과(로그 축).

그래서 층 ③은 설계 의도대로 작동하지 않았다. 의도는 「그 시기 전반이 올랐는지」를 걷어내는 것이었고, 실제로 한 일은 「이 개체가 어느 도메인 크기에 사는지」를 알려 준 것이다. 도메인 이름표는 열 하나로 더 싸게 살 수 있다.

4. 재현성 --- 같은 코드가 다른 수를 냈다

같은 러너를 15분 간격으로 두 번 돌렸는데 수가 움직였다(Δp 0.0591 → 0.0598 · 도메인 안 평균 0.00025 → 0.00163). 그 사이 상시 수집 데몬이 배경 곡선의 원천인 위키 일별 파일 열한 개를 다시 썼기 때문이다. 판정 칸은 안 바뀌었지만 「같은 코드 · 같은 명령 → 같은 수」가 거짓이었다. 데몬을 재우고 정보 주행을 다시 돌렸고, 코드 해시만 박던 자리에 입력 해시를 같이 박았다. 재현 가능성은 코드의 성질이 아니라 코드와 입력의 짝의 성질이다.

5. 한계

생활인구는 서울만이고 2025-01부터라 답론 코퍼스(2012-2023)와 안 겹친다. 「그 격자의 사람이 그 팝업 때문에 왔는가」는 이 자료로 원리상 못 가른다 — 생활인구는 거주지 기반 추정이라 방문 목적이 없다. 층 ③의 「무관」은 같은 도메인으로 좁게 정의했다. 도메인을 가로지르는 배경(진짜 「아예 관련없는 상황」)은 아직 안 켜다.