

IP 파운데이션 월드모델 연구 노트 973

한 도메인이 92% 이던 코퍼스를 웹 크롤로 연다

113GB 한국어 웹 코퍼스를 처음 끝까지 정제해 (s,a,o) 삼중쌍 35,641 행을 냈다 --- 최대 도메인 점유율이 0.926688 에서 0.498242 로 내려간다

Sweetspot 월드모델 연구

2026년 8월 16일

초 록

이 실험실의 (s,a,o) 삼중쌍은 열두 사이클 동안 한 도메인이 92% 였다. 원천이 셋뿐이었고 셋 다 같은 자리에서 왔다. 끝에 113GB 짜리 한국어 웹 코퍼스 (HPLT 2.0 kor_Hang · 464 shard · CC0)를 받아 두고도 정제 실행이 0 회 였고 그 자료에서 온 삼중쌍이 0 행이었다. 이 노트는 그 파이프라인을 처음 끝까지 통과시킨다. shard 8 개를 읽어 문서 670,118 개를 게이트 아홉에 대고, 살아남은 문서에서 위키 개체 언급을 찾아 (s,a,o) 삼중쌍 35,641 행을 냈다. 그 행은 10 도메인을 덮고 최대 도메인은 「게임」이 아니다. 합친 코퍼스의 최대 도메인 점유율은 0.926688 → 0.498242 로 내려간다. □ 그러나 이 축의 자는 leave-one-source-out Δ 이고 그 Δ 는 아직 0 이다 — 학습 팔이 없다. 이 노트가 만든 것은 그 자의 분모다: 원천 태그를 행마다 박고, 원천 × 도메인 행렬과 원천 하나를 뺀 때의 Δ 를 덮개 자 돌(도메인 수 · 최대 점유율)로 냈다. 결으로, 이 사이클 중에 저장소 규칙이 증거를 파괴했다 — 「원장은 배관으로만 쓴다」를 지키면 HEAD 와 디스크가 갈리고, 수집 데몬이 그 차이를 커밋해 원장 11 줄이 지워졌다. 뿌리는 데몬의 커밋 목록에 경로 제한이 없던 것이었고, 임시 저장소에 심어서 재현한 뒤 막았다.

1. 왜 이 축인가

이 실험실은 여섯 능력 축 중 넷이 실측 0 인 채로 열린 사이클을 돌았다. 그 중 하나(C1 · 상태→예측)는 지난 사이클이 채서 원리상 막힌 게 아니라 검정력이 두 배쯤 모자란다는 것까지 밝혔다 — 80% MDE 0.051101 대 관측 0.025527. □ 그런데 행을 늘리는 길이 저장소에 없었다.

원천이 셋이고 그 셋이 낸 삼중쌍 40,007 중 37,074 가 한 도메인이었다. 끝에 113GB 가 있었는데 한 번도 안 돌렸다. 「데이터별 성능 기여도」라는 축은 실측이 0 회 였다. 어떤 수라도 그 축의 첫 수가 된다.

주장 1. 한 원천이 92% 인 코퍼스에서 「데이터 혼합」을 논하는 것은 분모가 없는 말이다

반증 조건. 원천을 하나 더 들여 최대 점유율이 안 내려가면 이 주장은 떨어진다. 여기서는 0.926688 에서 0.498242 로 내려갔다.

2. 정제 파이프라인 --- 게이트 아홉

□ 바퀴를 다시 만들지 않았다. 이 저장소는 이미 네 사이클 전에 조사해 두었다: datatrove 의 MinHash 는 0.28% 만 지우고 진짜 Jaccard ≥ 0.9 는 0 쌍, 형태소 분석은 공백 5-gram 대비 이득이 없고, nemo-curator 는 이 플랫폼을 거부한다. 그래서 도박 정규식과 URL 정규화는 그 사이클의 생산 함수를 그대로 불렀고, 분절은 공백 5-gram 으로 했다.

게이트	자	통과
G0	읽은 문서(분모)	670,118
G4	도박 정규식 미적중	-11,885
G5	길이 ≥ 200 · 한글비율 ≥ 0.5	
G6	정규화 URL 첫 등장	-175,950
G7	본문 전문 첫 등장	-147
G8	개체 언급 ≥ 1	44,100
G9	위키 창 181 일 전량 덮기	-38,141
(s,a,o) 삼중쌍		35,641

□ G6 가 가장 크게 묻다. 정규화 URL 중복만으로 175,950 문서가 떨어진다 — 같은 코퍼스를 앞선 사이클이 전량 훑었을 때 38,866,835 문서가 정규화 키 20,080,264 개였던 것과 같은 방향이다. 반대로 본문 전문 중복은 147 개뿐이다 — □ URL 로 걸려낸 뒤에는 본문 해시가 거의 아무 일도 안 한다.

주장 2. 웹 코퍼스에서 URL 정규화 중복 제거를 먼저 대면 본문 해시 중복 제거는 거의 남는 일이 없다

반증 조건. 본문 해시가 URL 정규화 뒤에도 상당수를 지우면 이 주장은 떨어진다. 여기서는 175,950 대 147 이다.

3. 행과 도메인을 같이 센다

□ 이 저장소는 「몇 행 늘었나」만 적고 「몇 도메인 늘었나」를 빠뜨려 세 번 걸린 적이 있다. 그래서 둘을 같은 자리에 적는다.

	행	도메인	최대 도메인 점유율
HPLT 넣기 전	40,007	11	0.926688
HPLT	35,641	10	—
합침	75,648	11	0.498242

4. 자의 분모는 만들었고 자는 아직 못 냈다

이 축의 자는 leave-one-source-out Δ 다. $\square$ 그 Δ 를 못 냈다 — 이 저장소에는 아직 학습을 도는 자리가 없다. 대신 그 자를 썰 수 있는 꼴을 만들었다: 원천 태그를 행마다 박고, 옛 원천 셋의 태그는 파일 경로에서 결정되게 했다. 그 위에서 낸 LOSO Δ 는 덮개 자 둘에 대한 것이다: 원천 하나를 빼면 도메인 수가 0 만큼, 최대 점유율이 0.428446 만큼 움직인다.

주장 3. 원천 태그가 행에 없으면 「데이터별 기여도」는 원리상 못 잰다

반증 조건. 태그 없이도 기여도를 가르는 방법이 있으면 이 주장은 떨어진다. 이 노트는 태그를 박는 것을 그 축의 첫 일로 삼았다.

5. 규칙이 증거를 파괴했다

이 사이클 도중에 사고가 났다. 저장소 규칙은 「원장은 배관으로만 쓴다 — checkout 금지」다. 그 규칙을 지키면 HEAD 는 새 blob 인데 디스크와 인덱스는 옛 blob 으로 남는다. 60 초마다 도는 수집 데몬은 자기 경로 둘만 스테이지하지만, $\square$ 커밋 목록을 만드는 명령에 경로 제한이 없었다. 그 목록은 인덱스 대 HEAD 전량을 건주므로 원장이 끼어들었고, 옛 blob 이 그대로 커밋돼 원장 11 줄이 지워졌다.

임시 저장소에 그 상황을 심어서 재현했다 — 옛 판은 경로 밖 파일을 목록에 넣고, 경로 제한을 물린 새 판은 안 넣는다. 옛 판으로 커밋하면 원장이 옛 값으로 되돌아간다. 고침은 둘이다: 규칙에 「배관으로 쓴 뒤 디스크 사본을 그 커밋본으로 되맞춘다」를 더하고, 데몬의 커밋 목록에 경로 제한을 두 겹 물렸다.

주장 4. 안전 규칙은 자기 결수효를 같이 적지 않으면 흥기가 된다

반증 조건. 규칙 자체가 파괴에 필요조건이 아니었으면 이 주장은 떨어진다. 여기서는 「배관만 쓴다」가 HEAD 와 디스크를 갈라 놓은 것이 파괴의 첫 고리였고, 심어서 재현했다.

6. 앞 노트의 수를 셋 정정한다

- 앞 노트는 「어느 판으로도 밑값을 안 넘었다」고 적었다. $\square$ 네 칸 중 한 칸에서 넘는다 — 그 칸을 만들어 커밋해 놓고 채점기에 안 물렸다. $\square$ 다만 Fisher 두쪽 p 를 병기하면 네 칸 어디서든 $p \leq 0.05$ 가 아니다. 정직한 문장은 「이 분모로는 아무것도 못 가른다」이지 「넘었다」도 「안 넘었다」도 아니다.
- 앞 노트의 「무관한 48 줄」은 존재하지 않는 꼬리

다. 생산 함수를 불러 재니 작은 꼬리 37 줄 · 큰 꼬리 437 줄 · 주석만 갈래 49 줄이다. 48 은 주석만 갈래의 주석 개수이고 그 갈래는 뒤집힌 판 0 인 음성 대조다. $\square$ 그 수는 치환표를 통과했다 — 값은 산출물에서 왔고 열쇠 라벨에 손으로 친 수가 박혀 있었다. 이 노트는 치환표에 라벨 안의 수도 그 열쇠 자신의 값에서 와야 한단을 물렸다.

- 앞 노트의 「낙하 n 도 파일 나머지 내용에 매여 있다」는 철회한다 — 그 노트 자신의 「낙하가 흔들렸나」 열쇠가 0 / 18 다.

7. 못 한 것

$\square$ 예측 성능의 LOSO Δ 는 0 이다. $\square$ 464 shard 중 8 개만 읽었다. $\square$ 개체 언급의 정밀도를 안 잰다 — 문서빈도가 큰 제목 4 개를 표시만 하고 지우지 않았고, 사람이 읽어 맞는지 세지 않았다. $\square$ 한글 네 글자 문턱은 원편 맨 같은 진짜 개체도 뻔다 — 그 손실도 안 잰다.