

IP 파운데이션 월드모델 연구 노트 974

삼중쌍이라 부르기 전에 정밀도를 재라

앞 노트가 「(s,a,o) 삼중쌍 35,641」이라 부른 것의 개체 정밀도는 0.754310 이고, 그 자료를 넣은 유보 예측의 leave-one-source-out Δ 는 0.002192 (순열 $p = 0.465134$)다

Sweetspot 월드모델 연구

2026년 8월 16일

초 록

앞 노트는 113GB 한국어 웹 코퍼스를 처음 끝까지 정제해 「(s,a,o) 삼중쌍 35,641 행」을 냈다고 적었다. □ 그 이름은 아직 못 쓴다 — 언급이 참인지 한 번도 안 봤기 때문이다. 이 노트는 무작위 표본 696 행 (총 = 제목 토큰 단일/다중 × 개체 언어 ko/en)을 문서 맥락과 함께 읽어 라벨하고, 개체 정밀도 0.754310 (95% Clopper-Pearson 0.720571 - 0.785877)와 총 가중 유효 삼중쌍 27,499.4 (분모 35,641 · 77.16%)를 낸다. □ 층별로는 언어가 토큰 수보다 크게 가른다 — 다중·ko 0.929032 > 단일·ko 0.792254 > 다중·en 0.640777 > 단일·en 0.584416 이라, 「단일 토큰 일치는 곧 잡음」이라는 읽기는 반만 맞다(단일·ko 는 22,640 행으로 가장 큰 층인데 다중·en 보다 정밀하다). 그 다음에야 이 층의 자를 처음 켜다: 유보를 시간으로 자르면 새 원천은 학습에만 들어가고 유보 집합이 팔마다 글자 그대로 같다. 그 설계에서 leave-one-source-out $\Delta\rho = 0.002192$ (순열 $p = 0.465134$ · 귀무 95 분위 0.034364) — 채택 실패이고, 정밀도 게이트를 건 팔은 -0.044382 로 더 나쁘다. □ 그러나 같은 주행이 다른 축 하나를 움직인다 — 도메인별 유보 성능의 최저값이 -0.345988 → -0.235423 → -0.158134 로 단조로 오르는데 평균은 거의 안 움직인다 (0.215083 → 0.211554). 행을 늘리는 것은 전체를 올리는 일이 아니라 바닥을 올리는 일이었다.

1. 이름이 자를 앞서면 안 된다

앞 노트는 없던 것을 만들었다 — 그 코퍼스에서 온 행이 0 이었고 35,641 이 되었다. 그것은 참이다. □ 그러나 그 행을 「삼중쌍」이라 부른 순간 두 가지가 같이 참이 되어야 한다: 상태 s 와 결과 o 가 그 개체의 것이고, 액션 a 가 그 개체를 실제로 가리키는 것이다. 앞의 것은 정의로 보장된다(둘 다 같은 위키 계열을 자른 것이다). 뒤의 것은 측정이 필요하다.

이 노트의 첫 결정은 순서다. 정밀도를 모르는 행으로 기여도를 재면, Δ 가 0 근처로 나와도 자료가 안 도운 것인지 자료가 틀린 것인지 원리상 못 가른다. 그래서 사전등록에 「정밀도를 안 내면 실패」와 「정밀도 산출물이 없으면 학습 러너가 터진다」를 같이 박았다.

주장 1. 규모를 보고한 뒤 정밀도를 보고하는 순서는 결과의 해석을 바꾼다

반증 조건. 정밀도를 재기 전과 후에 Δ 의 해석이 같다면 이 주장은 떨어진다. 여기서는 77.16% 라는 수가 있어야 「자료가 쓰레기라서」라는 설명을 뺄 수 있다.

2. 표본과 라벨

층은 행의 필드에서만 정한다 — 맞은 제목의 공백 토큰 수(단일/다중)와 개체 언어(ko/en). 층마다 무작위로 뽑고(씨앗 974), 결 표본으로 층 없는 단순무작위 300 행을 따로 뽑아 대조했다. 표본 행의 문서 id 로 shard 를 다시 흘러 읽어 본문을 되찾고(657 문서 · 못 찾은 문서 0), 맞

은 자리 앞뒤를 잘라 산출물에 남겼다 — 라벨을 재검할 수 있어야 하기 때문이다.

라벨은 네 값이다. 참(그 자리가 그 개체를 가리킨다) · 거짓·일반어(그 위키 문서 제목의 일반어 뜻을 가리키고 개체는 안 가리킨다) · 거짓(제3의 것) · 모름. □ 셋째 값이 필요한 이유는 실측에서 나왔다 — 웹툰 개체 블루투스 의 상태 계열은 무선 규격 문서의 조회수다. 그런 행에서 「블루투스 4.0」은 문서에는 맞고 개체에는 틀리다. 그래서 두 정밀도를 같이 적는다: 개체 정밀도 0.754310 와 문서 정밀도 0.831897.

주장 2. 개체 기준 정밀도와 문서 기준 정밀도를 나누지 않으면 언급 자료의 오류를 잘못 귀속한다

반증 조건. 두 값이 같으면 이 주장은 떨어진다. 여기서 0.754310 대 0.831897 로 54 행이 그 사이에 있다.

3. 정밀도

주 자는 모름을 실패로 세는 개체 정밀도다: $525 / 696 = 0.754310$ (95% CP 0.720571 - 0.785877). 결 표본(단순무작위 300)은 0.786667 로 구간이 겹친다. 총 가중으로 되돌린 유효 삼중쌍은 27,499.4(붓스트랩 95% 26,228.8 - 28,677.4).

층별 정밀도는 단일·en 0.584416 · 다중·en 0.640777 · 단일·ko 0.792254 · 다중·ko 0.929032 다. 사전등록은 「가장 낮은 층이 단일·en 일 것」을 맞혔고 「정밀도가 0.75 미만일 것」과 「유효 삼중쌍이 25,000 미만일 것」을 틀렸다. □ 두 반증 모두 앞 노트에게 유리한 쪽이다.

그대로 적는다.

주장 3. 토큰 수보다 언어가 언급 정밀도를 크게 가른다

반증 조건. 단일·ko 가 다중·en 보다 낮으면 이 주장은 떨어진다. 여기서는 0.792254 대 0.640777 다.

4. 게이트 --- 그리고 성립하지 않은 게이트 하나

네 게이트를 걸고 라벨로 채점했다: 단일 토큰 라틴 제목 · 토큰화가 원문을 뭉개는 제목 · 위키 자기 순환 host · 레포트/딤프 사이트. 넷을 다 걸면 11,332 / 35,641 (31.79%) 가 떨어지고, 때는 쪽 정밀도 0.678967 가 남는 쪽 0.802353 보다 낮다.

□ 그런데 위키 자기 순환은 게이트로 성립하지 않는다 — 무슨 쪽 정밀도가 0.804348 로 남는 쪽 0.750769 보다 높다. 위키 미리 문서는 맞는 제목을 그대로 나열하니 언급이 오히려 정확하다. 자기 순환은 정밀도 문제가 아니라 독립성 문제이고, 정밀도 자로는 원리상 못 잡는다.

주장 4. 자기 순환 원천은 정밀도 자로 걸리지 않는다

반증 조건. 위키 host 를 무슨 행의 정밀도가 남는 행 보다 낮으면 이 주장은 떨어진다. 여기서는 0.804348 대 0.750769 로 반대다.

5. 문턱의 손실을 같은 표본에서 센다

한글 제목 길이 문턱(4자)은 진짜 개체도 땀다. 문턱을 3 으로 내리면 제목 133 개가 새로 들어오고 같은 표본 문서에서 짝이 1,194 개 는다. □ 그중 840 개가 ‘원피스’ 하나이고 뒤이어 ‘네이버’ · ‘고양이’ · ‘거짓말’ 같은 세 글자 보통명사가 온다. 문턱이 땀 진짜 개체(‘원편맨’)는 12 짝이다. 문턱은 손실보다 이득이 크다.

6. 이 축의 자 --- leave-one-source-out

설계. 유보를 시간으로 자른다. 새 원천의 문서는 유보 창보다 앞선 것뿐이라 유보에 0 행 들어간다 — 그래서 유보 집합이 세 팔에서 글자 그대로 같고 다른 것은 학습 뿐이다. 그것이 「원천 하나를 빼면 유보 예측이 얼마나 달라지나」의 깨끗한 꼴이다. 특징 · 능형 · 순위상관 · 묶음 · 순열 귀무는 앞 노트들의 생산 함수를 그대로 부른다.

결과. 학습 행 1,581 → 37,222 로 35,641 행을 더해도 묶음 $\Delta\rho = 0.002192$ · 순열 $p = 0.465134$ · 양수 도메인 4 / 7 다. 귀무 95 분위가 0.034364 이니 관측은 이 설계가 가를 수 있는 크기 밑이다. 정밀도 게이트를 건 팔은 $-0.044382(p = 0.954511)$ 로 더 나쁘다.

□ 정직한 문장은 「좋아진다고 나빠진다고 이 분모로는 못 말한다」이다. □ 그러나 앞 노트와 달라진 것이 하나 있다 — 정밀도를 켜기 때문에 「자료가 쓰레기라서」는 이제 답이 아니다. 행의 77.16% 가 진짜 언급이다.

주장 5. 언급 정밀도가 높아도 규모만으로는 유보 예측이 안 오른다

반증 조건. Δ 가 귀무 95 분위기를 넘으면 이 주장은 떨어진다. 여기서는 0.002192 대 0.034364 다.

7. 바닥이 오른다 --- 평균은 안 오른다

같은 주행이 도메인별 유보 성능을 낸다. 최저값은 $-0.345988 \rightarrow -0.235423 \rightarrow -0.158134$ 로 단조로 오르고, 최저 도메인은 세 팔 모두 같다. □ 그런데 평균은 $0.215083 \rightarrow 0.213073 \rightarrow 0.211554$ 로 거의 안 움직인다.

묶음 Δ 는 0 근처인데 바닥은 오른다 — 이 둘은 모순이 아니다. 도메인별 Δ 는 $\mathcal{A}^+$ 0.110565 와 최대 $\mathcal{A}^-$ -0.206897 로 갈리고, 유보 행 가중 합이 서로를 지운다. 규모를 더하는 것은 평균을 올리는 일이 아니라 재분배였고, 그 재분배가 바닥에 유리하다.

주장 6. 데이터 규모를 늘리는 이득은 평균이 아니라 최저 도메인에서 나타난다

반증 조건. 최저값이 안 오르거나 평균이 같이 오르면 이 주장은 떨어진다. 여기서는 최저 $-0.345988 \rightarrow -0.158134$ 이고 평균 $0.215083 \rightarrow 0.211554$ 다.

8. 한계

라벨은 한 사람이 붙였고 둘째 채점자가 없다. 맞은 자리 앞뒤 맥락만 보았고 문서 전문은 안 읽었다. 새 원천의 문서는 유보 창보다 여러 해 앞선 것이라 분포 이동이 팔 사이에 섞여 있고, 이 설계로는 「원천이 나빠서」와 「시대가 달라서」를 못 가른다. 그리고 읽은 shard 는 앞 노트와 같은 여덟 개다 — 전량이 아니다.