

IP 파운데이션 월드모델 연구 노트 975

무엇이 capability 를 정하나 --- 요인 하나만 혼든 짝 실험

어느 요인이 유보 예측 성능을 정하는지 묻는 자리가 그 동안 비어 있었다. 요인 다섯을 하나씩만 흔들어 델타와 짝지은 표준오차를 내고 순위를 적는다

Sweetspot 월드모델 연구

2026년 8월 16일

초 록

「무엇이 capability 를 정하나」는 이 실험실의 여섯 능력 축 가운데 하나인데, 그 칸은 세 사이클 연속 비어 있었다. 자가 없어서가 아니다 — 자는 이미 적혀 있었다(요인 하나만 혼든 짝 실험의 $\Delta \pm SE$). 없던 것은 흔들 요인의 목록이다. 흔들 요인을 등록한 적이 없으니 어떤 개선의 크기도 견줄 대상이 없었다.

이 노트는 그 목록을 먼저 만든다. 학습 파이프라인의 다섯 칸 — architecture(특징 집합) · objective(도메인 가중) · data mixture(원천 혼합) · optimizer(능형 정칙화) · curriculum(학습 창 길이) — 에 격자를 측정 전에 못 박고, 밀판에서 한 칸만 바꾼 짝 실험을 돌린다. 유보 집합은 모든 수준에서 글자 그대로 같다. SE 는 유보 행을 도메인 안에서 되 뽑는 짝지은 군집 붓스트랩에서 낸다.

결과는 순위 하나와 부호 하나다. 순위는 특징 집합 > 학습 창 > 원천 혼합 > 도메인 가중 > 능형 정칙화이고, □ 사전등록 문턱을 넘은 수준은 전부 Δ 가 음수다. 즉 이 격자가 켜진 것은 「무엇이 성능을 올리나」가 아니라 「무엇을 망가뜨리면 내려가나」다. □ 그리고 스패는 격자가 정한 수라, 이 순위는 격자 밖으로 일반화되지 않는다 — 그 한계를 결과와 같은 자리에 적는다.

같은 라벨 위에서 앞 노트의 언급 정밀도 추정량도 고친다. 표본이 등할당 층화인데 헤드라인이 층을 무시한 비율이었고, 제목이 군집인데 구간이 독립 시행을 가정했다. 새 라벨은 하나도 붙이지 않았다 — 바뀐 것은 추정량뿐이다.

1. 빈 칸은 자가 없어서가 아니라 요인이 없어서 비었다

여섯 능력 축 가운데 「무엇이 capability 를 정하나」에 붙은 자는 처음부터 분명했다: 요인 하나만 혼든 짝 실험의 $\Delta \pm SE$. 그런데도 그 칸은 세 사이클 연속 비었다. □ 까닭은 자가 아니라 목록이었다 — 무엇을 흔들 것인지 적어 둔 적이 없으니 흔들 수가 없었다.

같은 공백이 다른 축도 막고 있었다. 「상태에서 예측으로」 축은 개선의 크기를 못 가른다는 곳에서 멈춰 있었는데, 크기를 가르려면 견줄 다른 크기가 있어야 한다. 요인 표가 없으면 그 비교 자체가 정의되지 않는다.

그래서 이 노트의 첫 일은 측정이 아니라 등록이다. 학습 파이프라인의 다섯 칸에 각각 요인 하나를 붙이고, 각 요인의 격자값을 측정 전에 사전등록에 박았다. 격자를 뒤에 고치면 실패로 적기로 같이 박았다.

2. 설계 --- 유보를 한 번도 안 건드린다

밀판은 앞 노트가 쓰던 학습 팔 그대로다. 각 수준은 밀판에서 정확히 한 칸만 다르고, 그것을 산문으로 주장하지 않고 기계로 확인해 산출물에 적는다.

가장 중요한 설계 결정은 유보를 손대지 않는 것이다. 시간으로 자른 유보는 어떤 요인을 흔들어도 바뀌지 않으므로, 모든 수준의 유보 행 지문이 하나여야 한다. 그것도

산출물에 적는다. SE 는 같은 되뽑기를 두 수준에 동시에 먹이는 짝지은 군집 붓스트랩에서 나온다 — 수준마다 따로 뽑으면 짝이 깨지고 폭이 부풀기 때문이다.

3. C4 — 요인 하나만 혼든 짝 실험

주장 1. 요인 다섯을 하나씩만 흔들어 유보 예측 성능의 $\Delta \pm SE$ 를 냈다. 이 격자 안에서의 순위는 특징 집합 (architecture) > 학습 창 (curriculum) > 원천 혼합 (data mixture) > 도메인 가중 (objective) > 능형 λ (optimizer) 다

반증 조건. 한 수준이 밀판과 두 칸 이상 다르거나, 유보 집합이 수준마다 달라지거나, Δ 에 짝지은 SE 가 안 붙으면 이 주장은 떨어진다. 격자를 넓히면 스패이 커지므로 순위는 격자 밖으로 일반화되지 않는다.

밀판은 HPLT 전량 학습 ($n = 37,222$ 행) · $\lambda = 1.0$ · 특징 전량6 · 창 전량 · 균등 가중이고, 유보는 모든 수준에서 같다 ($n = 782$ · 게이트 도메인 합 728). 밀판 묶음 유보 스피어만은 0.37815 다.

문턱(사전등록: $|\Delta|$ 가 두 배 SE 이상이고 카드 문턱 이상)을 둘 다 넘은 수준은 6 / 18 이고, 여섯 전부 Δ 가 음수다. 즉 이 격자에서 켜진 것은 성능을 올리는 요인이 아니라 망가뜨리면 내려가는 요인이다.

순위	요인	스팬	$\Delta \pm SE$
1	R2 특징 집합 (architecture)	0.098849	-0.098849 ± 0.041639
2	R3 학습 창 (curriculum)	0.071424	-0.071424 ± 0.021517
3	R5 원천 혼합 (data mixture)	0.046575	-0.046575 ± 0.023094
4	R4 도메인 가중 (objective)	0.039736	-0.039736 ± 0.018558
5	R1 능력 λ (optimizer)	0.017251	$+0.015264 \pm 0.012209$

Table 1: 요인 순위. 스패는 사전등록된 격자 안에서의 최대 - 최소 차다.

4. 언급 정밀도의 추정량 정정

주장 2. 등할당 층화 표본에서 층을 무시한 비율은 편향 추정량이고, 제목이 군집이면 독립 시행 가정의 구간은 좁다

반증 조건, 층가중 값이 층 무시 값과 같거나, 제목 군집 붓스트랩 구간이 Clopper - Pearson 구간보다 넓지 않으면 이 주장은 떨어진다.

층가중 개체 정밀도는 0.771566 이고 층을 무시한 값은 0.75431 다. 라벨한 696 행이 제목 164 개에서 나오므로 독립 시행 가정의 Clopper - Pearson 구간은 좁다: 제목 군집 붓스트랩의 95% 구간은 [0.559859, 0.872423] 이고 설계효과는 22.5251 다. 유효 삼중쌍은 27499.4 [19953.9, 31094] 다.

5. 이 순위가 말하지 않는 것

□ 스패는 요인의 본질적 크기가 아니다. 격자를 넓히면 스패가 커진다. 그래서 이 표는 「이 격자 안에서」의 순위이고, 다음에 필요한 것은 격자와 무관한 정규화(예: 같은 계산 예산에서의 최대 Δ)다.

□ 그리고 문턱을 넘은 수준이 전부 음수라는 사실은 그 자체가 결과다. 이 격자에서 밀판은 이미 각 요인의 좋은 쪽에 있었고, 혼든 것은 대부분 망가뜨리는 방향이었다. 성능을 올리는 요인을 찾으려면 격자를 밀판의 바깥쪽으로 넓혀야 한다 — 그것이 다음 사이클의 일이다.