

IP 파운데이션 월드모델 연구 노트 977

바깥 원천은 이 예측기를 만들지 않는다 --- 학습 라벨을 부수어 확인한다

앞 노트들은 바깥 웹 말뭉치를 들어온 것을 데이터 기여로 적었다. 학습 라벨만 골라 부수는 대조로 그 기여가 사실상 0 임을 보인다

Sweetspot 월드모델 연구

2026년 8월 16일

초 록

데이터 기여도 측은 세 노트 연속 「원천을 하나 더 들였다」라는 배관 문장에 머물러 있었다. 이 노트는 그 문장을 예측 성능 위에서 검사한다. 측에 등록된 자는 원천 하나 빼기 델타이고, 이 노트가 그 자를 처음 끝까지 돌린다.

먼저 앞 노트의 결과를 정정한다. 앞 노트는 바깥 원천의 섞음 비율을 요인으로 흔들면서 능형 정칙화 세기를 자리마다 교차검증으로 다시 골랐다. 그래서 섞음 비율의 효과와 정칙화 선택의 효과가 엉켰다. 이 노트는 정칙화를 등록된 값으로 열리고 섞음 비율 일곱 값과 정칙화 아홉 값의 격자 63 칸을 교차 유보 겹 써앗 다섯에서 다시 켜다. 앞 노트가 본 크기의 대부분은 정칙화 선택에서 왔다.

그다음 까닭을 묻는다. 학습 행의 95 퍼센트가 바깥 원천인데 그 라벨을 통째로 뒤섞어도 유보 성능이 거의 안 움직인다. 반대로 나머지 5 퍼센트 — 안쪽 원천의 90 행 — 만 뒤섞으면 크게 움직인다. 크기를 맞춘 대조(바깥 원천에서 같은 수의 행만 뒤섞기)는 사실상 0 이다. 학습 라벨 전량을 뒤섞으면 자는 제대로 무너진다 — 자는 살아 있고, 안 움직이는 것은 그 행들이 안 쓰이기 때문이다.

마지막으로 자 자체를 손본다. 유보에서 한 도메인이 절반을 넘고 묶음 값의 대부분을 그 하나가 정한다. 측정 전에 박은 규칙 셋 — 지배도 · 두 자의 부호 뒤집힘 · 라벨 전량 파괴에서 자가 죽는가 — 을 모두 통과했으므로 도메인 균등 가중을 정본 자료 올린다. 올린 첫 결과는 이 노트 자신의 부차적 주장을 짚는 것이다.

1. 배관과 기여는 다른 문장이다

「원천을 하나 더 들였다」와 「그 원천이 성능을 만든다」는 다른 문장이다. 앞 세 노트는 앞의 것을 해냈고 — 정제 주행이 처음 끝까지 돌았고 삼중쌍이 0 행에서 수만 행이 됐다 — 뒤의 것을 안 켜다. 측에 등록된 자가 원천 하나 빼기 델타인데 그 자를 돌리려면 학습 팔이 필요했고, 그 팔이 이제 있다.

한 가지 함정이 앞 노트에 있었다. 섞음 비율을 흔들 때 정칙화 세기를 자리마다 교차검증으로 다시 골랐고, 그 값이 섞음 비율과 함께 크게 움직였다 — 비율이 낮은 쪽에서는 약한 정칙화, 높은 쪽에서는 아주 강한 정칙화가 뿔었다. 그래서 「원천을 뺐더니 좋아졌다」의 대부분은 사실 「정칙화가 달라졌다」였다. 요인 하나를 흔들다는 말은 선택기까지 열려야 참이 된다.

2. 설계

정칙화를 열렸다. 격자의 모든 칸에서 정칙화 세기를 등록된 값으로 고정한다. 교차검증을 아예 안 돌린다.

겹 써앗을 다섯 개 평균했다. 앞 노트에서 교차 유보 겹의 배정 써앗을 바꾸는 것만으로 값이 신고된 표준오차의 두 배 가까이 흔들렸다. 자리마다 써앗 다섯에서 채고 평균과 써앗 표준편차를 같이 적는다.

두 자를 같이 낸다. 유보 행 가중 묶음과 도메인 균등 가중을 모든 칸에서 둘 다 낸다. 부호가 갈리는 자리를

하나도 빼지 않고 켜다.

학습 라벨만 부순다. 파괴 대조는 학습 쪽 라벨만 뒤섞고 유보는 한 줄도 만지지 않는다. 크기를 맞춘 대조를 반드시 함께 둔다 — 그것이 없으면 「행이 많아서」와 「행이 쓸모없어서」를 못 가른다.

3. 원천 하나를 빼면 어떻게 되나

주장 1. 바깥 웹 말뭉치에서 들어온 학습 행을 통째로 빼도 유보 성능이 안 내려간다 — 안쪽 두 원천은 빼면 내려간다

반증 조건. 바깥 원천을 뺐 팔의 델타가 잡음 문턱을 넘어 음수가 되거나, 안쪽 원천을 뺐 팔의 델타가 양수가 되면 이 주장은 떨어진다.

학습 예산을 고정하고 바깥 원천의 섞음 비율만 바꾼 격자를 세웠다. 정칙화 세기는 자리마다 고르지 않고 등록된 값으로 열렸다 — 앞 노트에서는 그 값이 섞음 비율과 함께 움직여 두 효과가 엉켰다. 교차 유보 겹은 다섯 개의 써앗에서 다시 만들어 평균했다. 바깥 원천을 통째로 뺐 팔의 델타는 0.040949 이고, 다른 정칙화 값에서는 0.011773 다. 두 값 모두 양수다. 같은 자리에서 안쪽 두 원천을 뺐 팔은 각각 -0.026338 와 -0.013606 로 음수다. 다만 도메인 균등 가중으로 재면 바깥 원천을 뺐 팔의 부호가 정칙화 값에 따라 갈린다(0.01344 와 -0.000709) — 그래서 이 노트는 빼면 나아진다가 아니라 넣어도 안

달라진다까지만 주장한다.

4. 왜 그런가 --- 라벨을 부수는 대조

주장 2. 바깥 원천 쪽 학습 라벨을 통째로 뒤섞어도 유보 성능이 거의 안 움직이는 반면 안쪽 원천 쪽 라벨만 뒤섞으면 크게 움직인다 — 즉 모형은 소수의 안쪽 행 위에서 있다

반증 조건. 작은 쪽을 부순 절대 델타가 큰 쪽보다 작거나, 전량을 부순 델타가 잡음 문턱을 못 넘으면 이 주장은 떨어진다.

학습 라벨만 뒤섞고 유보는 한 줄도 만지지 않았다. 바깥 원천 쪽 1,710 행을 전부 뒤섞은 절대 델타는 0.018906 인데, 안쪽 원천 쪽 90 행만 뒤섞은 절대 델타는 0.113826 다. 행당 효과로 고치면 114.3919 배 차이다. 크기를 맞추면 대조 — 바깥 원천에서 같은 수의 행만 뒤섞은 팔 — 의 절대 델타는 0.000916 로 사실상 영이다. 학습 라벨 전량을 뒤섞은 팔은 절대 델타 0.252914 로 잡음 문턱 둘을 넘는다 — 자가 학습 라벨을 보긴 본다.

5. 앞 노트의 크기는 대부분 정칙화 선택이었다

주장 3. 앞 노트가 원천 혼합의 효과로 적은 크기의 대부분은 정칙화 세기를 교차검증으로 다시 고른 데서 왔다

반증 조건. 정칙화를 맞춘 뒤에도 같은 크기가 남으면 이 주장은 떨어진다.

앞 노트는 바깥 원천을 뺀 수준에서 델타 0.127683 를 봤다. 정칙화를 등록된 값으로 맞추면 그 델타는 0.011773 와 0.040949 다. 정칙화 아홉 값 가운데 바깥 원천을 뺀 쪽이 나은 칸은 7 / 9 이다. 다만 정칙화를 각 팔에서 따로 최적화하면 두 팔의 최고값 차이는 -0.000201 로 사실상 영이다 — 그래서 두 문장을 갈라 적는다.

6. 자를 한 도메인에서 뺄 수 있나

주장 4. 묶음 가중 자는 한 도메인이 값의 대부분을 정하므로 도메인 균등 가중으로 갈아 끼워야 한다 — 균등 가중은 학습 라벨을 전부 부수면 제대로 내려가므로 자로서 살아 있다

반증 조건. 균등 가중 값이 라벨 전량 파괴에서 안 내려가면 이 주장은 떨어진다.

유보에서 가장 큰 도메인의 묶은 0.545994 인데 묶음 값에 대는 기여는 86.803 퍼센트다. 앞 노트의 격자에서 두 자의 부호가 뒤집히는 수준은 12 / 32 이다. 학습 라벨 전량을 뒤섞은 팔에서 균등 가중 델타는 -0.023854 로 음수이므로, 측정 전에 박은 결정 규칙 셋이 모두 참이다. 이 노트는 균등 가중을 정본으로 올린다. 다만 등록한 조건은 부호만 물었다 — 크기까지 물으면 그 델타는 자기 표준오차 0.091314 의 두 배를 못 넘는다. 균등 가중은 묶음 가중보다 잡음이 넓고, 그 자의 검정력을 세우는 일은 다음 노트로 넘긴다. 올린 첫 결과는 이 노트 자신의 부차적 주장을 꺾는 것이다 — 정본 자로 보면 바깥 원천

을 뺀 팔의 델타가 정칙화 값에 따라 부호를 바꾼다.

7. 이 수가 말하지 않는 것

이 노트는 라벨만 부셨다. 바깥 원천의 행이 왜 안 쓰이는지 — 특징이 유보와 겹치지 않아서인지, 라벨의 잡음 때문인지 — 는 아직 안 같았다. 다음에 필요한 것은 특징 쪽을 부수는 대조다.

섞음 비율 격자는 0 과 0.2 사이가 비어 있다. 「조금만 넣는 것이 최적인가」는 안 물었다.

그리고 교차 유보는 시간 방향이 아니다. 이 자는 예측이 아니라 보간에 가깝고, 그 한계는 앞 노트에서 그대로 물려받았다.