

IP 파운데이션 월드모델 연구 노트 295

가려던 자리가 더 거친 자리였다

세 노트에서 “하네스는 분해능이 다르다”고 전제하고 갈 곳으로 적었다 --- 재 보니 lab 보다 일곱에서 서른 배 거칠다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 291 · 293 · 294가 전부 “남은 것”의 첫 줄에 하네스에서 재기 — MAPE 쪽은 분해능이 다른 유일한 자리를 적었다. 세 번 적는 동안 한 번도 안 켜다. 켜다. 하네스에는 이미 짝 A/B 셋(시장층 · 피쳐 · 신호, 서로 레코드가 안 겹치는 30 · 29 · 27건)과 반복 실행 로그가 디스크에 있다. 노트 274의 법칙(검출 문턱 = $2 \times$ 짝SE)을 그대로 적용했다. 지표 수준으로 정규화한 문턱이 lab 은 2~10% 인데 하네스는 15~65% 다 — 일곱에서 서른 배 거칠다. 그리고 실측 라벨을 쓰는 내부 폴드가 제일 거칠다(65%) — 내가 계속 인용하던 “MAPE 16~18%”가 바로 그 폴드다. 원인은 표본이다: lab 은 유보 2,675행을 채점하고 하네스는 A/B 당 27~30건이다. 그래서 하네스가 지금까지 보고한 세 개선이 전부 자기 문턱 아래다($t=0.52 \cdot 1.07 \cdot 1.74$). 여기서 멈추지 않고 갈랐다(노트 133) — APE 는 이미 비율이라 차보다 비가 맞는 척도다. 배수 척도로 다시 재니 셋이 $t=1.64 \cdot 1.58 \cdot 1.51$ 로 거의 같고 방향도 같다. 서로 안 겹치는 세 셋을 합치면 $n=86 \cdot t=+2.69 \cdot$ 주입이 APE 를 21.4% 줄인다. 다중비교 $m=4$ 기준 2.50은 넘고 $m=8$ 기준 2.73은 못 넘는다. 그리고 각 셋에 필요한 표본이 45~47건인데 지금 27~30건이고 안 쓴 라벨이 120건 남아 있다. 갈 곳이 아니라 넓힐 곳이였다.

1. 세 번 적고 한 번도 안 켜다

노트 291 · 293 · 294의 “남은 것” 표가 전부 같은 줄로 시작한다.

노트	적은 것
291	하네스에서 재기 — 분해능이 다르다
293	하네스에서 재기 — 분해능이 다른 유일한 자리
294	하네스에서 재기 — MAPE 쪽은 분해능이 다르다

“다르다”고 썼지만 쓴 뜻은 ‘더 낮다’였다 — lab 에서 켜는 것이 전부 문턱 아래로 끝나니 문턱이 낮은 데로 가자는 뜻이었다. 그건 측정이 아니라 희망이다. 켈 재료는 이미 디스크에 있었다.

짝 A/B	n	무엇을 뺐나
market-eval-v3	30	시장 층
feat-eval	29	피쳐
sig-eval	27	신호
runvar	9×4	— (같은 팔 반복)

세 셋은 레코드가 하나도 안 겹친다.

2. 일곱에서 서른 배 거칠다

노트 274의 법칙을 그대로 적용했다.

자리	수준	문턱	비	유보 n
lab 판	0.4819	0.0100	2%	2,675
lab 게임	0.6158	0.0150	2%	180
lab 웹툰	0.4500	0.0460	10%	711
하네스 신호	1.4930	0.2245	15%	27
하네스 피쳐	1.4420	0.3808	26%	29
하네스 시장층	0.7289	0.3004	41%	30
하네스 내부	0.1890	0.1227	65%	9

하네스가 더 거칠다. 그리고 제일 거친 것이 내부 폴드다 — 라벨이 실측이라 MAPE 가 0.19 로 낮은 그 폴드가, 레코드 9건에 실행 잡음이 0.13 이라 짝 A/B 를 한 번씩 돌리면 문턱이 수준의 65%다. 내가 세 노트에서 인용한 “MAPE 16~18%”가 바로 이 폴드다. 제일 좋아 보이는 숫자가 제일 못 재는 자리에서 나왔다.

원인은 표본이다. lab 은 유보 2,675행을 채점한다. 하네스는 A/B 당 27~30건이다 — 100배다. 게다가 APE 짝차가 두꺼운 꼬리를 가진다: 절대값 상위 3건이 총합의 52 · 71 · 53%를 차지한다(최대 5.40).

그래서 세 보고가 전부 문턱 아래다.

	효과	문턱	t
시장층	+0.0788	0.3004	+0.52
피쳐	+0.2034	0.3808	+1.07
신호	+0.1957	0.2245	+1.74

3. 척도를 바꾸니 셋이 같은 말을 한다

여기서 멈추면 “하네스도 아무것도 못 켜다”로 끝난다. 갈랐다(노트 133).




Figure 1: 왼쪽 — 지표 수준으로 나눈 검출 문턱. 오른쪽 — 배수 척도로 다시 켜 세 주입 효과와 합친 것(± 1.96 작SE).

APE 는 이미 비율이다. $0.07 \rightarrow 0.05$ 와 $2.9 \rightarrow 2.7$ 을 같은 -0.2 로 세는 것이 척도의 잘못이다. 비로 다시 썼다 ($\log \frac{\text{벤 팔}+0.05}{\text{낮은 팔}+0.05}$).

	n	효과	t	필요 n
시장층	30	+0.3204	+1.64	45
피쳐	29	+0.1874	+1.58	46
신호	27	+0.2107	+1.51	47
합침	86	+0.2411	+2.69	—

t 가 1.64 · 1.58 · 1.51 이다. 서로 레코드가 안 겹치고 뻥 것도 다른 세 실험이 거의 같은 값을 낸다. 더하기 척도에서는 0.52 ~ 1.74 로 흩어져 있던 것이다 — 척도가 맞으면 잡음이 줄고 일치가 보인다.

합치면 $n=86$ 에 $t = +2.69$, 되돌리면 주입이 APE 를 21.4% 줄인다.

그런데 넘었다고 말하지 않는다. 노트 275의 배포 규칙대로 다중비교 문턱을 건다. 척도를 둘 봤고 비교를 냈했다.

샘	문턱	t=2.69
단일 ($m=1$)	1.96	통과
셋 + 합침 ($m=4$)	2.50	통과
× 두 척도 ($m=8$)	2.73	미달

내가 척도를 고른 것이 자료를 본 뒤다. 그러니 $m=8$ 이 정직한 샘플이고, 그 문턱을 0.04 차이로 못 넘는다. “넘었다”가 아니라 “넘기 직전”이다.

4. 갈 곳이 아니라 넓힐 곳이였다

필요 표본이 셋 다 45~47건인데 지금 27~30건이다. 그리고

라벨 있는 시장 레코드	205
세 A/B 가 쓴 것	86
아직 안 쓴 것	120

각 셋에 15~20건씩만 더하면 셋 다 자기 힘으로 문턱을 넘는다. 그러면 척도 선택도 자료를 보기 전에 고정할 수 있어 $m=8$ 이 아니라 $m=3$ 이 된다.

남은 것.

갈래	왜
셋에 20건씩 더	문턱을 각자 넘게. 라벨 120건 남음
척도를 먼저 고정	배수. 다음 재기 전에 적어 둔다
내부 폴드 양상불	실행 잡음 0.13 이 문턱의 전부
lab 회사 측	노트 294의 +0.0040 을 남길지

규약. “저기가 낫다”고 세 번 적기 전에 한 번 재라. 하네스는 lab 이 못 재는 것을 재 주는 자리가 아니라 더 못 재는 자리였고, 재료는 처음부터 디스크에 있었다. 그리고 척도를 자료 보고 고르면 그 값으로 다중비교를 물어야 한다 — 배수 척도가 옳다고 지금은 믿지만, 그 믿음이 자료 뒤에 생겼으므로 이번 $t=2.69$ 는 증거가 아니라 다음 측정의 설제다.