

IP 파운데이션 월드모델 연구 노트 298

셋이 같았던 것이 우연이었다

하네스 짝 셋에 57건을 더해 사전 등록한 척도로 다시 봤다 --- 노트 295의 일치가 무너지고 신호 하나만 복제된다

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

노트 295가 하네스 짝 셋(시장층 · 피쳐 · 신호)이 배수 척도에서 $t=1.64 \cdot 1.58 \cdot 1.51$ 로 거의 같은 값을 낸다는 것을 근거로 합쳐서 $t=2.69$ 를 보고했다. 다만 척도를 자료 보고 골랐으므로 그것은 증거가 아니라 다음 측정의 설계라고 적었다. 그 설계를 실행했다. 재기 전에 척도(APE 비의 $\log$ · 완충 0.05) · 문턱($|t| > z(0.05/6) = 2.39$) · 대상 ID 57건 · 미리 적는 실패를 파일에 못 박고, 안 쓴 시장 라벨 119건에서 시기 구성을 기존 셋과 맞춰 뽑아 114회 예측을 돌렸다. 결과, 셋 중 하나만 문턱을 넘는다(신호 $t=2.41$ · 피쳐 1.73 · 시장층 1.32). 미리 적은 규칙이 “하나만 넘으면 넘었다고 하지 않는다”였으므로 안 넘었다고 적는다. 그런데 진짜 수는 새 57건만 떼어 볼 때 나온다: 시장층은 부호가 뒤집히고($+0.3204 \rightarrow -0.0275$) 피쳐는 반토막($+0.1874 \rightarrow +0.0746$)인데 신호는 그대로다($+0.2107 \rightarrow +0.2160$, $t=2.21$). 합침도 $+0.2411 \rightarrow +0.0945$ ($t=1.19$)로 복제 안 된다. 노트 295가 증거로 삼은 ‘셋이 거의 같다’가 바로 그 우연이었다 — $n \approx 30$ 짜리 셋의 t 가 0.13 폭 안에 모이는 것은 신호가 아니라 요행이다. 남은 것은 하나다: 신호 층.

1. 설계를 먼저 못 박았다

노트 295의 마지막 줄이 “이번 $t=2.69$ 는 증거가 아니라 다음 측정의 설계”였다. 그 설계를 파일로 적었다 (data/lab/preregister_harness_scale.json).

못 박은 것	
지표	$\log \frac{\text{변환 APE}+0.05}{\text{원본 APE}+0.05}$
문턱	$ t > z(0.05/6) = 2.39$
1차 판정	셋이 각자 넘는지. 합침은 보조
표본	시장층 +18 · 피쳐 +18 · 신호 +21
고르는 법	안 쓴 119건에서 라벨 안 보고

고르는 법을 두 번 고쳤다 --- 둘 다 라벨 보기 전. ① “사전순으로 잘라 나눈다”로 적었는데 MKT-YYYY-NNNN이라 사전순이 곧 연도순이다 — 자르면 시장층은 전부 2023, 신호는 전부 2024 를 받는다. 번갈아 배분으로 고쳤다. ② 번갈아 배분해도 앞서서부터 채우면 새 표본이 전부 2023~24 다. 조건화 뱅크가 시기에 따라 0건에서 309건까지 자라므로 period_from 순으로 세워 균등 간격으로 뽑았다.

	기존	더한 것
시장층	30 (23:5 24:7 25:12 26:6)	+18 (5/5/7/1)
피쳐	29 (23:4 24:11 25:11 26:4)	+18 (5/5/7/1)
신호	27 (23:3 24:9 25:8 26:7)	+21 (4/6/7/4)

그리고 미리 적은 실패도 함께 적었다 — “셋 중 하나만 넘으면 ‘넘었다’고 하지 않는다”, “표본을 더해도 t 가 안 오르면 노트 295의 $t=2.69$ 는 우연이었던 것이다”, “완충 0.05 를 바꿔 t 가 오르면 그건 척도 고르기다.”

2. 셋 중 하나만 넘는다

114회 예측을 돌리고 사전 등록한 척도로 읽었다.

	전	후	효과	짝SE	t
시장층	30	48	+0.1899	0.1440	+1.32
피쳐	29	47	+0.1442	0.0833	+1.73
신호	27	48	+0.2130	0.0885	+2.41
합침	86	143	+0.1827	0.0626	+2.92

신호만 2.39 를 넘는다. 미리 적은 규칙대로 “셋이 넘었다”고 하지 않는다. 합침 $t=2.92$ 는 보조로만 적는다 — 다만 이번에는 척도를 자료 보기 전에 고정했으므로 노트 295와 달리 척도 고르기가 아니다.

효과는 줄었다. 시장층 $+0.3204 \rightarrow +0.1899$, 피쳐 $+0.1874 \rightarrow +0.1442$. 승자의 저주다 — 노트 295에서 “필요 n 은 관측된 효과에서 되짚은 값이라 낙관적”이라고 미리 적어 둔 그대로다. 되돌린 APE 감소도 21.4% $\rightarrow$ 16.7% 다.

3. 진짜 수는 새 57건에 있다

전과 후를 합치면 옛 자료가 섞여 복제인지 아닌지 안 보인다. 새로 더한 57건만 떼어 봤다.

	옛		새	
	효과	t	효과	t
시장층	+0.3204	+1.64	-0.0275	-0.14
피쳐	+0.1874	+1.58	+0.0746	+0.70
신호	+0.2107	+1.51	+0.2160	+2.21
합침	+0.2411	+2.69	+0.0945	+1.19




Figure 1: 왼쪽 — 옛 자료(동그라미)와 새 57건(네모)의 효과(± 1.96 짝SE). 오른쪽 — 전부 합쳐 사전 등록한 문턱과 견준 것.

- 시장층은 부호가 뒤집혔다. $+0.3204$ 에서 -0.0275 다. 새 $n=18$ 에 짝SE 0.20 이라 “나쁘다”고도 못 하지만, $+0.32$ 는 확실히 아니다.
- 피쳐는 반토막이다. $+0.1874 \rightarrow +0.0746$ (40%).
- 신호는 그대로다. $+0.2107 \rightarrow +0.2160$ — 독립인 21건에서 같은 크기가 다시 나오고 $t=2.21$ 이다.
- 합침은 복제 안 된다. $t=1.19$.

그러니 노트 295의 근거가 무너진다. 노트 295가 합치기를 정당화한 근거는 “ t 가 $1.64 \cdot 1.58 \cdot 1.51$ 로 거의 같다”였다. 새 자료에서는 $+2.21 \cdot +0.70 \cdot -0.14$ 다. 그 일치 자체가 우연이었다 — $n \approx 30$ 에 짝SE 0.12~0.20 인 셋의 t 가 0.13 폭 안에 모이는 것은 신호가 아니라 요행이고, 나는 그 요행을 “서로 안 겹치는 세 실험이 같은 말을 한다”로 읽었다.

4. 남은 것은 하나다

층	판정	다음
신호	복제됨	왜 듣는지 갈라라
피쳐	절반 · 미결	표본 더
시장층	복제 안 됨	원래 수를 정정

세 층을 한 덩어리로 “주입”이라 부르면 $t=2.92$ 지만, 그 안에서 하나는 되고 하나는 부호가 뒤집힌다. 합침은 “무엇이든 넣으면 낫다”를 묻는 것이고, 그 물음은 무엇을 넣을지 정해 주지 않는다.

남은 것.

갈래	왜
신호를 갈라라	어느 신호가 듣나 — 아직 뭉치다
시장층 정정	노트 295의 $+0.32$ 를 새 수로
피쳐 표본 더	남은 라벨 62건
lab 회사 측	노트 294의 $+0.0040$

규약. 일치를 증거로 쓰기 전에 그 일치를 복제하라. 노트 295의 논증은 “서로 독립인 셋이 같은 값을 낸다”였고 그것은 강한 논증 형식이다 — 일치가 진짜라면, 각 t 의 짝SE 가 자기 값만큼 컸으므로 0.13 폭의 일치는 애초에 우연으로 설명된다. 합침이 답한 물음과 내가 알고 싶던 물음이 달랐다 — 나는 “무엇을 넣을까”를 묻고 있었는데 합침은 “무엇이든 넣을까”에 답했다.