

IP 파운데이션 월드모델 연구 노트 306

문서가 생긴 것은 나중 일이다

위키 축의 값은 사전인데 관측 표시자가 사후였다 --- 챔피언 판의 정정

Sweetspot 월드모델 연구

2026년 7월 31일

초 록

열려 있던 갈래 하나(“모바일 · 게임 검색 덮음 30~41%”)를 재려고 축 계열별 덮음을 켜더니 그 숫자부터 낱아 있었고(실제로 모바일 80% · 게임 74%) 대신 다른 것이 나왔다 — 위키 계열의 관측 표시자가 라벨을 예측한다(게임 유보 $\rho=+0.397$ · 애니 학습 $+0.301$ · 유보 $+0.243$, 연도 탓 아님). 구조를 읽으니 `wikiaxes._read` 는 문서를 못 찾으면 결측, 찾으면 관측으로 두고 `zero_is_data=True` 에서는 창이 비어도 관측이 선다. 그래서 마스크 = 굵은 시점(2026)에 위키 문서를 찾았나 이다. 값은 깨끗하다(창이 시작일 이전 90일) — 문제는 표시자다. 결정적 대조를 붙였다: 사전 창 조회수가 둘 다 0 인데 문서 유무만 다른 두 무리. 게임 유보 7.643 대 9.087($p=0.0008$) · 애니 · 웹툰 · 만화 · 세계애니까지 여덟 칸 중 여섯이 $p<0.01$ 이다. 출시 전 관심이 0 으로 같은데 라벨이 갈린다 — 사전 정보일 수 없다. 수선은 이미 있던 손잡이다: `zero_is_data=False` 로 두면 창에 조회수가 있어야 관측이므로 문서가 출시 전에 있어야 한다. 표시가 애니 유보 $0.243 \rightarrow 0.098$ · 웹툰 학습 $0.221 \rightarrow 0.03$ · 만화 $0.126 \rightarrow -0.011$ 로 준다. 대가는 판 $0.4851 \rightarrow 0.4799$ (-0.0052 · $t=-1.44$ · 문턱 0.0072, 못 가른다), 게임 -0.0321 · 애니 -0.0249 — 표시가 있던 자리에서만 난다. 내려가도 되돌리지 않는다. 개선이 아니라 정정이다. 배포했고 기준선을 다시 놓았다.

1. 다른 것을 재려다 걸렸다

열려 있던 갈래 중 하나가 “모바일 · 게임 검색 덮음 30~41% 제목 언어 한계”였다. 노트 301 이후로 물음이 달라진다 — 덮음은 그 도메인의 신호가 아니라 빌린 구조를 받을 수 있는 행의 수다. 그래서 계열별 덮음부터 켜다.

도메인	검색	위키	달력	태그
웹툰	98%	7%	100%	100%
애니	98%	33%	100%	100%
모바일	80%	9%	100%	0%
게임	74%	44%	100%	0%
세계애니	0%	53%	100%	0%
만화	0%	17%	100%	0%

갈래에 적힌 30~41% 가 낱았다. 그 갈래는 닫는다. 대신 같은 표를 만들다 표시자와 라벨의 상관을 같이 켜는데 거기서 걸렸다.

도메인	계열	구간	표시자~라벨	~연도
게임	위키	유보	+0.397	-0.176
애니	위키	학습	+0.301	+0.102
애니	위키	유보	+0.243	-0.039
웹툰	위키	학습	+0.221	-0.200
모바일	검색	학습	+0.173	+0.753
게임	검색	학습	+0.192	+0.285

위키 셋은 연도 탓이 아니다. 게임 유보는 오히려 -0.176 이다.

2. 마스크가 무엇을 뜻하나

`lab/wikiaxes.py` 를 읽었다.

문서를 못 찾음 (page None · 점수 미달 · 분류 불일치)	결측
문서 있음 · 창 비었음($n=0$)	관측 (값 0.0)
문서 있음 · 창에 조회수	관측

⇒ 마스크 = 굵은 시점(2026)에 위키 문서를 찾았나

2025년에 나온 게임이 2026년까지 위키 문서를 갖게 되는 것은 그 게임이 어떻게 됐는지의 결과다. 노트 224 가 `kitsu_rating` · `kitsu_rank` 를 막은 것과 같은 자리다.

값은 깨끗하다. 조회수 창은 시작일 이전 90일이고 당일 이후는 한 칸도 안 본다(노트 149). `provenance` 가 `wiki_*` 를 PRE 로 등록해 둔 것은 값에 대해 맞았고 표시자를 말하지 않았다.

3. 결정적 대조

사전 창 조회수가 둘 다 0 인데 문서 유무만 다른 두 무리를 견졌다. 둘 다 출시 전 위키 관심이 정확히 0 이다.

문서가 생긴 것은 나중 일이다




Figure 1: 왼쪽 — 사전 창 조회수가 둘 다 0 인 두 무리의 라벨 차이. 오른쪽 — 수선 전후의 표시자~라벨 상관.

도메인	구간	문서없음	문서□	p
게임	유보	7.643	9.087	0.0008 *
애니	학습	2.049	2.508	<1e-4 *
애니	유보	1.663	2.081	<1e-4 *
웹툰	학습	4.786	5.378	<1e-4 *
만화	학습	3.960	4.089	<1e-4 *
세계애니	학습	4.649	4.749	0.0008 *
모바일	학습	2.710	2.752	0.322
게임	학습	8.179	8.659	0.275

여덟 칸 중 여섯이 $p < 0.01$ 이다. 출시 전 관심이 같은데 라벨이 갈리므로 그 차이는 사전 정보일 수 없다.

4. 수선

손잡이는 이미 있었다 — `zero_is_data=False`. 창에 조회수가 있어야 관측으로 치고, 그러려면 문서가 출시 전에 존재해야 한다. 그러면 표시자가 “출시 전에 문서가 있었다”가 되어 사전이 된다.

도메인	구간	지금	수선
게임	유보	0.397	0.310
애니	학습	0.301	0.179
애니	유보	0.243	0.098
웹툰	학습	0.221	0.030
만화	학습	0.126	-0.011
세계애니	학습	0.147	0.136

애니 · 웹툰 · 만화는 사실상 사라진다. 게임 유보는 0.31로 남는데 그것은 남아야 하는 것이다 — 수선 뒤 표시자는 “출시 전에 문서가 있었고 조회수가 있었다”이고 그건 진짜 사전 관심이다.

대가.

	지금	수선	t
판	0.4851	0.4799	-1.44
게임	0.6214	0.5893	-2.23
애니	0.5012	0.4764	-2.27
세계애니	0.5336	0.5475	+1.79
나머지 일곱		$ t < 1.1$	

판 $\Delta = -0.0052$ 에 문턱 0.0072 — 못 가른다. 그리고 비용이 표지가 있던 두 도메인에서만 난다. 도메인 문턱 ($|t| > 2.77$)을 넘는 것은 없다.

내려가도 되돌리지 않는다. 배포 규칙(노트 275)은 개선을 거르는 장치다. 이것은 개선이 아니라 정정이고, 사전 등록에 그렇게 적어 뒀다. 배포했다 — `lab/loop.py`의 `_wiki` 기본값을 바꾸고, 축 정의가 바뀌었으므로 `denominator.json`에 새 기준선 0.4799를 명시적으로 다시 놓았다(노트 284의 규약). 지문도 바뀐다.

5. 검색 측은 왜 괜찮은가

같은 의심을 검색 계열에 붙여 보면 구조가 다르다.

위키	문서가 없으면 물어볼 대상이 없다
검색	물어보고 빈 계열을 받는다

수집기는 데이터랩에 검색어를 물어보고 빈 계열이 오면 그것을 “아무도 안 찾았다”로 기록한다 — 수집 시점의 진짜 측정이고, 창이 오픈 210일 전부터라 계열이

오기만 하면 오픈 이전 점이 반드시 넷 이상 나온다(노트의 `_state` 주석). 검색에서 마스크 0 은 그 레코드의 검색어를 아예 모른다는 뜻이지 결과가 아니다.

그래서 이것은 “모든 표시자가 의심스럽다”가 아니라 위키 하나의 구조적 문제다.

남은 것.

갈래	왜
표시자 감사를 가드로	표시자~라벨을 자동으로
게임 위키 0.31	진짜 사전인지 한 번 더
태그 · 달력 표시자	달력은 100% 라 상수
피쳐 위약	노트 302의 갈래 — 돌고 있다

규약. 축의 출처를 등록할 때 값과 표시자를 따로 물어라. `provenance` 가 `wiki_*` 를 “시작일 이전 90일”로 PRE 에 올려 뒀고 그 문장은 참이었다 — 값에 대해서만. `forms._design` 이 (값, 표시자) 쌍을 내므로 표시자는 별도의 열이고 별도의 출처를 가진다. 그리고 다른 것을 재려다 걸린 것을 그냥 지나치지 마라 — 오늘 덮음을 세려던 표에서 이것이 나왔고, 갈래에 적힌 숫자는 남아 있었다.