

장부를 만들었더니, 한 번도 채점 안 되는 도메인이 판을 누르고 있었다

월드모델 실험실

노트 356 · 2026년 8월 1일


초 록

갈라진 목록을 일곱 번 찾았는데 일곱 번 다 운이었다. `lab/listaudit` 는 모듈끼리 도메인 목록을 견주는데, 노트 354의 MKT2 는 도메인 이름이 양쪽에 다 있었고 갈라진 것은 행이었다(647 중 205). 그래서 **행 수 장부**를 붙였다 — 도메인마다 디스크 레코드 수와 축 파일 행 수를 견주고 15% 넘게 버리면 표시한다. 넷이 걸리고 넷 다 설명이 있다 (만화 비일본 611 — `manga_axes.py:118` 노트 79 · 도서 전자책 153 — 노트 35·253 · 시장팝업 — 노트 354가 고쳤다 · 아이돌 `chodong` 결측 107). 값은 소급에 있다: 노트 354 전에 돌렸으면 시장팝업 68%가 제일 큰 자리로 걸린다. 그런데 장부를 읽다가 아무도 안 묻은 것이 하나 나왔다 — 만화는 학습 1,783행인데 채점은 한 번도 안 된다(유보 6 < 문턱 20). 빼 봤다. 판 +0.0058(10/12) 이고 아이돌 +0.0754(11/12) · 애니 +0.0168(11/12) · 시장팝업 +0.0173(10/12) 이 오른다. 안 뻐다 — 대표 수치인 팝업이 -0.0340(2/12)이고 노트 275의 규칙은 판이 미결정 폭 안일 때 배포 쪽이 정한다고 말한다. 규칙이 정했지 내가 정한 게 아니다.

1. 장부

노트 335부터 354까지 갈라진 목록을 일곱 번 찾았다. 매번 다른 경로로, 매번 운으로. `lab/listaudit`(노트 337)이 그것을 검사로 만들려던 것인데 노트 354를 못 잡았다 — 그것은 도메인 목록을 견주고 MKT2 는 행 수준 구멍이었다.

장부를 만들었더니, 한 번도 채점 안 되는 도메인이 판을 누르고 있었다



장부는 도메인마다 두 수만 건준다. 판정하지 않는다 — 버리는 데는 옳은 이유가 많다. 표시하고, 근거를 찾는 것은 사람 몫이다.

도메인	레코드	축	버림	근거
아이돌	282	81	71%	chodong 결측 107 (idolset 은 173행을 직접 읽는다)
시장팝업	647	249	62%	단일 행사 아님 · 방문객 없음 (노트 354)
도서	396	243	39%	전자책 153 (노트 35 · 253)
만화	2,400	1,789	26%	비일본 611 (KEEP_COUNTRY, 노트 79)
세계애니	2,988	2,948	1%	—
웹툰 · 애니 · 모바일 · 게임 · 편딩			0%	—

지금 돌리면 새로 나오는 것이 없다. 노트 354가 마지막 구멍을 메웠기 때문이다. 값은 소급 검증에 있다 — 노트 354 전에 돌렸으면 시장팝업이 68%로 제일 크게 걸렸을 것이고, 일곱 번을 운으로 찾는 대신 한 번에 봤을 것이다.

정정 하나. 처음에 만화를 “어디에도 안 적혀 있다”로 적었는데 틀렸다. 노트에 없었을 뿐 ingest/manga_axes.py:118 에 근거까지 다 있다 — KR 556건은 자기 순위 상관이 +0.083 으로 일본 작품(+0.477)의 6분의 1이고, 라벨이 세계 독자의 서재 등록 수라 한국 작품은 영어 번역 유무에 지배된다. 장부는 제 일을 했다 — 표시했고, 읽어 보니 설명이 있었다.

2. 읽다가 나온 물음

표를 보다 걸린 것은 버림이 아니라 다른 수였다. 만화는 학습 1,783행인데 유보가 6행이라 evaluate 의 문턱 20을 못 넘어 한 번도 채점되지 않는다. 판 가중에도 안 들어간다. 그런데 학습에는 들어간다 — 전체 학습 10,483행의 17%다.

채점 안 되는 도메인이 공유 적합에 무엇을 하는지 아무도 안 물었다. 노트 252가 “풀링은 타협이 아니라 이득”을 보였지만 그것은 채점되는 도메인들 얘기였다. 빼 봤다 — 열두 번 짝 뽑기.

만화를 빼면	차	SD	부호
판	+0.0058	0.0058	10/12
아이돌	+0.0754	0.0517	11/12
시장팝업	+0.0173	0.0202	10/12
애니	+0.0168	0.0111	11/12
편딩	+0.0128	0.0387	7/12
웹툰	+0.0092	0.0126	10/12
게임	+0.0064	0.0167	10/12
세계애니	-0.0018	0.0130	6/12
모바일	-0.0027	0.0068	4/12
도서	-0.0331	0.0542	4/12
팝업(대표)	-0.0340	0.0367	2/12

+0.0058 은 노트 349 · 350 · 351을 다 합친 것(+0.0079)에 가깝다. 여덟 도메인 중 여섯이 오르고 아이돌은 +0.0754 다.

3. 그런데 안 뺀다

노트 275의 규칙은 이렇다. ① 판이 미결정 폭(0.010) 안이고 ② 어느 도메인도 $|t| > 2.77$ 로 안 나빠지면, 배포 쪽 이득이 정한다.

① 판 +0.0058 < 0.010 — 미결정이다. ② 제일 나쁜 팝업이 -0.0340/0.0367 로 $|t| = 0.93$ — 문턱 안이다. 그래서 규칙은 “판이 정하지 못한다, 배포가 정하라”로 넘긴다. 배포 수치는 팝업이고 팝업은 -0.0340(2/12)이다. 안 뺀다.

노트 351과 방향이 정확히 반대이고 규칙은 같다. 그때는 판이 +0.0002 로 미결정이었고 팝업이 +0.0168(11/12)이라 넣었다. 지금은 판이 +0.0058 로 미결정이고 팝업이 내려가서 안 뺀다. 규칙이 두 번 다 정했고 두 번 다 판이 아니라 배포가 정했다 — 판이 미결정 폭 안에서 움직이는 한 판은 결재권이 없다.

그리고 노트 352가 여기에도 걸린다. 팝업 -0.0340 의 SD 가 0.0367 이다 — 못 가린다. 판 +0.0058 도 SD 0.0058 이다. 이 결정은 못 가리는 둘 사이에서 규칙으로 갈랐다. 규칙이 없었으면 어느 쪽이든 고를 수 있었고, 그게 규칙을 미리 적어 두는 이유다.

4. 만화는 나쁜 가운데 자리에 있다

만화는 학습에 들어가고 채점에는 안 든다. 그 자리가 +0.0058 짜리다. 나가는 문이 둘인데 둘 다 안 열려 있다.

하나 — 뻔다. 판이 오르지만 대표가 내려가 규칙이 막았다.

둘 — 채점되게 만든다. 문턱 20을 넘기려면 유보 20행이 필요한데 지금 6행이다. 버린 611건 중 2025년이 10건이라 다 넣어도 16행이고, 그나마 그 611건은 노트 79가 근거를 대고 뻔 것이다. 2026년 만화 레코드가 아예 없다 — 굶어야 한다.

둘째가 옳은 문이다. 만화는 유일하게 “자료는 많은데 최근에 없어서” 못 채는 도메인이고, 2026년 것을 스무 건만 더 모으면 열한 번째 채점 도메인이 된다. 그것은 판을 +0.0058 올리는 일보다 크다 — 노트 352가 센 것처럼 지금 마흔다섯 쌍 중 스물아홉이 순서가 안 갈리는데, 도메인이 하나 더 서면 그 분모부터 바뀐다.

5. 규약에 더하는 줄

- 목록 대조는 이름이 아니라 행으로 한다. 도메인 이름이 양쪽에 있어도 행이 갈릴 수 있다 — 노트 354가 그랬다.
- 장부는 표시만 하고 판정하지 않는다. 넷이 걸렸고 넷 다 근거가 있었다. 근거가 코드 주석에 있고 노트에 없어도 근거다.
- 학습에만 들어가는 도메인은 따로 센다. 만화 1,783행이 전체 학습의 17%이고 판 +0.0058 짜리인데, 그 도메인은 점수표에 한 줄도 안 나온다.

6. 남은 것

갈래	지금 아는 것
만화 2026 스무 건	열한 번째 채점 도메인이 된다. 다음 순번
만화가 왜 누르나	라벨 종류(선호형)로는 안 갈린다 — 뻔을 때 선호형 웹툰 +0.0092 · 세계애니 -0.0018 로 엇갈린다
MKT2 나머지 195건	라벨 · 기간 없음. 원천 크롤에도 없다(107/338만 방문객)
추가 2026 아홉 행	노트 353. 아이돌 라벨 수준이 한터와 반대

둘째 줄은 열어 둔다. “왜 누르나”를 못 밝혔고, 라벨 종류 · 도메인 수 · 행 수 중 무엇인지 가르려면 만화를 절반 · 4분의 1로 줄여 가며 재야 한다. 그건 판을 올리는 일이 아니라 아는 일이라 순번이 뒤다.