

목록이 정렬돼 있으면 표본을 늘려도 늘어난 쪽이 다른 모집단이다

월드모델 실험실

노트 374 · 2026년 8월 1일

초 록

노트 373이 “이제 남은 것은 수집뿐”이라 적고 편당을 버림 0% — 이미 다 쓴다로 분류했다. 틀렸다. 축이 레코드를 100% 쓰는 것은 맞지만 레코드가 77,515건 중 400건이다. 늘리러 갔다가 더 큰 것이 나왔다.

텀블벅 목록은 인기순으로 정렬돼 있다. 캐시된 3,875쪽에서 쪽 번호와 라벨(log10 후원자)의 순위 상관관계는 -0.3666 이다(쪽 50~161 중앙 2.56 대 531~753 중앙 1.93). 우리 400건은 쪽 50~753 — 위에서 19% 에서 왔다. 그래서 표본을 늘리면 늘어난 쪽이 체계적으로 다른 모집단이 된다: 옛 400 대 새 180 의 라벨 중앙이 2.14 대 2.46, 맨휘트니 $p = 1.5 \times 10^{-13}$.

그리고 내 대표성 검사가 두 번 다 통과했다 — 연도 분포로만 봤기 때문이다(2025+ 비율 20% 대 19%). 섞은 유보로 재면 편당이 0.4195 → 0.6019 로 뛰는데, 무리 안에서 다시 순위를 매기면 +0.4385 다. 0.16 이 표집 구조였다.


수집 정렬이 과제를 정한 네 번째 도메인이다(도서 베스트셀러 · 모바일 인기 차트 · 만화 인기순 · 편당). 고침은 싸다 — 목록 전체가 이미 캐시에 있다(자격 있는 것 75,434건, 그중 2025년 이후 13,030건). 균일 무작위 표집기를 만들어 돌리는 중이다.

1. 노트 373을 정정한다

노트 373이 편당을 이렇게 적었다: 레코드 400 = 축 400, 버림 0%. 유보 80은 2025+ 가 그만큼뿐 → 새 수집만. 앞은 맞고 뒤가 틀렸다 — “2025+ 가 80건뿐”은 세계에 대한 사실이 아니라 --want 400 에서 멈춘 결과다. 목록에는 77,515건이 있다.

2. 목록이 정렬돼 있다

목록이 정렬돼 있으면 표본을 늘려도 늘어난 쪽이 다른 모집단이다



캐시된 목록 3,875쪽 · 77,495건에서 각 레코드의 출처 쪽을 붙여 봤다.

쪽 구간	n	라벨 중앙
50~161	140	2.56
161~253	140	2.41
253~346	140	2.28
346~531	130	2.12
531~753	140	1.93
쪽 ↔ 라벨 순위 상관 -0.3666		

`funding_domain.run` 은 `range(50, 3876, stride)` 를 돌면서 후보가 차면 멈춘다. `--want 400` 이면 스물몇 쪽에서 멈추므로 목록 맨 위 19%만 본다.

보폭을 바꿔도 안 고쳐진다. 처음엔 “보폭 7이라 앞쪽만 봤다”로 읽고 보폭을 자동 조정하게 고쳤는데, 다시 받은 180건도 라벨 중앙 2.46 에 $p = 1.5 \times 10^{-13}$ 이었다. 어느 보폭이든 앞에서부터 채우면 같다.

3. 연도 검사는 통과하고 라벨 검사는 실패한다

사전 등록에 대표성 확인을 적어 뒀다 — 새로 받은 것의 연도 분포가 기존과 비슷한지 먼저 본다. 통과했다(2025+ 비율 20% 대 19%, 두 번 다). 그런데 라벨이 같았다.

	옛 400	새 180	
2025+ 비율	20%	19%	통과
라벨 중앙(log10 후원자)	2.14	2.46	$p = 1.5 \times 10^{-13}$ 실패
사분위	[1.83, 2.50]	[2.24, 2.73]	

규약: 표본을 늘렸으면 라벨 분포를 건준다. 연도는 정렬과 무관할 수 있고, 실제로 여기서는 무관했다.

4. 섞으면 점수가 부풀려진다

두 무리를 한 유보에 넣고 재면 편당이 $0.4195 \rightarrow 0.6019$ 로 된다. 갈라 보면:

유보 부분집합	n	ρ	95% 구간
옛 80행	80	+0.4513	[0.241, 0.636]
새 105행	105	+0.4281	[0.247, 0.581]
전부 185행	185	+0.5988	[0.487, 0.696]
무리 안에서 다시 순위		+0.4385	

전체가 두 부분집합 어느 쪽보다도 높다. 라벨 중앙이 1.95 대 2.46, 예측 중앙이 236.8 대 570.2 로 같은 방향이라 모형이 두 무리를 옳게 갈라 놓고, 그 무리 사이 순위가 ρ 에 얹힌다. 0.16 이 표집 구조다.

노트 353 · 357 · 372와 같은 집안이고 부호가 반대다. 거기서는 두 모집단이 섞여 ρ 를 무너뜨렸고, 여기서는 부풀린다. 두 모집단이 섞이면 점수는 어느 쪽으로든 움직인다 — 낮아지는 것만 의심하면 안 된다.

5. 고침은 싸다

목록 전체가 이미 캐시에 있다 — 3,875쪽 · 77,495건 · 자격 있는 것 75,434건(97%)이고 그중 2025년 이후가 13,030건이다. 목록 호출 없이 균일 무작위로 뽑아 리워드만 받으면 된다. ingest/funding_sample.py 를 만들어 씨앗을 박고(노트 367의 재현 조항) 돌리고 있다. 지금까지 받은 것은 쪽 474~2974(중앙 1814)에 퍼져 있다 — 옛 400의 50~753 과 다르다.

챔피언은 안 건드렸다. 균일 표본은 funding_uniform.json 에 따로 쌓고, 다 모인 뒤 짝으로 재고 바꾼다.

6. 규약에 더하는 줄

- 목록을 앞에서부터 채우지 마라. 정렬돼 있으면 표본이 한쪽이 된다. 무작위로 뽑거나 전 구간을 훑는다.
- 대표성은 라벨로 확인한다. 연도 · 분야는 정렬과 무관할 수 있다 — 여기서 두 번 다 통과했다.
- 두 모집단이 섞이면 점수가 오를 수도 있다(353 · 357 · 372는 내려갔고 여기는 올라간다). 오르는 것도 의심한다.
- “버림 0%”는 다 썼다는 뜻이 아니다 — 무엇을 못 모았는지는 안 나온다.

7. 남은 것

갈래	지금 아는 것
균일 편당 2,500건	돌고 있다. 다 모이면 짝으로 재고 바꾼다
다른 세 도메인의 정렬	도서 베스트셀러 · 모바일 인기 차트 · 만화 인기순. 같은 검사를 각각 돌린다
팝업 실측 41행	노트 360 · 364 · 366

둘째 줄이 이 노트가 여는 것이다 — 정렬 편향이 네 도메인에서 확인됐으니, 각 도메인의 라벨이 수집 순서와 얼마나 상관되는지를 한 번에 채는 것이 다음이다.