

옆방에도 못 건너간다 — 같은 플랫폼 · 같은 자 · 같은 해, 나라만 다른 도메인

월드모델 실험실

노트 398 · 2026년 8월 2일

초 록

노트 397이 안 본 도메인(비게임 앱)에서 전이 ≈ 0 을 보고, 한계를 크게 적었다 — 비게임 앱은 IP 출시가 아니라서 의도한 범위보다 어려운 시험일 수 있다. 그 도피로를 막는 시험을 찾았다.

이미 갖고 있었다. `manga_axes` 는 국가 필터로 JP 만 남긴다. 그래서 AniList 한국 만화 1,716행이 한 번도 학습에 안 들어갔다. 같은 플랫폼 · 같은 라벨(서재 등록 수) · 같은 매체 · 같은 축 코드 — 나라만 다르다.

2025년 이후 유보에서 재면 라벨 퍼짐이 0.266 대 0.264(비 1.01), 중앙이 3.096 대 3.054 로 짝이 저절로 맞는다.

	행	라벨 SD	모형 ρ	편상관(날짜 통제)
JP 만화 (학습에 든 도메인)	258	0.264	+0.3250	+0.3196
KR 만화 (한 번도 안 본 도메인)	322	0.266	-0.1220	-0.1261

+0.32 에서 -0.13 이다. 전이가 약한 게 아니라 음수다.

그리고 거리로 줄이 안 선다 — 먼 도메인(비게임 앱)이 +0.08 인데 가까운 도메인(KR 만화)이 -0.13 이다. “앱은 너무 멀었다”는 설명이 여기서 죽는다. 가르치는 것은 거리가 아니라 그 행들이 학습에 들었나.

다른 것은 하나뿐이다. 플랫폼 · 라벨 자 · 매체 · 시기 · 라벨 퍼짐 · 라벨 중앙 · 축 · 모형이 전부 같고, 그 나라 행이 학습에 들었는지만 다르다.

1. 왜 이 짝이 좋은가

노트 397의 약점은 도메인이 하나이고 그 하나가 유틸리티 앱이었다는 것이다. 공유 축 다섯(타깃 폭 · 장소 격 · 진입 마찰 · 매체 밀기 · 굵즈 규모)이 가계부 앱에서 무슨 뜻인지 애매하니, 전이가 0 인 것이 모형이 못 건너가서인지 축이 그 도메인에서 무의미해서인지 갈리지 않았다.

KR 만화는 그 애매함이 없다. 축이 채는 것이 화수 · 권수 · 태그 수 · 작가 수인데 한국 만화에서도 똑같은 뜻이다. 라벨도 같은 사이트의 같은 계수기다. 축과 라벨이 뜻을 유지하는 채로 학습 여부만 바뀌는 짝이라 노트 397이 못 가른 것을 가른다.

2. 켜다

`manga_axes` 의 국가 필터를 KR 로 돌려 축을 만들었다(코드는 한 줄도 안 고쳤다 — 상수만 바꿨다). 챔피언 $F18(K=32)$ 을 열한 도메인 학습 행으로만 적합하고, 두 무리를 같은 절차로 켜다:

- 공유 축 다섯만 — KR 은 트렌드 · 위키가 없으므로 JP 도 못 쓰게 막는다(노트 397의 대조).
- 날짜 통제 편상관 — 라벨이 누적이라 날짜가 섞인다.
- 씨앗 여섯 순위 평균 — 노트 395.
- 2025년 이후 유보만 — JP 쪽이 학습에 안 든 행이어야 한다.

퍼짐을 맞추려고 아무것도 안 했는데 맞았다. KR 0.266 · JP 0.264 (비 1.01), 중앙 3.096 · 3.054, 범위 2.80 ~ 4.12 · 2.80 ~ 4.35. 노트 376 이후 퍼짐 대조를 손으로 만들어 왔는데 이번에는 자연히 짝이다.

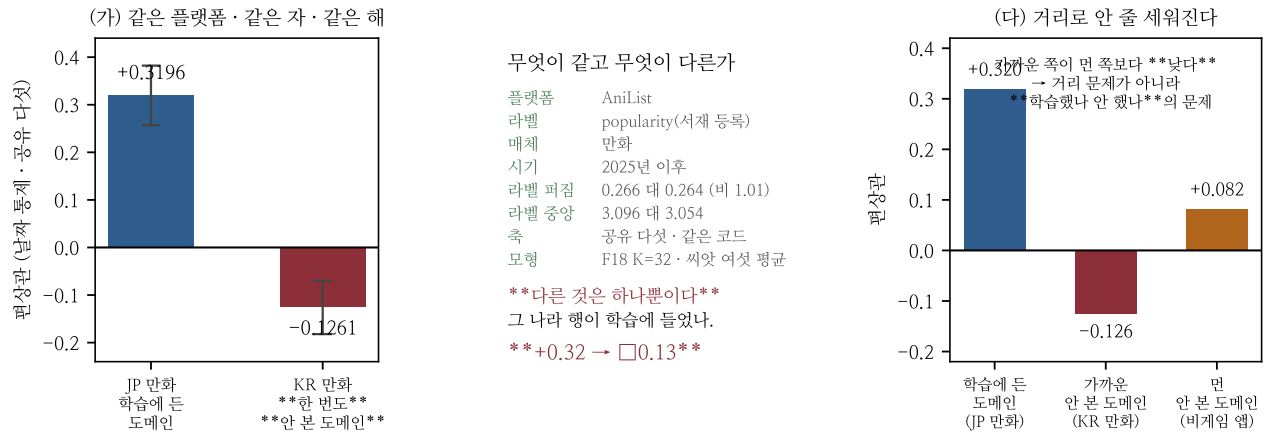


Figure 1: (가) 짝 맞춘 두 무리. 막대는 $1/\sqrt{n}$. (나) 여덟 가지가 같고 하나만 다르다. (다) 거리로 줄이 안 선다 — 가까운 쪽이 먼 쪽보다 낮다.

3. 읽는 법

첫째, 전이가 음수다. -0.1261 ± 0.056 이라 0 과도 구별된다. 모형이 KR 만화에서 거꾸로 줄을 세운다. 노트 372가 만화 KR 을 -0.16 으로 썼던 것이 다른 절차에서 재현됐다.

둘째, 거리가 설명이 아니다. 노트 397의 앱은 훨씬 먼 도메인인데 $+0.08$ 이고 KR 만화는 옆방인데 -0.13 이다. 거리로 정렬되지 않으므로 “더 가까운 도메인을 고르면 된다”는 길이 막힌다.

셋째, 무엇이 남았다. 도메인 원hat이다. F18 은 도메인마다 원hat을 하나씩 갖고, 모르는 도메인에는 전부 0 을 준다. 그러면 예측이 공유 계수만으로 나오는데, 그 공유 계수가 열한 도메인의 평균이라 어느 한 도메인에도 잘 안 맞는 것으로 읽는다. 다만 이것은 관측이 아니라 설명이라 다음 노트로 넘긴다 — 원hat을 켜고 켜을 때의 차를 재면 갈린다.

4. 그래서 판을 어떻게 읽나

판 0.4476 은 “열한 도메인 안에서”의 수다. 그 밖으로 나가면 $+0.08$ (먼 도메인) 또는 -0.13 (옆방)이다. 두 번 다 재 봤고 두 번 다 0 이하다.

그러면 판정치의 이름을 고쳐야 한다. 지금까지 대장에 “판”이라고만 적어 왔는데, 이 수가 뜻하는 것은 학습에 든 도메인 안에서의 평균 순위 상관이다. 대장과 노트에 “판(학습 도메인 안)” 으로 적는다. IP 파운데이션이라는 목표는 그 밖을 주장하는 것이고, 그 주장은 지금 증거가 없다.

안 바꾸는 것. 관문은 그대로다 — 두 팔을 같은 도메인 집합에서 짝지어 견주는 데는 이 문제가 안 생긴다. 이번 사이클의 채택들(펀딩 · 웹툰 · 만화 · 애니 학습 확장, $K=32$)은 전부 그 틀 안이라 영향이 없다.

5. 남은 것

항목	왜 값이 큰가	어떻게
원hat이 범인인가	유일하게 남은 설명	원hat 끄고 학습해 KR 을 다시 쟀다
KR 을 넣으면 사나	넣으면 되는지가 실무 답	KR 학습 추가 후 재측정
세 번째 짝	둘로는 아직 얇다	CN 만화 352행이 같은 자리에 있다
판정치 이름	지금 이름이 과장한다	대장·노트 표기 바꾸기