

원hat의 0 은 무지의 정직한 표시였다 — 모르는 걸 계산해 주자 더 나빠졌다

월드모델 실험실

노트 442 · 2026년 8월 2일

초 록

노트 441 이 채택한 것은 휴전이였다 — 안 배운 수집에는 `entry_friction` 을 안 쓴다. 그런데 그 측은 도메인 안에서는 값이 크다(모바일 +0.648 · 도서 +0.273). 못 쓰는 이유는 정보가 없어서가 아니라 어느 쪽으로 읽을지를 모르기 때문이고, 집 안에서 그걸 알려 주는 원hat과 `grp` 이 집 밖에는 둘 다 없다(원hat은 전부 0, `grp` 은 값 자체가 없다).

그래서 새 수집이 자기 행으로 계산할 수 있는 표지를 줘 봤다 — 그 수집의 `entry_friction` 평균과 SD. 새 수집도 자기 행에서 바로 계산되니 원hat과 달리 집 밖에서도 값이 있다. 등록한 문장은 “가리지 않고도 가림보다 낫거나 같다” 였다.

반증됐다. 그것도 크게. 표지를 주자 두 짝 다 더 나빠졌다.

팔	KR 만화	비게임 앱
가 · 기준 (가림 없음)	+0.3206	-0.0501
나 · 가림 (노트 441 이 채택)	+0.5336	+0.2635
다 · 평균표지	+0.2033	-0.2905
라 · 평균표지 + 가림	+0.5450	+0.2802

앱은 -0.050 에서 -0.291 로 갔다. 아무것도 안 준 것보다 나쁘다.

1. 왜 나빠지나 --- 마지막 줄이 진단이다

네 번째 팔이 답을 준다. 가림을 같이 걸면 평균표지는 무해해진다 (+0.5450 · +0.2802 — 가림만 한 것과 사실상 같다). 즉 표지 자체가 독인 게 아니라 표지가 독 있는 축을 쓰게 만든다.

기제는 이렇다. 상수 열은 노트 412 가 말한 대로 도메인 이름표를 한 번 더 적는 것이다. 나무는 그 값으로 갈라 도메인마다 다른 규칙을 학습한다. 집 안에서는 원hat과 겹쳐 아무것도 안 늘지만, 집 밖에서는 겹칠 원hat이 없다. 새 수집의 평균값은 학습한 어느 도메인 근처에 떨어지고, 모델은 그 도메인의 규칙을 자신 있게 갖다 쓴다. KR 의 평균 0.268 은 만화(0.112)와 편딩(0.396) 사이에, 앱의 0.295 도 같은 자리에 떨어진다 — 그리고 그 자리의 규칙은 KR 의 부호(-0.320)와 반대다.

원hat이 전부 0 인 것은 결함이 아니라 성질이였다. 그것은 “모른다”를 정직하게 적는다. 계산되는 표지는 “이 근처다”라고 적고, 근처가 틀리면 모델은 틀린 쪽을 확신한다. 노트 399 이래 원hat을 여러 번 범인으로 몰았는데, 집 밖에서는 원hat의 0 이 오히려 안전장치다.

2. 채택 판정

아무것도 안 바꾼다. 팔 라(표지 + 가림)가 팔 나보다 두 짝에서 +0.0114 · +0.0167 높지만, 이 크기는 집 밖 짝 둘의 차이를 가를 자가 없다 — 노트 441 이 만든 규약대로 집 밖 효과는 집 밖 쪽으로 재는데, 짝이 둘뿐이고 차이가 채택된 효과(+0.21 ~ +0.31)의 5% 다. 판은 이 변경도 못 본다. 유지: “예보 때 `entry_friction` 만 가리는 F18”.




Figure 1: 두 집 밖 쪽에서 네 팔. 초록(가림)이 노트 441 이 채택한 것이고, 빨강(평균표지)이 이번에 시험한 대안이다. 대안은 기준보다도 아래로 내려간다. 파랑(표지 + 가림)이 초록과 거의 같은 것이 진단이다 — 표지가 해로운 것은 오직 독 있는 축이 켜져 있을 때다.

남은 것

- 어느 쪽으로 읽을지를 알려 주는 다른 방법. 계산되는 표지는 죽었다. 남은 후보는 부호 자체를 새 수집에서 추정하는 것 — 라벨 몇 개만 있으면 짝 안 부호를 재서 축을 뒤집을 수 있다. 그건 완전한 영샷이 아니라 몇 샷이다. 값이 얼마나 되는지, 라벨 몇 개면 되는지는 안 재 봤다.
- CN 이 왜 안 오르나 — 독을 안 먹었는데 +0.2249 다. 라벨 분포(SD 0.485 · 왜도 1.84)가 마지막 후보다.
- LODO 씨앗 셋→아홉 — 다섯 노트째 미룸.