

싼 자는 한쪽만 증명한다 — 적합도를 안 사면 안전하고, 사면 알 수 없다

월드모델 실험실

노트 475 · 2026년 8월 3일

초 록

노트 474가 조항을 하나 만들었다 — 용량 변경이 판에서 비기면 다른 자 최소 둘로 확인한다. 옳지만 후보마다 40분이 든다. 그래서 값싼 앞자를 찾았다: 학습 적합도와 원핫 의존도 — 둘 다 유보 라벨도 집 밖 짝도 안 쓴다.

등록한 문장은 “판이 비기는데 적합도가 크게 오르면 위험”이었다.

후보	적합도 차	원핫 의존 차	여섯 자 판정
it 400	+0.0434	+0.0016	다섯에서 없음
lr 0.16	+0.0351	+0.0009	여섯 다 비김
K 64	+0.0001	+0.0002	여섯 다 비김
깊이 24	+0.0007	-0.0002	비김

반증이다. lr 0.16이 it 400의 81%만큼 적합도를 사는데 여섯 자에서 무해하다. 적합도 상승만으로는 둘을 못 가른다. 원핫 의존도도 1.8배 차이로 마찬가지다.

그런데 표가 한쪽으로는 깨끗하다.

1. 반쪽짜리지만 쓸모가 있다

적합도를 안 사면 안전하다 — K 64(+0.0001)와 깊이 24(+0.0007)는 여섯 자에서 아무 일도 안 했다.

적합도를 사면 알 수 없다 — it 400(+0.0434)은 다섯에서 잃고 lr 0.16(+0.0351)은 안 잃는다.

논리로 적으면 적합도 상승 ≈ 0 은 무해함의 충분 조건처럼 보이고(관측 2/2), 해로움의 필요 조건이다 — 판을 속이려면 뭔가 더 맞혀야 하니까.

그래서 앞자로 쓸 수 있다. 다만 통과가 아니라 건너뛰기로.

조항 — 용량 변경의 학습 적합도 상승이 잡음 크기면 (여기서는 +0.001 아래) 노트 474의 비싼 확인을 건너뛴다. 그보다 크면 반드시 비싼 확인을 한다 — 싼 자는 그 안에서 아무것도 못 가른다.

2/2는 적은 근거다. 그래서 건너뛰기로만 쓰고, 건너뛴 변경은 장부에 “싼 자로만 봤음”이라 적어 둔다. 반례가 하나 나오면 조항을 버린다.

2. 왜 lr은 사고도 안 해로운가

이것이 이 노트가 못 푼 것이다. it과 lr은 노트 459 ~ 461에서 계속 같은 무리로 묶였는데(용량 가족 · 환율 0.62 ~ 0.54), 여섯 자로 보면 다르다. lr 0.16은 적합도를 +0.035 사고 아무 데서도 안 잃는다 — 산 것이 어디로 갔는지 이 노트의 자로는 안 보인다.

가설 하나만 적어 둔다. lr은 보폭이라 같은 나무를 더 멀리 밀 뿐 구조를 안 바꾸고, it은 나무 수라 새 갈래를 계속 만든다. 새 갈래가 무리 사이를 파고들 자리다. 안 잤다.




Figure 1: 초록 칸(적합도를 안 사는 쪽)에 든 둘은 둘 다 무해했고, 빨강 칸에 든 둘은 하나만 해롭다.

남은 것

- lr 이 산 적합도는 어디 있나 — 여섯 자 어디에도 안 나온다. 자가 모자란 것인지 진짜 아무 데도 안 가는 것인지.
- 건너뛰기 조향의 반례 찾기 — 적합도를 +0.001 아래로 사면서 여섯 자 중 하나를 잃는 변경이 있다. 있으면 조향이 죽는다.
- 축 추가에도 걸리나 — 지금 조향은 용량 변경에만 걸었다.