

압축된 라벨 — 무리로 보면 보이는 것이 행으로는 안 보인다

월드모델 실험실

노트 484 · 2026년 8월 3일

초 록

노트 483 이 부정으로 끝났다 — “행이 원래 어렵다”를 우리가 쟀 어떤 변수로도 못 쥔다. 그래서 모형을 놓고 레코드를 열었다.

첫 줄에서 나왔다. venue_prominence 가 없는 487행은 production 이 100% 비어 있고 있는 119행은 채워져 있다. 그 축의 유무는 작품 성질이 아니라 수집 사정 — 어느 레코드에 풍부한 출처가 붙었나 — 이다. 따라오는 것들도 그렇다: 태그 중앙 8 대 5 · 갈래 3 대 2 · 리뷰 수 76 대 61.

그리고 하나가 더 있었다. 라벨 SD 가 0.586 대 0.721 로 좁다.

무리	n	라벨 SD	rho
venue 없는 487	487	0.721	+0.5877
487 중 무작위 440	440	—	+0.5881
487 중 SD·평균 맞춘 440	440	0.570	+0.5265
venue 있는 119	119	0.586	+0.4894

라벨 분포만 맞추면 격차의 62% 가 사라진다. 같은 크기 무작위는 +0.5881 로 그대로이니 크기 탓이 아니다.

1. 노트 483 과 어긋나지 않는다

노트 483 은 행 단위로 극단성을 재서 $|\text{rho}| 0.088$ 을 얻고 “못 쥔다”고 적었다. 이 노트는 무리 단위로 라벨 퍼짐을 맞춰 62% 를 설명한다. 둘은 같은 사실의 두 얼굴이다.

행 하나하나의 자기 라벨이 가운데인지 끝인지로 조금밖에 안 갈리지만, 무리 전체의 라벨이 좁으면 그 안에서 순위를 매길 거리가 통째로 줄어든다. 앞엿것은 상관으로 재고 뒤엿것은 퍼짐으로 재야 한다.

조항 — 무리끼리 rho 를 건줄 때는 라벨 퍼짐을 맞추고 건준다. 안 맞추면 썰 것이 적은 무리를 모형이 못하는 무리로 읽는다.

2. 이것이 노트 470 에 걸린다

노트 470 이 무리 안 판을 만들었다 — 도메인을 갈래로 갈라 0.4969 $\rightarrow$ 0.4377. 그때 대조는 같은 크기 무작위였고 (0.4932), 그래서 “크기가 아니라 동질성”이라 읽었다.

그 동질성의 상당 부분이 라벨 압축일 수 있다. 갈래 무리는 크기만 작은 게 아니라 라벨도 좁다 — 무작위 쪼개기는 전체 퍼짐을 그대로 보존한다. 이 노트의 애니 사례에서 그 뒤통이 62% 였다.

그러면 노트 470 의 읽기가 바뀐다. “판이 무리 사이 순위에 기댄다”(모형을 탓하는 읽기)에서 “무리 안에서는 썰 것이 적다”(자료를 적는 읽기)로. 무리 안 판이라는 자 자체는 남지만 그 낮은 값을 실력 부족으로 읽으면 안 된다.

안 썰다. 다음 노트의 일이다 — 갈래 무리마다 라벨 퍼짐을 맞춘 대조를 놓고 -0.0555 중 얼마가 압축인지 재야 한다.




Figure 1: 가 — 무리의 라벨 SD 와 그 무리 안 rho, 나 — -0.098 의 분해.

남은 것

- 노트 470 을 라벨 퍼짐 맞춰 다시 — 위에 적은 그대로. 이 사이클에서 만든 자 하나의 뜻이 걸려 있다.
- 남은 38% — 라벨 퍼짐을 맞춰도 119행이 $+0.5265$ 대 $+0.4894$ 로 낮다. 아직 모른다.
- **production** 이 붙은 레코드가 왜 라벨이 좁나 — 많이 기록된 작품끼리는 서로 비슷하다는 뜻일 수 있다. 수집 갈래.