

한 자 차이로 서른 배 — 두 해 묵은 [:20] 이 제일 값비싼 자료의 목을 조르고 있었다

월드모델 실험실

노트 491 · 2026년 8월 3일

초 록

노트 490 이 검색 시계열에 판 -0.0283 을 매겼다 — 두 해 동안 채택한 어떤 모형 변경보다 여섯 배 크다. 그런데 그 자료의 덮음은 아홉 도메인 합계 41.7% 다. 열린 갈래는 두 해째 “모바일 · 게임 검색 덮음 30 ~ 41% 는 제목 언어 한계”라고 적혀 있었다.

언어가 아니었다. 만화는 제목의 한글 비율이 0.000 (전부 라틴)인데 5% 가 붙고, 세계애니도 0.000 인데 18% 가 붙는다. 게임은 붙는 쪽이 오히려 라틴 비율이 0.378 더 높다.

열 도메인 전부에서 일관된 신호는 하나뿐이었다 — 길이. 그리고 길이를 파고 들어가니 `ingest/trend_all.py` 의 한 줄이 나왔다.

```
return (han[0] if han else segs[0])[:20]
```

조각을 고른 뒤에 스무 자에서 자른다 — 낱말 한가운데서. “Family Go! - 대를 잇는 인생게임”이 “Family Go! - 대를 잇는 인”이 되고, 데이터랩은 그런 질의에 아무것도 안 돌려준다.

자르기 전 조각 길이	행	시계열이 붙음
정확히 20 자 (안 잘림)	164	18.3%
정확히 21 자 (한 자 잘림)	165	0.6%

한 자 차이에 서른 배(피서 $p = 1.1 \times 10^{-22}$ · 승산비 29.2).

1. 첫 읽기는 거의 들렸다

처음엔 질의 문자열의 길이로 켜다. 열 도메인 중 아홉에서 최대 길이가 정확히 20 이고(만화 60% · 편딩 49% · 세계애니 45% 가 그 20 에 몰려 있다), 17 ~ 19 자는 25.0% 가 붙는데 20 자는 2.4% 였다.

그런데 그것만으로는 못 말한다. 잘린 조각의 진짜 길이는 중앙 22 ~ 29 자다. 붙는 비율은 길이에 따라 원래 매끄럽게 내려가므로 (6 자 62.9% → 19 자 23.6%), 진짜 길이 25 자쯤이면 2.4% 는 그 기울기의 연장일 수 있다.

그래서 자르기 전 길이로 다시 그렸다. 20 자 미만은 매끄러운 로짓 직선이고(기울기 $-0.132/\text{자}$), 넘는 순간 그 직선 아래로 떨어진다 — 20 자 이상 전체가 실제 2.8% 대 예측 11.2% 로 $-8.4\%p$. 경계 바로 양옆(20 자 대 21 자)에서 서른 배 차가 난다.

조항 — 절단을 의심할 때는 자르기 전 값으로 켜다. 자른 뒤 값으로 재면 절단의 효과와 원래 있던 기울기가 같은 축에 겹쳐 서로를 흉내 낸다.

2. 되찾을 양

20 자 미만으로 맞춘 직선을 각 행의 진짜 길이에 넣어 예측하고 실제와의 차를 더하면 +152 행이다 — 만화 +60 · 세계애니 +42 · 편딩 +20 · 모바일 +18 · 애니 +10. 조인된 6,420 행에서 덮음 33.3% → 35.7%.

예보지 결과가 아니다. 다시 굽어야 확인된다. 고침은 넣었다 — 한도는 남기되 낱말 경계에서 자른다(스무 자가 API 제약인지 우리 선택인지 기록이 없어, 어느 쪽이든 안전한 쪽으로).




Figure 1: 가 — 자르기 전 길이별. 나 — 경계 양옆. 다 — 되찾을 양.

남은 것

- 다시 끊어야 한다 — 이 노트는 진단이고, +152 행은 예보다. 수집은 바깥으로 나가는 일이라 사람이 정한다.
- 만화 · 세계애니의 진짜 벽은 따로 있다 — 절단을 고쳐도 9.1% · 21.6% 다. 한글이 한 글자도 없는 제목에 한국어 검색을 물어서다. 그건 언어 문제가 맞다 — 다만 모바일 · 게임이 아니라 이 둘의 문제였다.
- 두 해 동안 열린 갈래의 진단이 틀려 있었다. 문장 하나가 “언어”라고 적혀 있어서 아무도 길이를 안 봤다. 갈래 목록의 설명은 측정이 아니라 짐작이었는데 측정처럼 읽혔다.