

굵기 전에 상금을 줬더니 내가 적은 규칙이 틀렸다 — 상한을 추정값으로 쓴 사전 등록을, 발동했는데도 안 따랐다

월드모델 실험실

노트 548 · 2026년 8월 4일

초 록

대기 중이던 갈래 “모바일 · 게임 검색 뒀음 30~41% 제목 언어 한계”를 열었다. 편당은 뒀음이 1.0% 인데 수집기에 남은 요청이 588 개 있다. 굵기 전에 상금부터 줬다 — 검색 축을 통째로 끄면 얼마나 읽나.

도메인	유보	검색 뒀음	끄면
도서	163	39.9%	-0.1654
게임	180	63.3%	-0.0515
애니	606	36.0%	-0.0003
편당	529	1.0%	-0.0016
만화	258	0.8%	+0.0099
팝업	65	78.7%	+0.0374 (12/12)
판			-0.0204

뒀음과 값 사이에 관계가 없다 — 순위상관 +0.191($n = 11$)이고 뒀음 30% 이상 여섯만 보면 -0.143 이다. 뒀음 79% 인 둘이 각각 해롭거나 0 이다.

1. 갈래의 전제가 틀렸다

“제목 언어 한계”가 아니다. 데이터랩은 영문 질의에 값을 준다 (노트 237 이 이미 확정했다) — 게임에서 값을 받은 347 건 중 56% 가 영문 제목이고, 원천에 아예 없는 135 건은 한글 제목이 5.9% 다. 언어가 막은 것이 아니라 안 굵은 것이다.

질의어	값	결과 없음	빈손 비율
< 20 자	4,152	3,656	46.8%
= 20 자(잘림)	53	2,133	97.6%

전체 빈손의 36.8% 가 스무 자 잘림이다. 그리고 이것은 이미 아는 결함이다 — 노트 490 · 491 이 회귀 불연속으로 잡았고(정확히 20 자 18.3% 대 21 자 0.6%, 승산비 29.2) “_cap” 을 낱말 경계로 고쳤다. 그런데 다시 안 굵어서 저장 파일에 옛 20 자 질의어가 2,179 건 남아 있다.

null 은 수집 실패가 아니다. 같은 질의어가 한 파일에선 값이 있고 다른 파일에선 없는 경우는 49 개 · 전체 null 의 0.9% 뿐이다. 재시도도 되찾을 것이 아니다.

2. 결측 자체가 정보다

전 도메인에서 “검색에 안 잡힘”이 라벨과 양수다(연도 통제) — 애니 +0.3522 · 도서 +0.1808 · 웹툰 +0.1600 · 게임 +0.1590 · 모바일 +0.1233 · 만화 +0.1049 · 편당 +0.0978 · 세계애니 +0.0506.

“검색량이 문턱 아래다”가 곧 “무명하다”이고, zero_is_data 표시자가 이미 그것을 갖고 있다. 뒀음을 채우는 값은 보이는 것보다 작다 — 이진 표시자를 눈금으로 바꾸는 것뿐이다.




Figure 1: 가 — 스무 자 절벽. 나 — 결측이 정보다. 다 — 덮음과 값이 안 맞는다.

3. 내가 적은 규칙이 틀렸다

사전 등록에 이렇게 적었다 — “판 손실 ≥ 0.010 이면 판딩 수집을 한다”. 손실은 -0.0204 다. 규칙이 발동했다.

그런데 안 따른다. 같은 문장에 “이 값이 모든 검색 수집의 상한이다”라고 적어 놓고, 그 상한을 추정값처럼 쓰는 결정 규칙을 달았다. 상한이 문턱을 넘는 것은 “넘을 수도 있다”이지 “넘는다”가 아니다.

그리고 갈라 보니 추론 자체가 안 선다.

- 덮음이 값을 예측 못 한다 — 순위상관 $+0.191$, 덮음 30% 이상만 보면 -0.143 . 덮음 78.7% 인 팝업은 해롭고 79.0% 인 아이들은 0 이다.
- 판딩 자신의 값이 $-0.0016(3/12, 0$ 을 문다)이다.
- 가장 후한 가정 — 덮음을 14% 까지 올리고(잘림 고친 뒤 히트율) 도서의 값을 그대로 얻는다고 쳐도 — 판 $+0.0083$ 으로 문턱 아래다. 그 가정에 근거도 없다.

판딩 수집을 안 한다. 규칙은 결과를 보고 고치는 것이 아니라 잘못 쓴 양을 바로잡는 것이다 — 상한과 추정값은 다른 것이고, 그 구분은 사전 등록 문장 안에 이미 적혀 있었다.

4. 대신 실험이 후보를 냈다

검색이 해로운 곳	덮음	끄면	무게
팝업	78.7%	$+0.0374$ (12/12)	1.9%
만화	0.8%	$+0.0099$ (10/12)	7.5%
KR 만화(집 밖)	—	$+0.0088$ (12/12)	자

애니는 이미 DOMDROP 에 들어 있다 — 그래서 -0.0003 이다. 같은 처방이 두 곳 더 있을 수 있고, 집 밖 짝까지 같은 방향 이라는 것이 강한 신호다. 노트 551 에서 네 팔로 가른다.

조항

상한을 재는 실험에는 상한용 결정 규칙을 단다. “이 값이 상한이다” 와 “이 값이 문턱을 넘으면 한다” 를 같은 문단에 쓰면 안 된다. 그리고 덮음은 값이 아니다 — 자료를 더 모으는 결정은 덮음이 아니라 그 도메인에서 그 축이 버는 양으로 한다.

남은 것

- 도서가 -0.1654 — 검색이 그 도메인 ρ 의 41% 를 낸다($0.4038 \rightarrow 0.2384$). 유보 163 행뿐이라 무게는 4.8% 지만, 왜 도서만 그런지는 안 봤다.

- 스무 자 잘림 재수집 — 대상 2,015 건인데 노트 491 의 추정대로면 되찾을 것이 ~170 행이고, 그 대부분이 만화(842 건 재질의 $\rightarrow$ 덮음 0.8% $\rightarrow$ 2.4%)라 값이 없다. 안 한다.
- 시장팝업 덮음이 0.0% 인데 끄면 -0.0103 이다 — 제 검색 축이 없는데도 잃는다. 남의 학습이 바뀌어서 생기는 간접 효과다.