

IP 파운데이션 월드모델 연구 노트 474

밴드가 천장보다 높았다

내가 열린 전향 시험대는 집안에서 본 크기의 효과를 검출할 힘이 없었다 --- 그리고 초판은 그것을 “불가능”이라 과장했다

Sweetspot 월드모델 연구

2026년 8월 9일

초 록

직전 사이클은 판을 움직일 후보(영화 국적)를 집안에서 재현하고, 집 밖 짝이 없으니 전향 봉인으로 시험 하겠다며 30편에 대한 예측을 개봉 이틀 전에 열렸다. 좋은 규율처럼 보였다. 이번 사이클에 그 동결물을 점검하니 셋이 고장나 있었다. 파일이 gitignore에 걸려 커밋되지 않았고(동결이 아니었다), 그것을 읽는 코드가 저장소에 0건이었고(9월 수확에서 자동 채점될 수 없었다), 판정에 쓰겠다고 적은 “대조 밴드”가 정의된 적이 없었다.

셋을 고치다 넷째가 나왔고 그게 이 논문이다. 밴드를 제대로 재고 비교 대상의 도달 가능 범위를 함께 재니, 국적 팔이 라벨을 완벽히 맞혀도 $\Delta\rho$ 의 상한이 0.101인데 밴드가 0.1668이었다. 두 팔의 순위 상관인 0.899라 한 팔이 $\rho=1$ 이면 다른 팔은 자동으로 $\rho=0.899$ 이고 차의 천장이 $1 - 0.899$ 로 놀린다. 단원형으로 $\sqrt{m(1-\rho)}/2$ 이므로 2σ 를 넘으려면 $m > 79$ 가 필요하다.

초판은 여기서 “양성이 발화할 라벨이 우주에 없다 — 확률이 아니라 구조”라고 썼다. 철회한다. 라벨을 적대적으로 고르면 $\Delta\rho = +0.4245$ 로 밴드를 넘는다. 그 수는 내 산출물이 같은 파일에 이미 인쇄하고 있었고, 나는 그것을 적어 놓고 다섯 줄 뒤에 반대되는 결론을 썼다. 참인 명제는 좁다: 완벽 예측 방향으로 못 넘고, 넘는 라벨은 대조 팔이 음의 상관인 세계다.

그리고 정정판이 찾은 것이 초판의 발견보다 중요하다. 천장은 출력이 아니다. 편별 짝 통계로 바꾸니 완벽 예측이 5.07σ 가 되어 초판의 검사를 통과했는데, 실제 관심 효과 크기(전향 정합 $\rho \approx 0.21$)에서 검정력이 5%였다(귀무 크기 2.4%). 통계를 바꿔 산 것은 5%를 8%로 올린 것뿐이고 판정은 바뀌지 않는다. 진짜 벽은 통계가 아니라 m 이었다.

1. 무엇이 고장나 있었나

전향 봉인은 이 실험실이 가진 가장 비싼 증거다. 예측을 열리고 두 달을 기다린다. 그래서 열리는 절차에는 검사가 붙어 있었다 — 지문, sha, 수정 금지 문구. 그런데 그 검사들은 전부 파일 안을 봤고 파일 밖은 아무도 안 봤다.

- tracked 인가. 아니었다. cycle_log/가 gitignore라 선행 동결물 9건은 전부 git add -f 로 들어갔는데 이번 것만 빠졌다. 커밋 시각이 사전등록 증거라고 적어 놓고 커밋을 안 했다. git clean 한 번이면 사라지는 물건이었다.
- 읽는 코드가 있다. 없었다. grep -rn annex7 --include=*.py가 자기 자신 세 줄만 냈다. 기존 수확기는 팔 넷을 하드코딩해 읽는다.
- 판정에 쓰는 수가 정의됐다. 안 됐다. “대조 밴드”라고 썼는데 저장소의 밴드 넷은 전부 단일 ρ 의 밴드이고 짝 $\Delta\rho$ 의 밴드는 존재한 적이 없다. 9월에 채점자가 넷 중 하나를 고르거나 그 자리에서 만들어야 했다 — 동결이 없애려던 바로 그 재량이다.

2. 넷째 --- 밴드가 천장보다 높았다

밴드를 제대로 정의했다: 동결된 두 순위 벡터 위에서 라벨을 순열해 $\Delta\rho$ 의 귀무분포를 낸다(20만 회). $2\sigma = 0.1668$.

그 다음이 이 논문의 핵심이고, 나는 이 계산을 885에서 했어야 했다. 그 통계가 갈 수 있는 가장 먼 곳은 어디인가? 라벨을 국적 팔의 순위와 정확히 일치시켜 보면 $\rho_{국적} = 1$ 이고 $\rho_{대조} = 0.899$ (두 팔의 상관)이므로 $\Delta\rho = 0.101$ 이다. 밴드의 61%다.

상관이 높은 두 예측을 비교할 때 상관계수의 차는 천장이 놀린다. ρ 가 $[-1, 1]$ 에 갇혀 있으니 한쪽이 완벽해지면 다른 쪽도 따라 올라간다. 두 팔이 닮을수록 — 즉 실험이 잘 통제될수록 — 천장이 낮아지는 통계다. 짝 설계의 미덕이 통계의 결함으로 뒤집힌다.

정정판 부기. 초판은 이 절을 “밴드를 잘못 고른 것이 아니라 통계를 잘못 골랐다”로 닫았다. 절반만 맞다. 통계를 바꿔도 착지 예상 구간의 검정력은 5%에서 8%로 갈 뿐이다. 합성으로 m 을 키워 보면 $m=120$ 에서 7%, $m=500$ 에서 15%, $m=2000$ 에서 48%다 — 이 짝 설계로 한 열을 전향 검증하는 길은 30편에 없다.




Figure 1: 같은 30편, 같은 순열, 같은 귀무분포. 왼쪽 1차($\Delta\rho$): 초록 파선(완벽 예측)이 빨강 실선(밴드) 안쪽에 있다 — 어떤 라벨로도 못 넘는다. 오른쪽 2차($\Delta|\text{err}|$): 같은 완벽 예측이 밴드 밖 5.07σ 다. 전부 산출물에서 계산했다.

3. 고친 것과, 고치지 않은 것

편별 짝 통계로 바꿨다: $|\Delta|\text{err}|| = |r_{\text{대조}} - r_{\text{라벨}}| - |r_{\text{국적}} - r_{\text{라벨}}|$. 같은 순열에서 밴드 1.1612, 완벽 예측 2.9333 — 5.07σ . 천장이 상관에 눌리지 않는다.

그런데 이걸 골대 이동처럼 보인다. 방어를 적어 둔다. (1) 첫 봉인작 개봉이 이를 뒤이고 라벨은 아직 존재하지 않는다. (2) 기존 1차 규칙은 한 글자도 안 고쳤고 9월에 그대로 계산 · 보고된다. (3) 2차의 밴드 · τ · 갈래 빛을 지금 전부 얼렸다 — 수확일에 고를 것이 없다. (4) 둘 다 보고한다. (5) 무엇보다 2차를 고른 근거가 라벨과 무관한 사실 (두 팔의 상관 0.899)이다. 라벨을 한 톨도 안 보고 내린 결정이라는 것이 이 방어의 전부이고, 그래서 개봉 전에 해야만 했다.

고치지 않은 것도 적는다. 동결물의 국적 코드는 마스크 밖 채움값이 0.5인데 3범주에서 그 값은 미국의 코드와 같다. 봉인 30편 중 4편이 그렇게 코딩됐다. 알려진 결함이고 그대로 둔다 — 라벨 전에 얼린 것을 라벨 전이라든가 고치면 동결의 뜻이 없다. 대신 9월에 판정을 읽을 때 함께 읽으라고 사이드카에 적었다.

4. 교훈

예측을 얼린다는 것은 셋을 얼린다는 뜻이다 — 예측, 채점기, 그리고 판정에 쓰는 모든 수. 셋 중 하나라도 라벨이 생긴 뒤에 만들어지면 그 자리에 재량이 들어간다. 나는 첫째만 열려 놓고 셋 다 얼렸다고 적었다.

그리고 사전등록 체크리스트에 한 줄이 늘었다. 초판은 그 줄을 “완벽 예측이 밴드를 넘나?”로 썼는데 그것도 틀렸다 — 정정판이 얼린 2차 통계는 그 검사를 5.07σ 로 통과하면서 검정력이 5%였다. 필요조건을 충분조건 자리에 얹힌 것이다. 옳은 줄은 이렇다.

사전등록한 관심 효과 크기가 밴드를 넘나 — 그 크기에서 검정력이 몇 %인가. 그리고 음성 나오면 그것을 어떻게 읽을지를 라벨이 생기기 전에 적어라.

문턱을 정할 때 우리는 잡음의 크기만 본다. 신호가 갈 수 있는 가장 먼 곳도, 실제로 기대하는 곳에서의 힘도 함께 봐야 한다. 그 방이 없으면 두 달을 기다려 얻는 것은 답이 아니라 침묵이고, 침묵을 음성으로 읽는 순간 우리는 없는 증거를 만들어낸다.

이 논문이 두 번 틀린 방식이 같다. 초판은 천장을 재고 “불가능”이라 썼고, 그 초판의 전 사이클은 $+0.0168$ 을 보고 “전이가 늘었다”고 썼다. 둘 다 켜 것에서 안 켜 것으로 건너뛰는 문장이다. 이 실험실의 만성병은 측정이 아니라 그 다음 문장에 있다.