

IP 파운데이션 월드모델 연구 노트 475

위약이 아무것도 안 했다

위약이 0 인 것은 맞았다. 이유가 틀렸고, 이유가 틀리니 결론이 뒤집혔다 --- 열이 설계행렬에 없었다

Sweetspot 월드모델 연구

2026년 8월 9일

초 록

이 실험실은 열을 채택할 때 두 가지를 본다. 위약 6뽑기를 이기는가, 그리고 판 문턱 0.0045를 넘는가. 뒤엎것은 50노트 전에 “채기선 후 첫 채택 실험에서 짝 부트스트랩으로 다시 재라”고 등록해 두고 미뤄 온 숙제였다. 이번에 이행했더니 답이 아니라 질문이 틀렸다는 것이 나왔다.

위약 여섯을 걸었더니 도메인 Δ 가 여섯 다 정확히 0.0000이고 뽑기 SD가 0.00000이었다. 초판은 여기서 “탐욕 분할 부스팅이 이득 없는 열을 한 번도 안 가르기 때문”이라고 썼다. 틀렸다 — 철회한다. 트리는 그 열을 본 적이 없다. `AXIS_MODE="common"`이라 설계행렬은 열두 도메인이 전부 가진 축만 쓰고(실측: 목록 36개, 아이돌 전용 축 0개), 사후에 붙인 37번째 열은 거기 없다. 유일한 통로는 도메인당 한 칸인 특기 슬롯이고, 그 칸은 학습 $|r| \argmax$ 로 정해진다. 잡음 열은 $\argmax$ 를 원리상 못 이긴다 — 그래서 Δ 가 정확히 0인 것은 통계 결과가 아니라 항등식이었다.

이유가 바뀌니 결론이 뒤집힌다. 초판은 “위약이 0이니 가드가 반보수적이다”라고 썼는데, 올바른 경로(열을 열두 도메인에 다 붙이는 길)에서 재면 아이돌의 위약 바닥은 +0.017이고 후보 `versions`의 +0.0278은 그 1.6배에 불과하다. 가드는 험거운 게 아니라 적절히 보수적이었고, 후보는 아마 못 넘는다. 그리고 그 경로에서 차원 비용도 실재한다(1열 판 -0.0018~-0.0063).

1. 먼저: 그 문턱은 얇은 도메인을 배제한다

측정 전에 산술부터 했다(직전 사이클이 만든 규약 — 채기 전에 도달 범위를 계산하라). 판 ρ 는 도메인 ρ 의 유보 행수 가중 평균이므로, 한 도메인에만 붙는 열의 판 Δ 는 대략 그 도메인 가중 $\times$ 도메인 Δ 다. 기지 사례 셋으로 맞춰 봤다: 영화 국적 0.0577 $\times$ 0.1075 = 0.00621(실제 +0.0063), 만화 3열 0.00158(실제 +0.0020), 모바일 `n_device` -0.00005(실제 0.0000). 셋 다 맞는다.

그러면 판 문턱 0.0045를 넘는 데 필요한 도메인 Δ 는 0.0045/가중이다. 웹툰 0.026부터 아이돌 0.333까지 열두 배 넘게 벌어진다. 최근 채택 아크에서 갓 1열 도메인 효과의 최대가 0.0577이니, 얇은 다섯 도메인의 열은 판 문턱을 구조적으로 못 넘는다. 그래서 이번 판정은 도메인 수준에서 했고, 판 Δ 는 병기만 했다.

2. Δ 가 정확히 0이면 통계로 읽지 마라

`unit_price`는 초판이 “없다”로 판정했다. 그것도 철회한다. 그 열의 유보 상관은 +0.2676($n=49$)으로 `versions`의 +0.2867과 거의 같다. Δ 가 0이었던 것은 정보가 없어서가 아니라 학습 $|r| \argmax$ 에서 `cal_dow_sin` (0.1847)에 0.035 차로 져서 모형에 한 칸도 안 닿았기 때문이다. “없다”가 아니라 “미측정”이다.

그리고 이 실험실의 코드는 이 증상을 이미 경고하고 있었다. 특징 생성기의 주석에 이렇게 적혀 있다 — “축을 여덟 개 덧붙여도 모형에 한 칸도 안 닿았다. 차이가 정확히 +0.0000으로 나온 게 단서였다.” 나는 같은 단서를




Figure 1: 왼쪽: 위약 여섯(빨강)이 한 점에 겹쳐 있다 — 흠여점이 아니라 점이다. 초록은 유일하게 움직인 후보와 그 95% 구간. 오른쪽: 판 문턱을 넘는 데 필요한 도메인 Δ . 초록 파선이 이제껏 갓 1열 최대치다. 빨강 막대는 그 선을 넘을 수 없는 도메인들이다. 전부 산출물에서 계산했다.

다시 만나고 다른 이야기를 지어냈다.

그래서 검사 문구가 하나 늘었다. Δ 가 정확히 0이면 통계로 읽기 전에 설계행렬을 비트 대조하라.

3. 범위 --- 어디까지 참인가

이 퇴화는 사후 주입 · 단일 도메인 경로에만 있다. 초판은 그 이유를 “정상 경로는 공유 인자 공간을 탄다”로 적었는데 그것도 틀렸다 — 그 기계(`factor_space`)는 다른 정식화 전용이고 챔피언은 쓰지 않는다. 진짜 이유는 정상 경로가 열을 열두 도메인 전부에 붙여 공통 축으로 만들기 때문이고, 그러면 특기 슬롯을 거치지 않고 설계행렬에 바로 들어간다.

그러니 “우리 위약은 전부 가짜였다”로 읽으면 안 된다. 읽어야 할 것은 이것이다: 위약이 무효가 되는 것은 모형의 성질이 아니라 주입 경로의 성질이다. 위약 분포의 폭을 함께 보고, 폭이 0이면 가드를 의심하기 전에 배선을 의심하라.

내가 이 경로를 쓴 것도 선택이 아니었다. 아이들은 열두 도메인 중 유일하게 표준 주입이 조용히 중립화된단 — 아이돌 열 부착부가 달력 · 위키 · 트렌드 제공자만 보고 주입 덕트를 안 읽어서, 이름만 등록되고 값은 통째로 0.5·마스크 0이 된다. 열두 도메인에 탐침을 넣어 전수로 켜고, 걸린 것은 아이돌 하나다.

4. 교훈

나는 이 사이클의 초판을 통째로 버렸다. 사전등록에 “_idol은 조용히 중립화한다 — 마스크 합과 값 가짓수를 찍어 확인한다”라고 적어 놓고, 그 검사를 내가 만든 배열에 걸었다. 마스크 149/173, 값 가짓수 9 — 전부 참이고 전부 무의미했다. 확인해야 했던 것은 하네스가 돌려준 행렬이고, 거기서는 마스크 합이 0이었다. 인용한 노트에 인용하면서 질렸다.

그래서 규약이 늘었다. 배선 검사는 입력이 아니라 산출 행렬에 건다. Δ 가 정확히 0이면 설계행렬을 비트 대조하라. 그리고 정정판이 하나 더 붙었다 — 산출물 없는 측정에서는 규약을 주조하지 않는다. 초판의 규약은 스크래치패드 한 번의 측정에서, 틀린 인과 이야기와 함께, 같은 사이클에 주조됐다. 러너도 산출물도 없어서 다음 사람이 재현할 수 없었다.

두 사이클 연속으로 같은 방식으로 틀렸다. 직전 논문은 천장을 채고 “불가능”이라 썼고, 이 논문의 초판은 0을 보고 “트리가 안 가른다”고 썼다. 둘 다 켜 것에서 안 켜 것으로 건너뛴 문장이다. 이번엔 코드가 그 문장을 반박하는 주석을 이미 달아 놓고 있었다는 점만 다르다.