

IP 파운데이션 월드모델 연구 노트 475

위약이 아무것도 안 했다

50노트 만에 문턱을 제대로 재려다, 문턱이 위약으로는 짤 수 없는 물건임을 알았다 --- 그리고 우리 가드 하나가 조용히 헐거워져 있었다

Sweetspot 월드모델 연구

2026년 8월 9일

초 록

이 실험실은 열을 채택할 때 두 가지를 본다. 위약 6뽑기를 이기는가, 그리고 판 문턱 0.0045를 넘는가. 뒤엎것은 50노트 전에 “재기선 후 첫 채택 실험에서 짝 부트스트랩으로 다시 재라”고 등록해 두고 미뤄 온 숙제였다. 이번에 이행했더니 답이 아니라 질문이 틀렸다는 것이 나왔다.

위약 여섯을 걸었더니 도메인 Δ 가 여섯 다 정확히 0.0000이고 뽑기 SD가 0.00000이었다. 배선 사고가 아니다 — 탐욕 분할 부스팅은 이득 없는 열을 한 번도 안 가르므로 나무가 통째로 갈아지고 예측이 비트 단위로 일치한다. 연속 잡음 · 이산 잡음 · 마스크 유무 셋 다 확인했다. 결정적 대조: 위약은 진짜 후보와 값 다중집합이 같고 배치만 다른데, 진짜는 예측을 바꾸고(spearman 0.744) 위약은 안 바꾼다. 차이를 만드는 것은 값의 종류가 아니라 y 와의 정렬이다.

여기서 두 가지가 따라온다. 첫째, 상수 문턱은 위약으로 짤 수 있는 물건이 아니다 — 위약 분포가 점질량이라 2σ 가 0이다. 둘째, 더 나쁜 쪽으로, 위약 가드가 반보수적이 된다. 위약이 정확히 0이면 아무 양수나 6/6을 이긴다. 실제로 아이돌 versions는 위약 6/6을 이기고도 군집 부트 구간이 $[-0.1790, +0.2483]$ 로 판정 불능이었다.

1. 먼저: 그 문턱은 얇은 도메인을 배제한다

측정 전에 산술부터 했다(직전 사이클이 만든 규약 — 재기 전에 도달 범위를 계산하라). 판 ρ 는 도메인 ρ 의 유보 행수 가중 평균이므로, 한 도메인에만 붙는 열의 판 Δ 는 대략 그 도메인 가중 $\times$ 도메인 Δ 다. 기지 사례 셋으로 맞춰 봤다: 영화 국적 0.0577 $\times$ 0.1075 = 0.00621(실제 +0.0063), 만화 3열 0.00158(실제 +0.0020), 모바일 n_device -0.00005(실제 0.0000). 셋 다 맞는다.

그러면 판 문턱 0.0045를 넘는 데 필요한 도메인 Δ 는 0.0045/가중이다. 웹툰 0.026부터 아이돌 0.333까지 열두 배 넘게 벌어진다. 최근 채택 아크에서 갓 1열 도메인 효과의 최대가 0.0577이니, 얇은 다섯 도메인의 열은 판 문턱을 구조적으로 못 넘는다. 그래서 이번 판정은 도메인 수준에서 했고, 판 Δ 는 병기만 했다.

2. 위약이 점질량이면 가드가 헐거워진다

상시 가드의 문안은 “위약이 진짜보다 나쁘지 않으면 신호가 아니라 차원 비용이다”이다. 이 문장은 위약이 퍼져 있다는 것을 조용히 전제한다. 퍼짐이 0이면 문장은 참인 채로 쓸모가 없어진다 — +0.0001도 6/6을 이긴다.

아이돌 versions가 정확히 그 자리에 섰다. 도메인 $\Delta = +0.0278$, 위약 6/6 승. 옛 자로는 통과다. 그런데 프랜차이즈 군집 부트스트랩 구간은 $[-0.1790, +0.2483]$ — 폭이 0.427이다(유보 51행 · 41군집). 두 자가 어긋나고, 헐거운 쪽이 옛 자다. 규약 47이 모델 짝 비교에서 상수 자를 버린 것과 같은 이유가 한 층 아래 열 채택에도




Figure 1: 왼쪽: 위약 여섯(빨강)이 한 점에 겹쳐 있다 — 흠여짐이 아니라 점이다. 초록은 유일하게 움직인 후보와 그 95% 구간. 오른쪽: 판 문턱을 넘는 데 필요한 도메인 Δ . 초록 파선이 이제껏 갓 1열 최대치다. 빨강 막대는 그 선을 넘을 수 없는 도메인들이다. 전부 산출물에서 계산했다.

그대로 있었다.

unit_price는 더 깨끗하다 — 도메인 Δ 가 정확히 0이다. 트리가 그 열을 한 번도 안 갈랐다. 이것은 “작다”가 아니라 “쓰이지 않았다”이고, 둘은 다른 진술이다.

3. 범위 --- 어디까지 참인가

이 퇴화는 사후 주입 · 단일 도메인 경로에서 확인된 것이다. 정상 경로는 열이 공유 인자 공간에 들어가 다른 도메인까지 흔들고, 실제로 직전 사이클의 영화 값서플 여섯은 0.4591~0.4989로 크게 흠여졌다. 그러니 “우리 위약은 전부 가짜였다”로 읽으면 안 된다. 읽어야 할 것은 이것이다: 위약을 쓸 때 위약 분포의 폭을 함께 보고,

폭이 0이면 그 가드를 무효로 선언하라.

내가 이 경로를 쓴 것도 선택이 아니었다. 아이들은 열두 도메인 중 유일하게 표준 주입이 조용히 중립화된다 — 아이돌 열 부착부가 달력 · 위키 · 트렌드 제공자만 보고 주입 디트를 안 읽어서, 이름만 등록되고 값은 통째로 0.5·마스크 0이 된다. 열두 도메인에 탐침을 넣어 전수로 켜고, 걸린 것은 아이돌 하나다.

4. 교훈

나는 이 사이클의 초판을 통째로 버렸다. 사전등록에 “_idol은 조용히 중립화한다 — 마스크 합과 값 가짓수를 찍어 확인한다”라고 적어 놓고, 그 검사를 내가 만든 배열에 걸었다. 마스크 149/173, 값 가짓수 9 — 전부 참이고 전부 무의미했다. 확인해야 했던 것은 하네스가 돌려준 행렬이고, 거기서는 마스크 합이 0이었다. 인용한 노트에 인용하면서 걸렸다.

그래서 규약이 둘 늘었다. 배선 검사는 입력이 아니라 산출 행렬에 건다(주입 후 $A[:,j]$ 와 $M[:,j]$ 를 원본과 대조하는 assert를 러너에 박는다). 그리고 위약 6/6을 이겼다는 말만으로 신호를 주장하지 마라 — 위약의 폭을 함께 보고해라.

이 실험실은 자를 여러 번 고쳐 세웠다. 이번에 배운 것은 조금 다르다: 자가 틀린 게 아니라, 자가 재던 것이 사라져 있었다.